

Draftable Comparison Export

This document is an exported comparison with limited functionality, generated by Draftable Desktop. To access full functionality, use Draftable's powerful comparison viewer in any of our products.

Left document: TI_Paniagua_Daniel_V2.pdf

Right document: TI_Paniagua_Daniel_V3.pdf

What is this document?

This is a comparison of two documents. The two documents are interleaved such that the left document is displayed on even pages and the right document is displayed on odd pages.

Is there a specific way I should view this file?

This document is intended to be viewed in Two Page Continuous mode (or sometimes called 'Two Page Scrolling'). It should open in this mode by default when using Adobe Acrobat and most popular PDF readers.

If the document opens in a different view, you can often change this in the settings. In Adobe Acrobat, go to **View > Page Display > Two Page Scrolling**

Why are there blank pages?

Blank pages are inserted to keep both documents as aligned as much as possible.

How do I read the changes?

Text deleted from the left document and, hence, not in right document is highlighted red. Text added to the right document and, hence, not in left document is highlighted green.

Tip for printing

When printing this document, we recommend printing double-sided and include this first page. This will result in the matching text being displayed on different pages and easily readable, much like a book.

For more information

Draftable offers powerful document comparison solutions for all use-cases. To view our products, please visit our website: draftable.com.

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Demanda eléctrica y operación del sistema argentino	1
1.2. Contexto y motivación	2
1.3. Estado del arte	3
1.4. Objetivos y alcance	5
2. Introducción específica	7
2.1. Frameworks para procesamiento y modelado	7
2.2. Fuentes de datos para el pronóstico de demanda	8
2.3. Modelos fundacionales para series temporales	10
2.4. Infraestructura híbrida de datos y cómputo	10
3. Diseño e implementación	13
Bibliografía	15

Índice general

Resumen	I
1. Introducción general	1
1.1. Demanda eléctrica y operación del sistema argentino	1
1.2. Contexto y motivación	2
1.3. Estado del arte	3
1.4. Objetivos y alcance	5
2. Introducción específica	7
2.1. Frameworks para procesamiento y modelado	7
2.2. Fuentes de datos para el pronóstico de demanda	8
2.3. Modelos fundacionales para series temporales	10
2.4. Infraestructura híbrida de datos y cómputo	10
3. Diseño e implementación	13
3.1. Pipeline de datos	13
3.1.1. Criterios de diseño del pipeline	14
3.1.2. Ingesta de demanda desde el SOTR	14
3.1.3. Transformación de demanda de diez minutos a resolución horaria	17
3.1.4. Ingesta y procesamiento de datos meteorológicos reales	19
Bibliografía	21

Índice de figuras

Índice de figuras

3.1. Regiones eléctricas del SADI según definición utilizada por CAM-MESA.	15
3.2. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado.	16
3.3. Corrección de valores extremos.	18
3.4. Corrección de saltos bruscos.	18
3.5. Pipeline de Fabric para la orquestación de datos meteorológicos. . .	20

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.	5
2.1. Fuentes de datos utilizadas en el trabajo.	9

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.	5
2.1. Fuentes de datos utilizadas en el trabajo.	9

Dedicado a... [OPCIONAL]

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI).

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI).

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA), en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA), en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas [1]. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas [2]. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño [3]. Aquila et al. revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico [4]. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas [1]. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas [2]. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño [3]. Aquila et al. revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico [4]. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles, como XGBoost, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En el trabajo, XGBoost se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar horizontes de múltiples pasos y representar patrones en distintas escalas. Oreshkin et al. aplicaron N-BEATS al pronóstico de demanda eléctrica de mediano plazo sobre 35 series nacionales europeas y obtuvieron mejoras frente a métodos estadísticos, de aprendizaje automático e híbridos [5]. El resultado aporta evidencia específica sobre la utilidad de las arquitecturas residuales para modelar tendencias, estacionalidades y fluctuaciones de la demanda, aunque trabaja con series mensuales y un horizonte diferente del considerado en este trabajo.

Otras arquitecturas, entre ellas N-HiTS y modelos basados en Transformers como PatchTST, extienden esta línea mediante mecanismos de procesamiento multiescala y segmentación temporal [6, 7]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos y aprovechar ventanas históricas extensas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se pre-entrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo [8]. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles, como XGBoost, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En el trabajo, XGBoost se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar horizontes de múltiples pasos y representar patrones en distintas escalas. Oreshkin et al. aplicaron N-BEATS al pronóstico de demanda eléctrica de mediano plazo sobre 35 series nacionales europeas y obtuvieron mejoras frente a métodos estadísticos, de aprendizaje automático e híbridos [5]. El resultado aporta evidencia específica sobre la utilidad de las arquitecturas residuales para modelar tendencias, estacionalidades y fluctuaciones de la demanda, aunque trabaja con series mensuales y un horizonte diferente del considerado en este trabajo.

Otras arquitecturas, entre ellas N-HiTS y modelos basados en Transformers como PatchTST, extienden esta línea mediante mecanismos de procesamiento multiescala y segmentación temporal [6, 7]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos y aprovechar ventanas históricas extensas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se pre-entrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo [8]. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [1]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [2]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [3]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Oreshkin et al. [5]	N-BEATS	Demanda mensual de 35 países europeos.	Mejora de la precisión y del sesgo frente a diez métodos.
Meyer et al. [8]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del sistema como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendario necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando un modelo XGBoost como referencia.
- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [1]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [2]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [3]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Oreshkin et al. [5]	N-BEATS	Demanda mensual de 35 países europeos.	Mejora de la precisión y del sesgo frente a diez métodos.
Meyer et al. [8]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del sistema como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendario necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando un modelo XGBoost como referencia.
- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.

- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, bibliotecas, fuentes de datos e infraestructura de cómputo utilizadas como soporte del trabajo. El propósito es describir los componentes de terceros y el entorno tecnológico utilizados.

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Aquellas actividades que requerían acceso directo a sistemas internos o ejecución desde la red local se alojaron en una instalación de Dagster ejecutada en infraestructura propia de la empresa.

2.1. Frameworks para procesamiento y modelado

El lenguaje principal utilizado fue Python, debido a su amplia adopción en ciencia de datos y a la disponibilidad de bibliotecas para aprendizaje automático, series temporales y acceso a fuentes heterogéneas. Su utilización permitió mantener una base tecnológica común entre los notebooks ejecutados en Fabric y los procesos alojados en el servidor local.

Para la preparación y análisis de datos se utilizó principalmente la librería `pandas`, que proporciona estructuras tabulares y operaciones para selección, agrupamiento y transformación de datos. Esta herramienta resulta apropiada para el tratamiento de series temporales de demanda y meteorología, especialmente en las etapas que pueden resolverse en memoria sobre un único nodo.

Cuando el volumen de datos o la integración con los servicios de Fabric lo requirió, se empleó PySpark. Los notebooks de Fabric admiten procesamiento distribuido mediante Apache Spark y permiten combinar DataFrames de Spark con `pandas`. Esta alternativa proporciona escalabilidad para el tratamiento de datos históricos con resolución horaria o inferior, sin abandonar el ecosistema Python utilizado en el resto de la solución [9].

Para los modelos de referencia se previó el uso de regresiones lineales y algoritmos basados en árboles, particularmente XGBoost. Las regresiones lineales ofrecen una línea de base simple e interpretable, útil para verificar que modelos más complejos aporten una mejora real. XGBoost, por su parte, permite representar relaciones no lineales e interacciones entre variables históricas, meteorológicas y calendarias. La interfaz compatible con `scikit-learn` facilita la preparación de experimentos, el ajuste de hiperparámetros y el cálculo homogéneo de métricas.

Los modelos neuronales abarcan redes recurrentes, como LSTM y GRU, y arquitecturas más recientes diseñadas para el pronóstico de múltiples pasos. Para su

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, bibliotecas, fuentes de datos e infraestructura de cómputo utilizadas como soporte del trabajo. El propósito es describir los componentes de terceros y el entorno tecnológico utilizados.

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Aquellas actividades que requerían acceso directo a sistemas internos o ejecución desde la red local se alojaron en una instalación de Dagster ejecutada en infraestructura propia de la empresa.

2.1. Frameworks para procesamiento y modelado

El lenguaje principal utilizado fue Python, debido a su amplia adopción en ciencia de datos y a la disponibilidad de bibliotecas para aprendizaje automático, series temporales y acceso a fuentes heterogéneas. Su utilización permitió mantener una base tecnológica común entre los notebooks ejecutados en Fabric y los procesos alojados en el servidor local.

Para la preparación y análisis de datos se utilizó principalmente la biblioteca `pandas`, que proporciona estructuras tabulares y operaciones para selección, agrupamiento y transformación de datos. Esta herramienta resulta apropiada para el tratamiento de series temporales de demanda y meteorología, especialmente en las etapas que pueden resolverse en memoria sobre un único nodo.

Cuando el volumen de datos o la integración con los servicios de Fabric lo requirieron, se empleó PySpark. Los notebooks de Fabric admiten procesamiento distribuido mediante Apache Spark y permiten combinar DataFrames de Spark con `pandas`. Esta alternativa proporciona escalabilidad para el tratamiento de datos históricos con resolución horaria o inferior, sin abandonar el ecosistema Python utilizado en el resto de la solución [9].

Para los modelos de referencia se previó el uso de regresiones lineales y algoritmos basados en árboles, particularmente XGBoost. Las regresiones lineales ofrecen una línea de base simple e interpretable, útil para verificar que modelos más complejos aporten una mejora real. XGBoost, por su parte, permite representar relaciones no lineales e interacciones entre variables históricas, meteorológicas y calendarias. La interfaz compatible con `scikit-learn` facilita la preparación de experimentos, el ajuste de hiperparámetros y el cálculo homogéneo de métricas.

Los modelos neuronales abarcan redes recurrentes, como LSTM y GRU, y arquitecturas más recientes diseñadas para el pronóstico de múltiples pasos. Para su

implementación se consideraron bibliotecas especializadas en series temporales que utilizan PyTorch como motor de entrenamiento. Este enfoque permite evaluar familias de modelos con una interfaz común y reducir diferencias de implementación que podrían afectar la comparación.

El seguimiento de experimentos y modelos se apoyó en MLflow, integrado en las capacidades de ciencia de datos de Fabric. MLflow permite registrar parámetros, métricas y artefactos asociados con cada ejecución, además de conservar versiones de los modelos. Su elección respondió a la necesidad de comparar alternativas de manera reproducible y mantener trazabilidad entre los datos utilizados, la configuración de entrenamiento y los resultados obtenidos. Fabric incorpora esta herramienta dentro de sus notebooks y experiencias de ciencia de datos [10].

En el entorno local se utilizó Dagster como orquestador de datos. Su modelo basado en activos permite representar tablas, archivos y otros productos persistentes como elementos con dependencias explícitas, historial de ejecuciones y políticas de actualización [11, 12]. Esta característica resulta adecuada para los procesos que obtienen información desde sistemas internos y posteriormente la escriben en Fabric. pandas y NumPy se utilizaron también en este entorno, junto con bibliotecas de Azure para autenticación y acceso a servicios en la nube.

Para la lectura de series operativas se utilizó PIconnect, conector de Python para PI System y PI Asset Framework. La biblioteca permite consultar valores registrados o interpolados mediante el SDK de PI, por lo que posibilita acceder desde el servidor local a la información histórica del Sistema Operativo en Tiempo Real (SOTR) de CAMMESA [13].

Finalmente, Power BI se empleó como herramienta de visualización, tanto para los pronósticos como para las métricas de desempeño. Su integración con Fabric permite construir informes sobre los datos centralizados sin incorporar una capa adicional de exportación.

2.2. Fuentes de datos para el pronóstico de demanda

Los conjuntos de datos utilizados fueron contruidos a partir de fuentes internas de CAMMESA y servicios meteorológicos externos. No se trató, por lo tanto, de un dataset público **preparado previamente** para aprendizaje automático, sino de información operativa que debió integrarse con distintas resoluciones, coberturas geográficas y condiciones de acceso.

La variable principal provino de registros de demanda eléctrica del sistema SOTR, almacenados en PI System. Las series poseen una resolución original de diez minutos y representan la demanda del SADI y de sus regiones eléctricas. A partir de estas series se obtienen las variables diarias que actúan como objetivos de pronóstico: energía y potencias mínima y máxima.

También se incorporó información calendaria, como día de la semana, feriados y otras clasificaciones utilizadas habitualmente por los especialistas. Estas variables permiten representar modificaciones del consumo asociadas con la actividad residencial, comercial e industrial.

La información meteorológica se obtuvo de tres fuentes. La primera correspondió al Servicio Meteorológico Nacional (SMN), cuyos datos se consideraron prioritarios por su carácter oficial. Se utilizaron archivos de observaciones diarias y

implementación se consideraron bibliotecas especializadas en series temporales que utilizan PyTorch como motor de entrenamiento. Este enfoque permite evaluar familias de modelos con una interfaz común y reducir diferencias de implementación que podrían afectar la comparación.

El seguimiento de experimentos y modelos se apoyó en MLflow, integrado en las capacidades de ciencia de datos de Fabric. MLflow permite registrar parámetros, métricas y artefactos asociados con cada ejecución, además de conservar versiones de los modelos. Su elección respondió a la necesidad de comparar alternativas de manera reproducible y mantener trazabilidad entre los datos utilizados, la configuración de entrenamiento y los resultados obtenidos. Fabric incorpora esta herramienta dentro de sus notebooks y experiencias de ciencia de datos [10].

En el entorno local se utilizó Dagster como orquestador de datos. Su modelo basado en activos permite representar tablas, archivos y otros productos persistentes como elementos con dependencias explícitas, historial de ejecuciones y políticas de actualización [11, 12]. Esta característica resulta adecuada para los procesos que obtienen información desde sistemas internos y posteriormente la escriben en Fabric. NumPy y pandas se utilizaron también en este entorno, junto con bibliotecas de Azure para autenticación y acceso a servicios en la nube.

Para la lectura de series operativas se utilizó PIconnect, conector de Python para PI System y PI Asset Framework. La biblioteca permite consultar valores registrados o interpolados mediante el SDK de PI, por lo que posibilita acceder desde el servidor local a la información histórica del Sistema Operativo en Tiempo Real (SOTR) de CAMMESA [13].

Finalmente, Power BI se empleó como herramienta de visualización, tanto para los pronósticos como para las métricas de desempeño. Su integración con Fabric permite construir informes sobre los datos centralizados sin incorporar una capa adicional de exportación.

2.2. Fuentes de datos para el pronóstico de demanda

Los conjuntos de datos utilizados fueron contruidos a partir de fuentes internas de CAMMESA y servicios meteorológicos externos. No se trató, por lo tanto, de un dataset público para aprendizaje automático, sino de información operativa que debió integrarse con distintas resoluciones, coberturas geográficas y condiciones de acceso.

La variable principal provino de registros de demanda eléctrica del sistema SOTR, almacenados en PI System. Las series poseen una resolución original de diez minutos y representan la demanda del SADI y de sus regiones eléctricas. A partir de estas series se obtienen las variables diarias que actúan como objetivos de pronóstico: energía y potencias mínima y máxima.

También se incorporó información calendaria, como día de la semana, feriados y otras clasificaciones utilizadas habitualmente por los especialistas. Estas variables permiten representar modificaciones del consumo asociadas con la actividad residencial, comercial e industrial.

La información meteorológica se obtuvo de tres fuentes. La primera correspondió al Servicio Meteorológico Nacional (SMN), cuyos datos se consideraron prioritarios por su carácter oficial. Se utilizaron archivos de observaciones diarias y

datos horarios publicados en formato de texto [14]. Debido a restricciones de acceso desde direcciones IP externas al país, la descargas automáticas se realizan desde el servidor local y los archivos se almacenan en un Lakehouse de Fabric para su posterior lectura. Los registros incluyen, entre otras variables, temperatura, humedad relativa, presión y viento. La desventaja que presentan los datos de pronóstico del SMN es que su horizonte máximo es de 7 días, incluyendo el día en curso.

La segunda fuente fue Open-Meteo, utilizada para obtener datos históricos y pronósticos meteorológicos mediante interfaces de programación (API). Tiene múltiples variables disponibles, como temperatura, humedad, presión, viento, nubosidad, precipitación, radiación solar y temperatura aparente con resolución horaria o agregación diaria. La posibilidad de consultas por coordenadas facilita asociar las variables con puntos representativos de las regiones eléctricas. Para los pronósticos se seleccionaron algunos de los modelos disponibles, según el horizonte de cálculo y disponibilidad geográfica [15, 16].

La tercera fuente de pronósticos corresponde a The Weather Channel [17]. Su inclusión permite disponer de una referencia meteorológica adicional, que además es habitualmente consultada por el área de Programación Semanal y Diaria de CAMMESA. Esta fuente presenta un horizonte máximo de pronóstico de 15 días, que se ajusta al requerimiento para predicción de demanda.

La tabla 2.1 resume las fuentes consideradas.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	Contenido principal	Resolución y cobertura	Condición de uso
SOTR PI System	Demanda eléctrica del SADI y sus regiones.	Series de diez minutos, con cobertura nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, fines de semana, feriados y clasificaciones especiales.	Información con resolución diaria.	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios de estaciones argentinas.	Datos abiertos oficiales con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios consultados por coordenadas geográficas.	Datos sujetos a las condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Datos horarios y diarios para ubicaciones seleccionadas.	Servicio de terceros para uso institucional.

datos horarios publicados en formato de texto [14]. Debido a restricciones de acceso desde direcciones IP externas al país, las descargas automáticas se realizan desde el servidor local y los archivos se almacenan en un Lakehouse de Fabric para su posterior lectura. Los registros incluyen, entre otras variables, temperatura, humedad relativa, presión y viento. La desventaja que presentan los datos de pronóstico del SMN es que su horizonte máximo es de siete días, incluyendo el día en curso.

La segunda fuente fue Open-Meteo, utilizada para obtener datos históricos y pronósticos meteorológicos mediante interfaces de programación (API). Tiene múltiples variables disponibles, como temperatura, humedad, presión, viento, nubosidad, precipitación, radiación solar y temperatura aparente con resolución horaria o agregación diaria. La posibilidad de consultas por coordenadas facilita asociar las variables con puntos representativos de las regiones eléctricas. Para los pronósticos se seleccionaron algunos de los modelos disponibles, según el horizonte de cálculo y disponibilidad geográfica [15, 16].

La tercera fuente de pronósticos corresponde a The Weather Channel [17]. Su inclusión permite disponer de una referencia meteorológica adicional, que además es habitualmente consultada por el área de Programación Semanal y Diaria de CAMMESA. Esta fuente presenta un horizonte máximo de pronóstico de 15 días, que se ajusta al requerimiento para predicción de demanda.

La tabla 2.1 resume las fuentes consideradas.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	Contenido principal	Resolución y cobertura	Condición de uso
SOTR PI System	Demanda eléctrica del SADI y sus regiones.	Series de diez minutos, con cobertura nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, fines de semana, feriados y clasificaciones especiales.	Información con resolución diaria.	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios de estaciones argentinas.	Datos abiertos oficiales con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios consultados por coordenadas geográficas.	Datos sujetos a las condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Datos horarios y diarios para ubicaciones seleccionadas.	Servicio de terceros para uso institucional.

2.3. Modelos fundacionales para series temporales

Además de los modelos entrenados específicamente con datos del SADI, se consideró la incorporación de modelos fundacionales para series temporales. Estos modelos se preentrenan sobre colecciones amplias y heterogéneas de series, con el objetivo de aprender patrones generales de tendencia, estacionalidad y dependencia temporal. Luego pueden aplicarse a nuevas series sin reentrenamiento, modalidad conocida como *zero-shot*, o adaptarse mediante procedimientos de ajuste.

Entre las alternativas consideradas se encuentran Chronos y TimesFM. Chronos representa los valores de una serie mediante una discretización que permite emplear arquitecturas derivadas de modelos de lenguaje para producir distribuciones de pronóstico [18]. TimesFM utiliza una arquitectura basada en Transformers con procesamiento por segmentos y fue preentrenado sobre grandes volúmenes de series reales y sintéticas [19]. Ambos constituyen modelos desarrollados por terceros y sus pesos preentrenados no fueron generados como parte del trabajo.

La principal ventaja de estos modelos es que permiten obtener una referencia sin entrenar una red desde cero para cada variable o región. Esto resulta especialmente útil para comprobar si el conocimiento adquirido durante el preentrenamiento se transfiere a series de demanda eléctrica del SADI. Sin embargo, su utilización plantea limitaciones. Algunos modelos preentrenados procesan de forma nativa solo la historia de la variable objetivo, mientras que el problema tratado requiere aprovechar información meteorológica y calendaria. Además, los datos de preentrenamiento pueden no representar adecuadamente las particularidades del consumo argentino, su sensibilidad térmica ni las diferencias entre regiones.

Por este motivo, estos modelos se consideraron como una familia adicional de métodos y no como sustitutos directos de los modelos supervisados. La comparación debe realizarse sobre los mismos períodos y métricas, diferenciando los resultados obtenidos sin ajuste de aquellos que **eventualmente** requieran adaptación.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura adoptó un esquema híbrido compuesto por Microsoft Fabric y un servidor local de CAMMESA. Fabric concentró la mayor parte del almacenamiento, procesamiento, experimentación y visualización, mientras que el entorno local atendió los procesos que requerían conectividad con sistemas internos.

Dentro de Fabric se utilizaron distintos tipos de elementos según la función requerida. Una base de datos KQL actuó como capa inicial o bronce para recibir información con un grado mínimo de elaboración. Las bases KQL están orientadas al análisis de datos temporales y pueden ser consultadas desde notebooks mediante *Kusto Query Language* [20]. El repositorio relacional central se implementó con un *Data Warehouse* [21], con el objetivo de alojar las capas plata y oro. Allí se almacenaron datos normalizados, integrados y preparados para el consumo analítico mediante tablas y vistas T-SQL. También se utilizó un *Data Lakehouse* [22], que se reservó principalmente para archivos auxiliares y para aquellos formatos que no requerían almacenamiento relacional.

2.3. Modelos fundacionales para series temporales

Además de los modelos entrenados específicamente con datos del SADI, se consideró la incorporación de modelos fundacionales para series temporales. Estos modelos se preentrenan sobre colecciones amplias y heterogéneas de series, con el objetivo de aprender patrones generales de tendencia, estacionalidad y dependencia temporal. Luego pueden aplicarse a nuevas series sin reentrenamiento, modalidad conocida como zero-shot, o adaptarse mediante procedimientos de ajuste.

Entre las alternativas consideradas se encuentran Chronos y TimesFM. Chronos representa los valores de una serie mediante una discretización que permite emplear arquitecturas derivadas de modelos de lenguaje para producir distribuciones de pronóstico [18]. TimesFM utiliza una arquitectura basada en Transformers con procesamiento por segmentos y fue preentrenado sobre grandes volúmenes de series reales y sintéticas [19]. Ambos constituyen modelos desarrollados por terceros y sus pesos preentrenados no fueron generados como parte del trabajo.

La principal ventaja de estos modelos es que permiten obtener una referencia sin entrenar una red desde cero para cada variable o región. Esto resulta especialmente útil para comprobar si el conocimiento adquirido durante el preentrenamiento se transfiere a series de demanda eléctrica del SADI. Sin embargo, su utilización plantea limitaciones. Algunos modelos preentrenados procesan de forma nativa solo la historia de la variable objetivo, mientras que el problema tratado requiere aprovechar información meteorológica y calendaria. Además, los datos de preentrenamiento pueden no representar adecuadamente las particularidades del consumo argentino, su sensibilidad térmica ni las diferencias entre regiones.

Por este motivo, estos modelos se consideraron como una familia adicional de métodos y no como sustitutos directos de los modelos supervisados. La comparación debe realizarse sobre los mismos períodos y métricas, diferenciando los resultados obtenidos sin ajuste de aquellos que requieran adaptación.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura adoptó un esquema híbrido compuesto por Microsoft Fabric y un servidor local de CAMMESA. Fabric concentró la mayor parte del almacenamiento, procesamiento, experimentación y visualización, mientras que el entorno local atendió los procesos que requerían conectividad con sistemas internos.

Dentro de Fabric se utilizaron distintos tipos de elementos según la función requerida. Una base de datos KQL actuó como capa inicial o bronce para recibir información con un grado mínimo de elaboración. Las bases KQL están orientadas al análisis de datos temporales y pueden ser consultadas desde notebooks mediante Kusto Query Language [20]. El repositorio relacional central se implementó con un Data Warehouse [21], con el objetivo de alojar las capas plata y oro. Allí se almacenaron datos normalizados, integrados y preparados para el consumo analítico mediante tablas y vistas T-SQL. También se utilizó un Data Lakehouse [22], que se reservó principalmente para archivos auxiliares y para aquellos formatos que no requerían almacenamiento relacional.

Los notebooks de Fabric [9] proporcionaron los entornos de ejecución para Python, pandas y PySpark. También sirvieron como espacio para la experimentación con

Los notebooks de Fabric [9] proporcionaron los entornos de ejecución para Python, pandas y PySpark. También sirvieron como espacio para la experimentación con modelos y para la integración con MLflow. Por otra parte, se utilizaron *Pipelines* [23] para la orquestación entre notebooks, consultas y actividades de copia de datos.

La conexión con bases Oracle instaladas en la infraestructura de CAMMESA se realizó mediante una puerta de enlace de datos alojada en servidores de la empresa. Este componente permite que los servicios de Fabric accedan de manera controlada a fuentes locales sin exponer directamente las bases internas.

El servidor local ejecutó Dagster y las bibliotecas necesarias para comunicarse con PI System y Fabric. Allí se programaron activos encargados de consultar las series internas, procesarlas con pandas y NumPy, y persistir los resultados en el Warehouse mediante autenticación de Azure. El enfoque basado en activos de Dagster facilita describir dependencias y programar actualizaciones periódicas, manteniendo separados el código de acceso a fuentes locales y los servicios administrados en la nube [11, 12].

Esta distribución de responsabilidades respondió a restricciones tecnológicas existentes y a la conveniencia de utilizar la plataforma institucional de CAMMESA. Fabric aporta almacenamiento centralizado, capacidad de procesamiento y servicios integrados de ciencia de datos, mientras que el servidor local conserva el acceso a fuentes que no están disponibles desde la nube. El diseño específico de los flujos, las dependencias entre componentes y los mecanismos de ejecución se desarrollan en el Capítulo 3.

modelos y para la integración con MLflow. Por otra parte, se utilizaron Pipelines [23] para la orquestación entre notebooks, consultas y copias de datos.

La conexión con bases Oracle instaladas en la infraestructura de CAMMESA se realizó mediante una puerta de enlace de datos alojada en servidores de la empresa. Este componente permite que los servicios de Fabric accedan de manera controlada a fuentes locales sin exponer directamente las bases internas.

El servidor local ejecutó Dagster y las bibliotecas necesarias para comunicarse con PI System y Fabric. Allí se programaron activos encargados de consultar las series internas, procesarlas con pandas y NumPy, y persistir los resultados en el Warehouse mediante autenticación de Azure. El enfoque basado en activos de Dagster facilita describir dependencias y programar actualizaciones periódicas, manteniendo separados el código de acceso a fuentes locales y los servicios administrados en la nube [11, 12].

Esta distribución de responsabilidades respondió a restricciones tecnológicas existentes y a la conveniencia de utilizar la plataforma institucional de CAMMESA. Fabric aporta almacenamiento centralizado, capacidad de procesamiento y servicios integrados de ciencia de datos, mientras que el servidor local conserva el acceso a fuentes que no están disponibles desde la nube. El diseño específico de los flujos, las dependencias entre componentes y los mecanismos de ejecución se desarrollan en el Capítulo 3.

Capítulo 3

Diseño e implementación

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño y la implementación de la solución desarrollada para automatizar el pronóstico de la demanda eléctrica del SADI. En primer lugar, se presenta el pipeline implementado para obtener, validar, transformar y almacenar los datos de demanda y las variables meteorológicas utilizadas por los modelos. A continuación, se describen la arquitectura de los modelos, el procedimiento de entrenamiento y optimización, y los mecanismos empleados para generar y persistir las predicciones. Finalmente, se detalla la integración de estos componentes en el sistema implementado, junto con las decisiones adoptadas para garantizar la trazabilidad y la reproducibilidad de las ejecuciones.

3.1. Pipeline de datos

El sistema de pronóstico requiere integrar series eléctricas, meteorológicas y calendarias con diferentes resoluciones temporales, coberturas geográficas y mecanismos de acceso. Por este motivo, antes de abordar la construcción y evaluación de los modelos se diseñó un pipeline de datos que automatiza la extracción, el procesamiento, la validación y la persistencia de la información. El objetivo de esta etapa fue disponer de conjuntos de datos consistentes y trazables, adecuados tanto para el entrenamiento como para la ejecución periódica de pronósticos.

La solución se implementó sobre la arquitectura híbrida presentada en el capítulo 2. Los procesos que necesitan conectividad con sistemas internos de CAM-MESA se ejecutan en un servidor local mediante Dagster. El almacenamiento y las transformaciones posteriores se concentran en Microsoft Fabric, donde se utilizan una base de datos KQL para la recepción inicial de determinados datos, un Data Warehouse para las capas estructuradas y Pipelines y notebooks para la orquestación y el procesamiento. Esta separación evita exponer directamente las fuentes internas y, al mismo tiempo, centraliza en Fabric la información utilizada por los modelos.

El pipeline se organizó en tres flujos principales, que obtienen y transforman los siguientes grupos de variables:

1. Demanda eléctrica.
2. Datos meteorológicos reales.
3. Pronósticos meteorológicos.

La información calendaria se incorpora posteriormente mediante tablas de existentes en las bases de datos de CAMMESA, de modo que pueda combinarse con las series eléctricas y meteorológicas utilizando la fecha como clave temporal.

3.1.1. Criterios de diseño del pipeline

El diseño se basó en cuatro criterios. En primer lugar, se buscó reducir la intervención manual en la obtención y actualización de datos. Las tareas repetitivas se encapsularon en activos de Dagster, notebooks y actividades de Pipeline, según el entorno desde el cual debía accederse a cada fuente. En segundo lugar, se preservó la granularidad original durante las primeras etapas. La demanda se almacena inicialmente con resolución de diez minutos y los datos meteorológicos conservan las resoluciones horaria o diaria provistas por cada fuente. Las agregaciones necesarias para el modelado se realizan en capas posteriores.

En tercer lugar, se incorporaron controles de calidad antes de generar las variables de entrenamiento. Estos controles abarcan la completitud temporal, la coherencia entre la demanda nacional y la suma regional, la consistencia de la partición de la provincia de Buenos Aires y la identificación de valores anómalos en las series horarias. Finalmente, se separaron los datos originales de los valores corregidos. Esta decisión permite conservar trazabilidad sobre las transformaciones y distinguir los registros que requirieron tratamiento.

La persistencia se estructuró mediante capas. La capa 1 recibe datos con un grado mínimo de elaboración y conserva una representación cercana a la fuente. La capa 2 contiene información validada, tipificada e integrada. Sobre estas tablas se construyen vistas y conjuntos derivados orientados al consumo analítico y al modelado. Esta organización evita aplicar transformaciones irreversibles durante la ingesta y facilita repetir los procesos cuando se modifican las reglas de limpieza.

3.1.2. Ingesta de demanda desde el SOTR

La demanda eléctrica se obtiene desde PI System mediante PIconnect. Debido a que esta fuente solo es accesible desde la red interna, la extracción se ejecuta en la infraestructura local. El proceso se implementó como un activo de Dagster que consulta valores interpolados con un paso de diez minutos, calcula la demanda por región eléctrica y escribe el resultado en el Data Warehouse de Fabric.

El cálculo regional combina generación e intercambios medidos en el SOTR. Para la partición en regiones del SADI se utilizó la definición implementada por CAMMESA, que se presenta en la figura 3.1 y son las siguientes:

- GBA: Gran Buenos Aires.
- CEN: provincias de Córdoba y San Luis.
- LIT: provincias de Santa Fe y Entre Ríos.
- CUY: provincias de Mendoza y San Juan.
- NEA: provincias de Corrientes, Misiones, Chaco y Formosa.
- NOA: provincias de Salta, Jujuy, Catamarca, La Rioja, Tucumán y Santiago del Estero.
- COM: provincias de Rio Negro, Neuquén y La Pampa.

Bibliografía

- [1] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: [10.48550 / arXiv.2509.19374](https://doi.org/10.48550/arXiv.2509.19374). arXiv: [2509.19374](https://arxiv.org/abs/2509.19374) [eess.SP]. URL: <https://arxiv.org/abs/2509.19374>.
- [2] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: [10.1016 / j. aei. 2026. 104419](https://doi.org/10.1016/j.aei.2026.104419). URL: <https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/>.
- [3] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: [10.3390/en13061407](https://doi.org/10.3390/en13061407). URL: <https://doi.org/10.3390/en13061407>.
- [4] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: [10.3390/en16217444](https://doi.org/10.3390/en16217444). URL: <https://doi.org/10.3390/en16217444>.
- [5] Boris N. Oreshkin et al. «N-BEATS Neural Network for Mid-Term Electricity Load Forecasting». En: *Applied Energy* 293 (2021), pág. 116918. DOI: [10.1016/j.apenergy.2021.116918](https://doi.org/10.1016/j.apenergy.2021.116918).
- [6] Cristian Challu et al. «N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6. 2023, págs. 6989-6997. DOI: [10.1609 / aaai.v37i6. 25854](https://doi.org/10.1609/aaai.v37i6.25854). URL: <https://doi.org/10.1609/aaai.v37i6.25854>.
- [7] Yuqi Nie et al. «A Time Series Is Worth 64 Words: Long-Term Forecasting with Transformers». En: *International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [8] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: [10.1109 / ACCESS.2025.3648056](https://doi.org/10.1109/ACCESS.2025.3648056).
- [9] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks> (visitado 12-09-2026).
- [10] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: <https://microsoftlearning.github.io/mslearn-fabric/> (visitado 12-09-2026).
- [11] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: <https://docs.dagster.io/> (visitado 12-09-2026).
- [12] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: <https://docs.dagster.io/api/dagster/assets> (visitado 12-09-2026).
- [13] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: <https://piconnect.readthedocs.io/en/main/> (visitado 12-09-2026).
- [14] SMN. *Datos Abiertos SMN*. 2026. URL: <https://www.smn.gob.ar/descarga-de-datos> (visitado 13-09-2026).

- PBA: provincia de Buenos Aires. Es importante mencionar que, para el pronóstico de demanda, esta región se divide en norte (PBN) y sur (PBS). Esto se debe a que presentan patrones de consumo distintos, en primer lugar por la variación de condiciones climáticas producto de la gran extensión territorial y, en segundo lugar, por la características de los usuarios (el norte está notablemente más industrializado que el sur).
- PAT: provincias de Chubut, Santa Cruz y Tierra del Fuego.




FIGURA 3.1. Regiones eléctricas del SADI según definición utilizada por CAMMESA.

El SOTR provee medidores de demanda por regiones, pero no son aptos para el pronóstico de demanda debido a que no incluyen las pérdidas que se producen en las líneas eléctricas que vinculan las regiones. Por este motivo, fue necesario desarrollar un algoritmo que obtenga los valores de generación e intercambios de cada región y, realizando la sumatoria correspondiente, calcule la demanda. Por otra parte, se hizo una repartición de las pérdidas entre corredores, asignando la mitad a cada una de las regiones asociadas al vínculo.

Para expresarlo de forma matemática, sea G_r la generación de la región r , $\mathcal{N}_r$ el conjunto de regiones vinculadas y $F_{r \rightarrow j}$ y $F_{j \rightarrow r}$ las mediciones del intercambio en ambos extremos del corredor. La demanda regional se calcula haciendo:

$$D_r = G_r - \sum_{j \in \mathcal{N}_r} \frac{F_{r \rightarrow j} - F_{j \rightarrow r}}{2} \quad (3.1)$$

donde los intercambios son positivos cuando representan una exportación desde la región r . La semidiferencia entre las mediciones de ambos extremos permite repartir las pérdidas del corredor en partes iguales entre las regiones vinculadas.

La figura 3.2, tomada del SOTR, muestra el estado de generación e intercambio entre algunas regiones para un instante determinado.




FIGURA 3.2. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado.

Si utilizamos la fórmula anterior para calcular la demanda corregida por pérdidas para LIT, podemos hacer (el intercambio con Uruguay es igual en ambos extremos, ya que es un vínculo interno de la central Salto Grande):

$$D_{LIT} = 1624 - \left[\frac{-1096 - 1132}{2} + \frac{-80 - 88}{2} + \frac{142 - (-142)}{2} + \frac{1176 - (-1161)}{2} \right] \quad (3.2)$$

Resolviendo,

$$D_{LIT} = 1624 - (-1114 - 84 + 142 + 1168,5) = 1511,5 \text{ MW} \quad (3.3)$$

Notar que el valor obtenido de 1511,5 MW difiere de los 1482 MW de demanda sin considerar las pérdidas. En caso de no aplicar esta corrección, la demanda nacional agregada presentaría un error considerable introducido en los datos de entrenamiento de los modelos.

La implementación de esta corrección requirió definir todos los intercambios entre regiones y consultar una cantidad de medidores del SOTR sustancialmente mayor que si se hubiesen podido utilizar los medidores de demanda existentes.

Por otra parte, se aplican ajustes específicos para representar de forma consistente la demanda utilizada en la programación. Entre ellos se encuentran la exclusión de consumos asociados con centrales de bombeo, que se ponen en servicio para almacenamiento de energía, y la demanda de grandes acerías que informan su consumo previsto.

El proceso genera también variables de control. La demanda MEM calculada como suma de las regiones se compara con un medidor nacional de referencia. Se almacenan la diferencia absoluta y porcentual entre ambos valores. Para PBA se conservan la demanda original, los valores directos de PBN y PBS y las diferencias asociadas con la partición. Asimismo, se calcula la suma de los intercambios internos, que debe permanecer próxima a cero porque las exportaciones de una región son importaciones de otra. Estos campos no constituyen objetivos de pronóstico, pero permiten verificar la coherencia del cálculo y detectar cambios en los medidores o en las reglas de negocio.

La salida se persiste en la tabla `DEMANDA.DEMANDA_REGIONES_10M`. Su clave está formada por fecha, hora e intervalo. Las columnas de demanda se almacenan en formato ancho, con una columna por región, junto con MEM y las variables de control. Esta tabla actúa como fuente para los procesos que generan resoluciones horarias y diarias.

La tarea de Dagster que ejecuta este proceso está programada cada 20 minutos, con el objetivo de mantener la tabla lo suficientemente actualizada para cualquier otro uso.

3.1.3. Transformación de demanda de diez minutos a resolución horaria

La transformación horaria se implementó en un notebook de Fabric. El proceso lee la tabla de diez minutos, controla la disponibilidad de nuevos registros y procesa únicamente el intervalo necesario. Para admitir correcciones tardías en la fuente se vuelve a considerar el día anterior al último registro persistido. Si no existen horas nuevas completas, el notebook finaliza sin efectuar escrituras.

Una hora se considera completa cuando contiene los seis intervalos esperados de diez minutos. Este criterio evita calcular promedios horarios a partir de observaciones parciales. Luego, la tabla en formato ancho se transforma a formato largo, con una fila por fecha, hora y región. La transformación facilita aplicar reglas homogéneas de limpieza y vincular cada observación con la dimensión de regiones.

La limpieza se realiza en dos etapas. Primero se identifican valores extremos por región mediante el rango intercuartílico. Los límites se establecen a partir del primer y tercer cuartil y un factor de tres veces el rango intercuartílico. Los valores que quedan fuera de esos límites se reemplazan temporalmente por valores nulos y se estiman mediante interpolación lineal en el eje temporal. En la figura 3.3 puede verse un caso de corrección de valores extremos.

El método de eliminación de outliers es eficiente para fallas de medición, donde se alcanzan valores extremos por instantes cortos de tiempos. Las correcciones

más desafiantes son aquellas que corresponden a fallas eléctricas reales del sistema eléctrico (por ejemplo, la desconexión intempestiva de una línea de transmisión que hace caer la demanda abruptamente). En estos casos, es deseable poder inferir el valor de demanda si no hubiese existido la falla, ya que, a los fines del entrenamiento de un modelo predictivo, esto representa un error que debe ser desestimado.

Por este motivo, en la segunda etapa se detectan escalones abruptos dentro de un mismo día. Un cambio se considera candidato a corrección cuando supera simultáneamente un umbral relativo del 7% y un umbral absoluto de 100 MW. Estos valores fueron determinados en base a la recomendación de los especialistas de CAMMESA en combinación con el análisis de amplios rangos temporales. La detección y corrección se ejecuta de manera iterativa, con un máximo de diez iteraciones. Los puntos identificados se interpolan y, cuando la interpolación no resulta posible en los extremos, se completan mediante propagación hacia adelante o hacia atrás. En la figura 3.4 puede verse un caso de corrección de saltos bruscos.




FIGURA 3.3. Corrección de valores extremos.




FIGURA 3.4. Corrección de saltos bruscos.

Después de la limpieza se calcula el promedio de los seis registros de cada hora. Se conservan tanto el valor resultante como el promedio obtenido a partir de los

datos anteriores a la corrección. La columna `FLAG_CORREGIDO` indica si ambos valores difieren. De este modo, los modelos pueden utilizar la serie depurada sin perder la posibilidad de auditar qué observaciones fueron modificadas.

Cada registro se vincula con la dimensión regional mediante la clave `RGE_ID` y el período de vigencia correspondiente. La tabla final contiene `FECHA`, `HORA`, `RGE_ID`, `VALOR`, `FLAG_CORREGIDO` y `VALOR_ORIGINAL`. Antes de persistir, se verifica la existencia de la clave compuesta en el destino para evitar duplicados. Los registros nuevos se incorporan en `DEMANDA.DEMANDA_REGIONES_1H`.

A partir de la demanda horaria se obtienen variables diarias utilizadas como objetivos. La energía diaria se almacena por región en la tabla del esquema `DEMANDA` llamada `DEMANDA_REGIONES_DIARIA`. Las vistas del Warehouse suman los valores regionales para obtener la demanda del MEM y calculan las potencias máxima y mínima sobre los intervalos horarios definidos para cada variable. Esta derivación mantiene una fuente regional común para los objetivos nacionales y permite comprobar que el agregado del MEM sea consistente con sus componentes.

3.1.4. Ingesta y procesamiento de datos meteorológicos reales

El flujo meteorológico integra observaciones del Servicio Meteorológico Nacional y valores obtenidos de Open-Meteo. La primera etapa se ejecuta en el notebook `NB_METEO_L1`. Para el SMN se procesan los archivos de observaciones diarias y de datos horarios. Para Open-Meteo se realizan consultas por coordenadas asociadas con estaciones de referencia. El rango de fechas se recibe como parámetro y, cuando no se informa, el notebook utiliza el día anterior a la ejecución.

Los archivos descargados del SMN se conservan en un Lakehouse. Esta copia permite mantener el insumo original y volver a procesarlo si resulta necesario. Los datos interpretados se escriben en la base KQL `EH_PSYD`, utilizada como capa 1. Allí se almacenan, entre otras variables, temperatura, humedad relativa, presión, dirección y velocidad del viento para la resolución horaria, y temperaturas máxima y mínima para la resolución diaria. Las tablas de Open-Meteo incorporan además temperatura aparente, nubosidad, precipitación y radiación solar, según la resolución de cada conjunto.

La persistencia en KQL se realiza por lotes. Antes de insertar un período se eliminan los registros existentes para el mismo rango temporal. Esta estrategia permite repetir una ejecución sin conservar versiones duplicadas del mismo dato. Cuando el volumen serializado supera el tamaño previsto para una operación, la carga se divide en bloques. El resultado de esta etapa es una representación cercana a las fuentes, separada por proveedor y resolución.

La transferencia desde la capa 1 hacia la capa 2 se orquesta mediante el Pipeline `PPLN_METEO`, que se presenta en la figura 3.5. El pipeline ejecuta el notebook y consulta en el Warehouse las estaciones cuya vigencia se superpone con el período procesado. Esta validación evita incorporar estaciones que no correspondan al intervalo analizado y permite asociar cada nombre de estación con su identificador `EMET_ID`.




FIGURA 3.5. Pipeline de Fabric para la orquestación de datos meteorológicos.

Para los datos horarios del SMN, la actividad de copia filtra el rango de fechas, conserva las estaciones vigentes y construye la marca temporal `FECHA_HORA`. También ajusta la numeración horaria para compatibilizarla con la convención utilizada en CAMMESA. A partir de la temperatura, la humedad relativa y la velocidad del viento se calcula una temperatura aparente. Finalmente, las variables se redondean y tipifican antes de escribirlas en el esquema `METEO` del Warehouse.

La escritura de los datos meteorológicos utiliza claves temporales y de estación. Para los valores horarios, la combinación de `FECHA_HORA` y `EMET_ID` identifica cada observación. Las tablas diarias emplean la fecha y el identificador de estación. Esta estructura permite comparar proveedores para una misma ubicación, seleccionar estaciones representativas de cada región eléctrica y construir agregados diarios sin perder el origen del dato.

Bibliografía

- [1] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: [10.48550 / arXiv.2509.19374](https://doi.org/10.48550/arXiv.2509.19374). arXiv: [2509.19374](https://arxiv.org/abs/2509.19374) [eess.SP]. URL: <https://arxiv.org/abs/2509.19374>.
- [2] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: [10.1016 / j. aei. 2026. 104419](https://doi.org/10.1016/j.aei.2026.104419). URL: <https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/>.
- [3] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: [10.3390/en13061407](https://doi.org/10.3390/en13061407). URL: <https://doi.org/10.3390/en13061407>.
- [4] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: [10.3390/en16217444](https://doi.org/10.3390/en16217444). URL: <https://doi.org/10.3390/en16217444>.
- [5] Boris N. Oreshkin et al. «N-BEATS Neural Network for Mid-Term Electricity Load Forecasting». En: *Applied Energy* 293 (2021), pág. 116918. DOI: [10.1016/j.apenergy.2021.116918](https://doi.org/10.1016/j.apenergy.2021.116918).
- [6] Cristian Challu et al. «N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6. 2023, págs. 6989-6997. DOI: [10.1609 / aaai.v37i6.25854](https://doi.org/10.1609/aaai.v37i6.25854). URL: <https://doi.org/10.1609/aaai.v37i6.25854>.
- [7] Yuqi Nie et al. «A Time Series Is Worth 64 Words: Long-Term Forecasting with Transformers». En: *International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [8] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: [10.1109 / ACCESS.2025.3648056](https://doi.org/10.1109/ACCESS.2025.3648056).
- [9] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks> (visitado 12-09-2026).
- [10] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: <https://microsoftlearning.github.io/mslearn-fabric/> (visitado 12-09-2026).
- [11] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: <https://docs.dagster.io/> (visitado 12-09-2026).
- [12] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: <https://docs.dagster.io/api/dagster/assets> (visitado 12-09-2026).
- [13] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: <https://piconnect.readthedocs.io/en/main/> (visitado 12-09-2026).
- [14] SMN. *Datos Abiertos SMN*. 2026. URL: <https://www.smn.gob.ar/descarga-de-datos> (visitado 13-09-2026).

- [15] Open-Meteo. *Historical Weather API*. 2026. URL: <https://open-meteo.com/en/docs/historical-weather-api> (visitado 12-09-2026).
- [16] Open-Meteo. *Historical Forecast API*. 2026. URL: <https://open-meteo.com/en/docs/historical-forecast-api> (visitado 12-09-2026).
- [17] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: <https://weather.com/es-AR/ar/city/buenos-aires/today> (visitado 13-09-2026).
- [18] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: <https://openreview.net/forum?id=gerNCVqqtR>.
- [19] Abhimanyu Das et al. «A Decoder-Only Foundation Model for Time-Series Forecasting». En: *Proceedings of the 41st International Conference on Machine Learning*. Vol. 235. Proceedings of Machine Learning Research. PMLR, 2024, págs. 10148-10167. URL: <https://proceedings.mlr.press/v235/das24c.html>.
- [20] Microsoft. *Analyze data in a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with> (visitado 12-09-2026).
- [21] Microsoft. *Documentación de Data Warehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-warehouse/> (visitado 13-09-2026).
- [22] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview> (visitado 13-09-2026).
- [23] Microsoft. *Documentación de Pipeline*. 2026. URL: <https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview> (visitado 13-09-2026).

- [15] Open-Meteo. *Historical Weather API*. 2026. URL: <https://open-meteo.com/en/docs/historical-weather-api> (visitado 12-09-2026).
- [16] Open-Meteo. *Historical Forecast API*. 2026. URL: <https://open-meteo.com/en/docs/historical-forecast-api> (visitado 12-09-2026).
- [17] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: <https://weather.com/es-AR/ar/city/buenos-aires/today> (visitado 13-09-2026).
- [18] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: <https://openreview.net/forum?id=gerNCVqqtR>.
- [19] Abhimanyu Das et al. «A Decoder-Only Foundation Model for Time-Series Forecasting». En: *Proceedings of the 41st International Conference on Machine Learning*. Vol. 235. Proceedings of Machine Learning Research. PMLR, 2024, págs. 10148-10167. URL: <https://proceedings.mlr.press/v235/das24c.html>.
- [20] Microsoft. *Analyze data in a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with> (visitado 12-09-2026).
- [21] Microsoft. *Documentación de Data Warehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-warehouse/> (visitado 13-09-2026).
- [22] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview> (visitado 13-09-2026).
- [23] Microsoft. *Documentación de Pipeline*. 2026. URL: <https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview> (visitado 13-09-2026).