Draftable Comparison Export

This document is an exported comparison with limited functionality, generated by Draftable Desktop. To access full functionality, use Draftable's powerful comparison viewer in any of our products.

Left document:	TI_Paniagua_Daniel_V4.pdf
Right document:	TI_Paniagua_Daniel_V5.pdf

What is this document?

This is a comparison of two documents. The two documents are interleaved such that the left document is displayed on even pages and the right document is displayed on odd pages.

Is there a specific way I should view this file?

This document is intended to be viewed in Two Page Continuous mode (or sometimes called 'Two Page Scrolling'). It should open in this mode by default when using Adobe Acrobat and most popular PDF readers.

If the document opens in a different view, you can often change this in the settings. In Adobe Acrobat, go to **View > Page Display > Two Page Scrolling**

Why are there blank pages?

Blank pages are inserted to keep both documents as aligned as much as possible.

How do I read the changes?

Text deleted from the left document and, hence, not in right document is highlighted red. Text added to the right document and, hence, not in left document is highlighted green.

Tip for printing

When printing this document, we recommend printing double-sided and include this first page. This will result in the matching text being displayed on different pages and easily readable, much like a book.

For more information

Draftable offers powerful document comparison solutions for all use-cases. To view our products, please visit our website: draftable.com.

.UBAfiuba
FACULTAD DE INGENIERÍA

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

.UBAfiuba
FACULTAD DE INGENIERÍA

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. Demanda eléctrica y operación del sistema argentino 1
1.2. Contexto y motivación 2
1.3. Estado del arte 3
1.4. Objetivos y alcance 5

2. Introducción específica 7
2.1. Frameworks para procesamiento y modelado 7
2.2. Fuentes de datos para el pronóstico de demanda 8
2.3. Modelos fundacionales para series temporales 10
2.4. Infraestructura híbrida de datos y cómputo 10

3. Diseño e implementación 13
3.1. Pipeline de datos 13
3.1.1. Arquitectura y criterios de diseño 13
3.1.2. Flujo de demanda eléctrica 15
Cálculo de la demanda regional 15
Resolución horaria y control de calidad 18
3.1.3. Flujo de datos meteorológicos observados 20
Ingesta en capa 1 20
Transformación a capa 2 21
3.1.4. Flujo de pronósticos meteorológicos 22
Fuentes e ingesta en capa 1 22
Reconstrucción de la historia de pronósticos 23
Transformación a capa 2 y orquestación 23

Bibliografía 25

Índice general

Resumen I

1. Introducción general 1
1.1. Demanda eléctrica y operación del sistema argentino 1
1.2. Contexto y motivación 2
1.3. Estado del arte 3
1.4. Objetivos y alcance 5

2. Introducción específica 7
2.1. Frameworks para procesamiento y modelado 7
2.2. Fuentes de datos para el pronóstico de demanda 8
2.3. Modelos fundacionales para series temporales 10
2.4. Infraestructura híbrida de datos y cómputo 10

3. Diseño e implementación 13
3.1. Pipeline de datos 13
3.1.1. Arquitectura y criterios de diseño 13
3.1.2. Flujo de demanda eléctrica 15
Cálculo de la demanda regional 16
Resolución horaria y control de calidad 19
3.1.3. Flujo de datos meteorológicos observados 21
Ingesta en capa 1 21
Transformación a capa 2 21
3.1.4. Flujo de pronósticos meteorológicos 22
Fuentes e ingesta en capa 1 23
Reconstrucción de la historia de pronósticos 23
Transformación a capa 2 y orquestación 24
3.2. Desarrollo de modelos 25
3.2.1. Selección del modelo de referencia 26
3.2.2. Modelos de aprendizaje profundo y fundacionales 28
3.3. Integración y puesta en producción 30
3.3.1. Arquitectura de ejecución 30
3.3.2. Generación diaria de pronósticos 31
3.3.3. Reentrenamiento y registro de modelos 31
3.3.4. Monitoreo del desempeño 31

4. Ensayos y resultados 33

A. Modelo de datos del warehouse 35
A.1. Relaciones entre esquemas 35
A.2. Esquema DEMANDA 36
A.3. Esquema METEO 37
A.4. Esquema PRONOS 39

Bibliografía **41**

Índice de figuras

3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia. 14
3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA. 16
3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado. 17
3.4. Corrección de valores extremos. 19
3.5. Corrección de saltos bruscos. 20
3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados. 21
3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos. 24

Índice de figuras

3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia. 14
3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA. 17
3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado. 18
3.4. Corrección de valores extremos. 20
3.5. Corrección de saltos bruscos. 20
3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados. 22
3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos. 25
3.8. Esquema de validación con origen móvil: reentrenamiento en la fecha R y pronóstico de una fecha de cálculo D hasta el reentrenamiento siguiente R'. 26
3.9. Arquitectura del sistema de pronóstico en producción. 30

A.1. Relaciones entre las tablas principales de los esquemas DEMANDA, METEO y PRONOS. 35

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica. 5

2.1. Fuentes de datos utilizadas en el trabajo. 9

3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline. . . 22

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica. 5

2.1. Fuentes de datos utilizadas en el trabajo. 9

3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline. . . 23
3.2. Grupos de covariables evaluados en la selección del modelo de referencia. 27
3.3. Modelos de aprendizaje profundo y fundacionales implementados. 28

A.1. Tablas y vistas del esquema DEMANDA. 36
A.2. Columnas de las tablas del esquema DEMANDA. 37
A.3. Tablas y vistas del esquema METEO. 38
A.4. Variables meteorológicas horarias. 39
A.5. Variables meteorológicas diarias. 39
A.6. Tablas y vistas del esquema PRONOS. 40
A.7. Columnas propias de las tablas y vistas del esquema PRONOS. . . 40

Dedicado a... [OPCIONAL]

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI).

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI) [1].

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA), en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA) [2, 3], en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas [1]. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas [2]. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño [3]. Aquila et al. revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico [4]. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo [4] desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. [5] estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. [6] aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño. Aquila et al. [7] revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles, como XGBoost, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En el trabajo, XGBoost se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar horizontes de múltiples pasos y representar patrones en distintas escalas. Oreshkin et al. aplicaron N-BEATS al pronóstico de demanda eléctrica de mediano plazo sobre 35 series nacionales europeas y obtuvieron mejoras frente a métodos estadísticos, de aprendizaje automático e híbridos [5]. El resultado aporta evidencia específica sobre la utilidad de las arquitecturas residuales para modelar tendencias, estacionalidades y fluctuaciones de la demanda, aunque trabaja con series mensuales y un horizonte diferente del considerado en este trabajo.

Otras arquitecturas, entre ellas N-HiTS y modelos basados en Transformers como PatchTST, extienden esta línea mediante mecanismos de procesamiento multiescala y segmentación temporal [6, 7]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos y aprovechar ventanas históricas extensas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se preentrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo [8]. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles de decisión, como XGBoost y LightGBM, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En este trabajo, un modelo basado en árboles se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar pronósticos de múltiples pasos e incorporar covariables conocidas a futuro, como la información calendaria o los pronósticos meteorológicos. Lim et al. [8] propusieron el Temporal Fusion Transformer (TFT), que combina capas recurrentes con mecanismos de atención y de selección de variables, y lo evaluaron, entre otros conjuntos, sobre series de consumo eléctrico. Su diseño permite distinguir la información histórica, la conocida a futuro y la estática, y estimar la relevancia de cada variable en el pronóstico.

En paralelo, otras arquitecturas, como TiDE y TSMixer, mostraron que modelos basados en perceptrones multicapa pueden alcanzar un desempeño competitivo frente a los basados en Transformers, con un costo de entrenamiento menor [9, 10]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos con covariables exógenas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se preentrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. [11] compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [1]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [2]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [3]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Oreshkin et al. [5]	N-BEATS	Demanda mensual de 35 países europeos.	Mejora de la precisión y del sesgo frente a diez métodos.
Meyer et al. [8]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del sistema como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendaria necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando un modelo XGBoost como referencia.
- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [4]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [5]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [6]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Lim et al. [8]	Temporal Fusion Transformer	Series de consumo eléctrico y de otros dominios, con covariables conocidas a futuro.	Pronóstico de múltiples pasos con estimación de la relevancia de las variables.
Meyer et al. [11]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del sistema como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendaria necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando como referencia un modelo basado en árboles de decisión.

- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.
- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, bibliotecas, fuentes de datos e infraestructura de cómputo utilizadas como soporte del trabajo. El propósito es describir los componentes de terceros y el entorno tecnológico utilizados.

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Aquellas actividades que requerían acceso directo a sistemas internos o ejecución desde la red local se alojaron en una instalación de Dagster ejecutada en infraestructura propia de la empresa.

2.1. Frameworks para procesamiento y modelado

El lenguaje principal utilizado fue Python, debido a su amplia adopción en ciencia de datos y a la disponibilidad de bibliotecas para aprendizaje automático, series temporales y acceso a fuentes heterogéneas. Su utilización permitió mantener una base tecnológica común entre los notebooks ejecutados en Fabric y los procesos alojados en el servidor local.

Para la preparación y análisis de datos se utilizó principalmente la biblioteca pandas, que proporciona estructuras tabulares y operaciones para selección, agrupamiento y transformación de datos. Esta herramienta resulta apropiada para el tratamiento de series temporales de demanda y meteorología, especialmente en las etapas que pueden resolverse en memoria sobre un único nodo.

Cuando el volumen de datos o la integración con los servicios de Fabric lo requirieron, se empleó PySpark. Los notebooks de Fabric admiten procesamiento distribuido mediante Apache Spark y permiten combinar DataFrames de Spark con pandas. Esta alternativa proporciona escalabilidad para el tratamiento de datos históricos con resolución horaria o inferior, sin abandonar el ecosistema Python utilizado en el resto de la solución [9].

Para los modelos de referencia se previó el uso de regresiones lineales y algoritmos basados en árboles, particularmente XGBoost. Las regresiones lineales ofrecen una línea de base simple e interpretable, útil para verificar que modelos más complejos aporten una mejora real. XGBoost, por su parte, permite representar relaciones no lineales e interacciones entre variables históricas, meteorológicas y calendarias. La interfaz compatible con scikit-learn facilita la preparación de experimentos, el ajuste de hiperparámetros y el cálculo homogéneo de métricas.

Los modelos neuronales abarcan redes recurrentes, como LSTM y GRU, y arquitecturas más recientes diseñadas para el pronóstico de múltiples pasos. Para su

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, bibliotecas, fuentes de datos e infraestructura de cómputo utilizadas como soporte del trabajo. El propósito es describir los componentes de terceros y el entorno tecnológico utilizados.

2.1. Frameworks para procesamiento y modelado

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Aquellas actividades que requerían acceso directo a sistemas internos o ejecución desde la red local se alojaron en una instalación de Dagster ejecutada en infraestructura propia de la empresa.

El lenguaje principal utilizado fue Python, debido a su amplia adopción en ciencia de datos y a la disponibilidad de bibliotecas para aprendizaje automático, series temporales y acceso a fuentes heterogéneas. Su utilización permitió mantener una base tecnológica común entre los notebooks ejecutados en Fabric y los procesos alojados en el servidor local.

Para la preparación y análisis de datos se utilizó principalmente la biblioteca pandas, que proporciona estructuras tabulares y operaciones para selección, agrupamiento y transformación de datos. Esta herramienta resulta apropiada para el tratamiento de series temporales de demanda y meteorología, especialmente en las etapas que pueden resolverse en memoria sobre un único nodo.

Cuando el volumen de datos o la integración con los servicios de Fabric lo requirieron, se empleó PySpark. Los notebooks de Fabric admiten procesamiento distribuido mediante Apache Spark y permiten combinar DataFrames de Spark con pandas. Esta alternativa proporciona escalabilidad para el tratamiento de datos históricos con resolución horaria o inferior, sin abandonar el ecosistema Python utilizado en el resto de la solución [12].

Para los modelos de referencia se utilizaron regresiones lineales y algoritmos basados en árboles de decisión: Random Forest, XGBoost y LightGBM. Las regresiones lineales ofrecen una línea de base simple e interpretable, útil para verificar que modelos más complejos aporten una mejora real. Los algoritmos basados en árboles, por su parte, permiten representar relaciones no lineales e interacciones entre variables históricas, meteorológicas y calendarias. La interfaz compatible con scikit-learn facilita la preparación de experimentos y el cálculo homogéneo de métricas.

implementación se consideraron bibliotecas especializadas en series temporales que utilizan PyTorch como motor de entrenamiento. Este enfoque permite evaluar familias de modelos con una interfaz común y reducir diferencias de implementación que podrían afectar la comparación.

El seguimiento de experimentos y modelos se apoyó en MLflow, integrado en las capacidades de ciencia de datos de Fabric. MLflow permite registrar parámetros, métricas y artefactos asociados con cada ejecución, además de conservar versiones de los modelos. Su elección respondió a la necesidad de comparar alternativas de manera reproducible y mantener trazabilidad entre los datos utilizados, la configuración de entrenamiento y los resultados obtenidos. Fabric incorpora esta herramienta dentro de sus notebooks y experiencias de ciencia de datos [10].

En el entorno local se utilizó Dagster como orquestador de datos. Su modelo basado en activos permite representar tablas, archivos y otros productos persistentes como elementos con dependencias explícitas, historial de ejecuciones y políticas de actualización [11, 12]. Esta característica resulta adecuada para los procesos que obtienen información desde sistemas internos y posteriormente la escriben en Fabric. NumPy y pandas se utilizaron también en este entorno, junto con bibliotecas de Azure para autenticación y acceso a servicios en la nube.

Para la lectura de series operativas se utilizó PIconnect, conector de Python para PI System y PI Asset Framework. La biblioteca permite consultar valores registrados o interpolados mediante el SDK de PI, por lo que posibilita acceder desde el servidor local a la información histórica del Sistema Operativo en Tiempo Real (SOTR) de CAMMESA [13].

Finalmente, Power BI se empleó como herramienta de visualización, tanto para los pronósticos como para las métricas de desempeño. Su integración con Fabric permite construir informes sobre los datos centralizados sin incorporar una capa adicional de exportación.

2.2. Fuentes de datos para el pronóstico de demanda

Los conjuntos de datos utilizados fueron construidos a partir de fuentes internas de CAMMESA y servicios meteorológicos externos. No se trató, por lo tanto, de un dataset público para aprendizaje automático, sino de información operativa que debió integrarse con distintas resoluciones, coberturas geográficas y condiciones de acceso.

La variable principal provino de registros de demanda eléctrica del sistema SOTR, almacenados en PI System. Las series poseen una resolución original de diez minutos y representan la demanda del SADI y de sus regiones eléctricas. A partir de estas series se obtienen las variables diarias que actúan como objetivos de pronóstico: energía y potencias mínima y máxima.

También se incorporó información calendaria, como día de la semana, feriados y otras clasificaciones utilizadas habitualmente por los especialistas. Estas variables permiten representar modificaciones del consumo asociadas con la actividad residencial, comercial e industrial.

La información meteorológica se obtuvo de tres fuentes. La primera correspondió al Servicio Meteorológico Nacional (SMN), cuyos datos se consideraron prioritarios por su carácter oficial. Se utilizaron archivos de observaciones diarias y

Los modelos neuronales abarcan redes recurrentes, como LSTM y GRU, y arquitecturas más recientes diseñadas para el pronóstico de múltiples pasos. Tanto estos modelos como los de referencia se implementaron con Darts, una biblioteca especializada en series temporales que integra algoritmos clásicos y redes neuronales entrenadas con PyTorch [13]. Este enfoque permite evaluar familias de modelos con una interfaz común y reducir diferencias de implementación que podrían afectar la comparación.

El seguimiento de experimentos y modelos se apoyó en MLflow, integrado en las capacidades de ciencia de datos de Fabric. MLflow permite registrar parámetros, métricas y artefactos asociados con cada ejecución, además de conservar versiones de los modelos. Su elección respondió a la necesidad de comparar alternativas de manera reproducible y mantener trazabilidad entre los datos utilizados, la configuración de entrenamiento y los resultados obtenidos. Fabric incorpora esta herramienta dentro de sus notebooks y experiencias de ciencia de datos [14].

En el entorno local se utilizó Dagster como orquestador de datos. Su modelo basado en activos permite representar tablas, archivos y otros productos persistentes como elementos con dependencias explícitas, historial de ejecuciones y políticas de actualización [15, 16]. Esta característica resulta adecuada para los procesos que obtienen información desde sistemas internos y posteriormente la escriben en Fabric. NumPy y pandas se utilizaron también en este entorno, junto con bibliotecas de Azure para autenticación y acceso a servicios en la nube.

Para la lectura de series operativas se utilizó PIconnect, conector de Python para PI System y PI Asset Framework. La biblioteca permite consultar valores registrados o interpolados mediante el SDK de PI, por lo que posibilita acceder desde el servidor local a la información histórica del Sistema Operativo en Tiempo Real (SOTR) de CAMMESA [17].

Finalmente, Power BI se empleó como herramienta de visualización, tanto para los pronósticos como para las métricas de desempeño. Su integración con Fabric permite construir informes sobre los datos centralizados sin incorporar una capa adicional de exportación.

2.2. Fuentes de datos para el pronóstico de demanda

Los conjuntos de datos utilizados fueron construidos a partir de fuentes internas de CAMMESA y servicios meteorológicos externos. No se trató, por lo tanto, de un dataset público para aprendizaje automático, sino de información operativa que debió integrarse con distintas resoluciones, coberturas geográficas y condiciones de acceso.

La variable principal provino de registros de demanda eléctrica del sistema SOTR, almacenados en PI System. Las series poseen una resolución original de diez minutos y representan la demanda del SADI y de sus regiones eléctricas. A partir de estas series se obtienen las variables diarias que actúan como objetivos de pronóstico: energía y potencias mínima y máxima.

También se incorporó información calendaria, como día de la semana, feriados y otras clasificaciones utilizadas habitualmente por los especialistas. Estas variables permiten representar modificaciones del consumo asociadas con la actividad residencial, comercial e industrial.

datos horarios publicados en formato de texto [14]. Debido a restricciones de acceso desde direcciones IP externas al país, las descargas automáticas se realizan desde el servidor local y los archivos se almacenan en un Lakehouse de Fabric para su posterior lectura. Los registros incluyen, entre otras variables, temperatura, humedad relativa, presión y viento. La desventaja que presentan los datos de pronóstico del SMN es que su horizonte máximo es de siete días, incluyendo el día en curso.

La segunda fuente fue Open-Meteo, utilizada para obtener datos históricos y pronósticos meteorológicos mediante interfaces de programación (API). Tiene múltiples variables disponibles, como temperatura, humedad, presión, viento, nubosidad, precipitación, radiación solar y temperatura aparente con resolución horaria o agregación diaria. La posibilidad de consultas por coordenadas facilita asociar las variables con puntos representativos de las regiones eléctricas. Para los pronósticos se seleccionaron algunos de los modelos disponibles, según el horizonte de cálculo y disponibilidad geográfica [15, 16].

La tercera fuente de pronósticos corresponde a The Weather Channel [17]. Su inclusión permite disponer de una referencia meteorológica adicional, que además es habitualmente consultada por el área de Programación Semanal y Diaria de CAMMESA. Esta fuente presenta un horizonte máximo de pronóstico de 15 días, que se ajusta al requerimiento para predicción de demanda.

La tabla 2.1 resume las fuentes consideradas.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	**Contenido principal**	**Resolución y cobertura**	**Condición de uso**
SOTR PI System	Demanda eléctrica del SADI y sus regiones.	Series de diez minutos, con cobertura nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, fines de semana, feriados y clasificaciones especiales.	Información con resolución diaria.	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios de estaciones argentinas.	Datos abiertos oficiales con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios consultados por coordenadas geográficas.	Datos sujetos a las condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Datos horarios y diarios para ubicaciones seleccionadas.	Servicio de terceros para uso institucional.

La información meteorológica se obtuvo de tres fuentes. La primera correspondió al Servicio Meteorológico Nacional (SMN), cuyos datos se consideraron prioritarios por su carácter oficial. Se utilizaron archivos de observaciones diarias y datos horarios publicados en formato de texto [18]. Debido a restricciones de acceso desde direcciones IP externas al país, las descargas automáticas se realizan desde el servidor local y los archivos se almacenan en un Lakehouse de Fabric para su posterior lectura. Los registros incluyen, entre otras variables, temperatura, humedad relativa, presión y viento. La desventaja que presentan los datos de pronóstico del SMN es que su horizonte máximo es de siete días, incluyendo el día en curso.

La segunda fuente fue Open-Meteo, utilizada para obtener datos históricos y pronósticos meteorológicos mediante interfaces de programación (API). Tiene múltiples variables disponibles, como temperatura, humedad, presión, viento, nubosidad, precipitación, radiación solar y temperatura aparente con resolución horaria o agregación diaria. La posibilidad de consultas por coordenadas facilita asociar las variables con puntos representativos de las regiones eléctricas. Para los pronósticos se seleccionaron algunos de los modelos disponibles, según el horizonte de cálculo y disponibilidad geográfica [19, 20].

La tercera fuente de pronósticos corresponde a The Weather Channel [21]. Su inclusión permite disponer de una referencia meteorológica adicional, que además es habitualmente consultada por el área de Programación Semanal y Diaria de CAMMESA. Esta fuente presenta un horizonte máximo de pronóstico de 15 días, que se ajusta al requerimiento para predicción de demanda.

La tabla 2.1 resume las fuentes consideradas.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	**Contenido principal**	**Resolución y cobertura**	**Condición de uso**
SOTR PI System	Demanda eléctrica del SADI y sus regiones.	Series de diez minutos, con cobertura nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, fines de semana, feriados y clasificaciones especiales.	Información con resolución diaria.	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios de estaciones argentinas.	Datos abiertos oficiales con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios consultados por coordenadas geográficas.	Datos sujetos a las condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Datos horarios y diarios para ubicaciones seleccionadas.	Servicio de terceros para uso institucional.

2.3. Modelos fundacionales para series temporales

Además de los modelos entrenados específicamente con datos del SADI, se consideró la incorporación de modelos fundacionales para series temporales. Estos modelos se preentrenan sobre colecciones amplias y heterogéneas de series, con el objetivo de aprender patrones generales de tendencia, estacionalidad y dependencia temporal. Luego pueden aplicarse a nuevas series sin reentrenamiento, modalidad conocida como zero-shot, o adaptarse mediante procedimientos de ajuste.

Entre las alternativas consideradas se encuentran Chronos y TimesFM. Chronos representa los valores de una serie mediante una discretización que permite emplear arquitecturas derivadas de modelos de lenguaje para producir distribuciones de pronóstico [18]. TimesFM utiliza una arquitectura basada en Transformers con procesamiento por segmentos y fue preentrenado sobre grandes volúmenes de series reales y sintéticas [19]. Ambos constituyen modelos desarrollados por terceros y sus pesos preentrenados no fueron generados como parte del trabajo.

La principal ventaja de estos modelos es que permiten obtener una referencia sin entrenar una red desde cero para cada variable o región. Esto resulta especialmente útil para comprobar si el conocimiento adquirido durante el preentrenamiento se transfiere a series de demanda eléctrica del SADI. Sin embargo, su utilización plantea limitaciones. Algunos modelos preentrenados procesan de forma nativa solo la historia de la variable objetivo, mientras que el problema tratado requiere aprovechar información meteorológica y calendaria. Además, los datos de preentrenamiento pueden no representar adecuadamente las particularidades del consumo argentino, su sensibilidad térmica ni las diferencias entre regiones.

Por este motivo, estos modelos se consideraron como una familia adicional de métodos y no como sustitutos directos de los modelos supervisados. La comparación debe realizarse sobre los mismos períodos y métricas, diferenciando los resultados obtenidos sin ajuste de aquellos que requieran adaptación.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura adoptó un esquema híbrido compuesto por Microsoft Fabric y un servidor local de CAMMESA. Fabric concentró la mayor parte del almacenamiento, procesamiento, experimentación y visualización, mientras que el entorno local atendió los procesos que requerían conectividad con sistemas internos.

Dentro de Fabric se utilizaron distintos tipos de elementos según la función requerida. Una base de datos KQL actuó como capa inicial o bronce para recibir información con un grado mínimo de elaboración. Las bases KQL están orientadas al análisis de datos temporales y pueden ser consultadas desde notebooks mediante Kusto Query Language [20]. El repositorio relacional central se implementó con un Data Warehouse [21], con el objetivo de alojar las capas plata y oro. Allí se almacenaron datos normalizados, integrados y preparados para el consumo analítico mediante tablas y vistas T-SQL. También se utilizó un Data Lakehouse [22], que se reservó principalmente para archivos auxiliares y para aquellos formatos que no requerían almacenamiento relacional.

Los notebooks de Fabric [9] proporcionaron los entornos de ejecución para Python, pandas y PySpark. También sirvieron como espacio para la experimentación con

2.3. Modelos fundacionales para series temporales

Además de los modelos entrenados específicamente con datos del SADI, se consideró la incorporación de modelos fundacionales para series temporales. Estos modelos se preentrenan sobre colecciones amplias y heterogéneas de series, con el objetivo de aprender patrones generales de tendencia, estacionalidad y dependencia temporal. Luego pueden aplicarse a nuevas series sin reentrenamiento, modalidad conocida como zero-shot, o adaptarse mediante procedimientos de ajuste.

Se utilizó Chronos-2, la versión más reciente de la familia Chronos. La primera versión representa los valores de una serie mediante una discretización que permite emplear arquitecturas derivadas de modelos de lenguaje para producir distribuciones de pronóstico [22]. Chronos-2, en cambio, incorpora un mecanismo de atención grupal que procesa en forma conjunta la serie objetivo y sus covariables pasadas y futuras, y fue preentrenado sobre grandes volúmenes de series reales y sintéticas [23]. Se trata de un modelo desarrollado por terceros, cuyos pesos preentrenados no fueron generados como parte del trabajo.

La principal ventaja de estos modelos es que permiten obtener una referencia sin entrenar una red desde cero para cada variable o región. Esto resulta especialmente útil para comprobar si el conocimiento adquirido durante el preentrenamiento se transfiere a series de demanda eléctrica del SADI. Sin embargo, su utilización plantea limitaciones. Algunos modelos preentrenados procesan de forma nativa solo la historia de la variable objetivo, mientras que el problema tratado requiere aprovechar información meteorológica y calendaria. Además, los datos de preentrenamiento pueden no representar adecuadamente las particularidades del consumo argentino, su sensibilidad térmica ni las diferencias entre regiones.

Por este motivo, estos modelos se consideraron como una familia adicional de métodos y no como sustitutos directos de los modelos supervisados. La comparación debe realizarse sobre los mismos períodos y métricas, diferenciando los resultados obtenidos sin ajuste de aquellos que requieran adaptación.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura adoptó un esquema híbrido compuesto por Microsoft Fabric y un servidor local de CAMMESA. Fabric concentró la mayor parte del almacenamiento, procesamiento, experimentación y visualización, mientras que el entorno local atendió los procesos que requerían conectividad con sistemas internos.

Dentro de Fabric se utilizaron distintos tipos de elementos según la función requerida. Una base de datos KQL actuó como capa inicial o bronce para recibir información con un grado mínimo de elaboración. Las bases KQL están orientadas al análisis de datos temporales y pueden ser consultadas desde notebooks mediante Kusto Query Language [24]. El repositorio relacional central se implementó con un Data Warehouse [25], con el objetivo de alojar las capas plata y oro. Allí se almacenaron datos normalizados, integrados y preparados para el consumo analítico mediante tablas y vistas T-SQL. También se utilizó un Data Lakehouse [26], que se reservó principalmente para archivos auxiliares y para aquellos formatos que no requerían almacenamiento relacional.

modelos y para la integración con MLflow. Por otra parte, se utilizaron Pipelines [23] para la orquestación entre notebooks, consultas y copias de datos.

La conexión con bases Oracle instaladas en la infraestructura de CAMMESA se realizó mediante una puerta de enlace de datos alojada en servidores de la empresa. Este componente permite que los servicios de Fabric accedan de manera controlada a fuentes locales sin exponer directamente las bases internas.

El servidor local ejecutó Dagster y las bibliotecas necesarias para comunicarse con PI System y Fabric. Allí se programaron activos encargados de consultar las series internas, procesarlas con pandas y NumPy, y persistir los resultados en el Warehouse mediante autenticación de Azure. El enfoque basado en activos de Dagster facilita describir dependencias y programar actualizaciones periódicas, manteniendo separados el código de acceso a fuentes locales y los servicios administrados en la nube [11, 12].

Esta distribución de responsabilidades respondió a restricciones tecnológicas existentes y a la conveniencia de utilizar la plataforma institucional de CAMMESA. Fabric aporta almacenamiento centralizado, capacidad de procesamiento y servicios integrados de ciencia de datos, mientras que el servidor local conserva el acceso a fuentes que no están disponibles desde la nube. El diseño específico de los flujos, las dependencias entre componentes y los mecanismos de ejecución se desarrollan en el Capítulo 3.

Los notebooks de Fabric [12] proporcionaron los entornos de ejecución para Python, pandas y PySpark. También sirvieron como espacio para la experimentación con modelos y para la integración con MLflow. Por otra parte, se utilizaron Pipelines [27] para la orquestación entre notebooks, consultas y copias de datos.

El entrenamiento de los modelos neuronales se realizó en Google Colab, que proporciona aceleración por GPU sin requerir infraestructura propia. Para ello, los datos necesarios se exportaron desde el warehouse a archivos que se cargaron en el entorno de ejecución.

La conexión con bases Oracle instaladas en la infraestructura de CAMMESA se realizó mediante una puerta de enlace de datos alojada en servidores de la empresa. Este componente permite que los servicios de Fabric accedan de manera controlada a fuentes locales sin exponer directamente las bases internas.

El servidor local ejecutó Dagster y las bibliotecas necesarias para comunicarse con PI System y Fabric. Allí se programaron activos encargados de consultar las series internas, procesarlas con pandas y NumPy, y persistir los resultados en el Warehouse mediante autenticación de Azure. El enfoque basado en activos de Dagster facilita describir dependencias y programar actualizaciones periódicas, manteniendo separados el código de acceso a fuentes locales y los servicios administrados en la nube [15, 16].

Esta distribución de responsabilidades respondió a restricciones tecnológicas existentes y a la conveniencia de utilizar la plataforma institucional de CAMMESA. Fabric aporta almacenamiento centralizado, capacidad de procesamiento y servicios integrados de ciencia de datos, mientras que el servidor local conserva el acceso a fuentes que no están disponibles desde la nube. El diseño específico de los flujos, las dependencias entre componentes y los mecanismos de ejecución se desarrollan en el Capítulo 3.

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño y la implementación de la solución desarrollada para automatizar el pronóstico de la demanda eléctrica del SADI. En primer lugar, se presenta el pipeline implementado para obtener, validar, transformar y almacenar los datos de demanda y las variables meteorológicas utilizadas por los modelos. A continuación, se describen la arquitectura de los modelos, el procedimiento de entrenamiento y optimización, y los mecanismos empleados para generar y persistir las predicciones. Finalmente, se detalla la integración de estos componentes en el sistema implementado, junto con las decisiones adoptadas para garantizar la trazabilidad y la reproducibilidad de las ejecuciones.

3.1. Pipeline de datos

El sistema de pronóstico requiere integrar series eléctricas, meteorológicas y calendarias con distintas resoluciones temporales, coberturas geográficas y condiciones de acceso. Para ello se diseñó un pipeline que automatiza la extracción, la validación, la transformación y la persistencia de los datos, con el objetivo de disponer de conjuntos consistentes y trazables tanto para el entrenamiento como para la ejecución periódica de los pronósticos. En esta sección se presentan, en primer lugar, la arquitectura y los criterios de diseño comunes y, a continuación, los tres flujos que componen el pipeline: demanda eléctrica, datos meteorológicos observados y pronósticos meteorológicos.

3.1.1. Arquitectura y criterios de diseño

La solución se implementó sobre la arquitectura híbrida presentada en el capítulo 2. Los procesos que requieren acceso a sistemas internos de CAMMESA, o a fuentes con restricciones de acceso desde el exterior, se ejecutan en un servidor local mediante Dagster. El almacenamiento y las transformaciones se concentran en Microsoft Fabric: una base de datos KQL recibe los datos meteorológicos con un grado mínimo de elaboración, el warehouse aloja las capas estructuradas, un lakehouse conserva los archivos de origen, y los notebooks y pipelines ejecutan y orquestan el procesamiento. La figura 3.1 resume los tres flujos y las etapas que atraviesa cada uno.

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño y la implementación de la solución desarrollada para automatizar el pronóstico de la demanda eléctrica del SADI. En primer lugar, se presenta el pipeline implementado para obtener, validar, transformar y almacenar los datos de demanda y las variables meteorológicas utilizadas por los modelos. A continuación, se describen la arquitectura de los modelos, el procedimiento de entrenamiento y optimización, y los mecanismos empleados para generar y persistir las predicciones. Finalmente, se detalla la integración de estos componentes en el sistema implementado, junto con las decisiones adoptadas para garantizar la trazabilidad y la reproducibilidad de las ejecuciones.

3.1. Pipeline de datos

El sistema de pronóstico requiere integrar series eléctricas, meteorológicas y calendarias con distintas resoluciones temporales, coberturas geográficas y condiciones de acceso. Para ello se diseñó un pipeline que automatiza la extracción, la validación, la transformación y la persistencia de los datos, con el objetivo de disponer de conjuntos consistentes y trazables tanto para el entrenamiento como para la ejecución periódica de los pronósticos. En esta sección se presentan, en primer lugar, la arquitectura y los criterios de diseño comunes y, a continuación, los tres flujos que componen el pipeline: demanda eléctrica, datos meteorológicos observados y pronósticos meteorológicos.

3.1.1. Arquitectura y criterios de diseño

La solución se implementó sobre la arquitectura híbrida presentada en el capítulo 2. Los procesos que requieren acceso a sistemas internos de CAMMESA, o a fuentes con restricciones de acceso desde el exterior, se ejecutan en un servidor local mediante Dagster. El almacenamiento y las transformaciones se concentran en Microsoft Fabric: una base de datos KQL recibe los datos meteorológicos con un grado mínimo de elaboración, el warehouse aloja las capas estructuradas, un lakehouse conserva los archivos de origen, y los notebooks y pipelines ejecutan y orquestan el procesamiento. La figura 3.1 resume los tres flujos y las etapas que atraviesa cada uno.

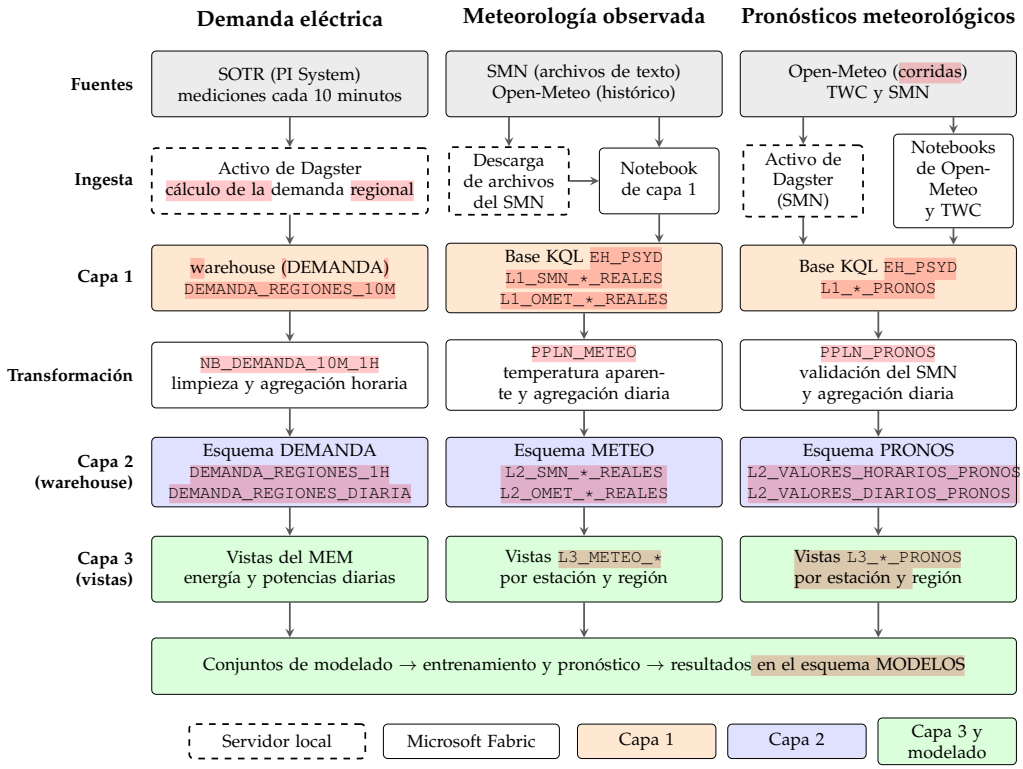


FIGURA 3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia.

La persistencia se organizó en tres capas. La capa 1 conserva una representación cercana a la fuente, sin transformaciones irreversibles. La capa 2 contiene datos validados, tipificados e integrados con las dimensiones del warehouse, como las estaciones meteorológicas y las regiones eléctricas. La capa 3 está formada por vistas orientadas al consumo analítico y al modelado, como los agregados del MEM o los valores meteorológicos por región. La demanda constituye una excepción: al provenir de un proceso local, su capa 1 se escribe directamente en el warehouse. Esta separación permite repetir las transformaciones cuando se modifican las reglas de procesamiento, sin volver a consultar las fuentes.

Sobre esta arquitectura se aplicaron los siguientes criterios, comunes a los tres flujos:

- Automatización: la obtención y la actualización de los datos se encapsularon en activos de Dagster, notebooks y pipelines, de modo que la ejecución diaria no requiera intervención manual.
- Preservación de la granularidad: la demanda se almacena con resolución de diez minutos y los datos meteorológicos con la resolución horaria o diaria de cada fuente. Las agregaciones se realizan en las capas posteriores.
- Reproceso sin duplicados: cada proceso recibe un período de fechas y reemplaza los registros de ese período, por lo que una ejecución puede repetirse sin generar versiones duplicadas de un mismo dato.
- Calidad y trazabilidad: los controles de completitud, coherencia y valores anómalos se aplican antes de generar las variables de entrenamiento, y los valores corregidos se conservan junto con los originales.

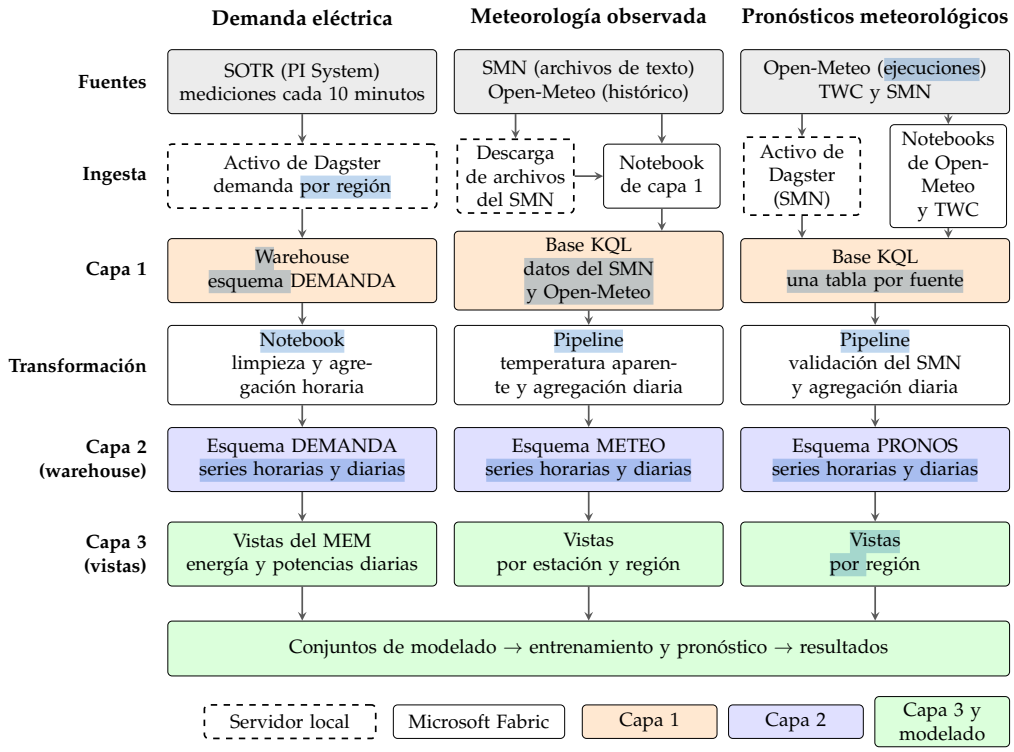


FIGURA 3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia.

La persistencia se organizó en tres capas. La capa 1 conserva una representación cercana a la fuente, sin transformaciones irreversibles. La capa 2 contiene datos validados, tipificados e integrados con las dimensiones del warehouse, como las estaciones meteorológicas y las regiones eléctricas. La capa 3 está formada por vistas orientadas al consumo analítico y al modelado, como los agregados del MEM o los valores meteorológicos por región. La demanda constituye una excepción: al provenir de un proceso local, su capa 1 se escribe directamente en el warehouse. Esta separación permite repetir las transformaciones cuando se modifican las reglas de procesamiento, sin volver a consultar las fuentes. El apéndice A describe las tablas y vistas de cada esquema.

Sobre esta arquitectura se aplicaron los siguientes criterios, comunes a los tres flujos:

- Automatización: la obtención y la actualización de los datos se encapsularon en activos de Dagster, notebooks y pipelines, de modo que la ejecución diaria no requiera intervención manual.
- Preservación de la granularidad: la demanda se almacena con resolución de diez minutos y los datos meteorológicos con la resolución horaria o diaria de cada fuente. Las agregaciones se realizan en las capas posteriores.
- Reproceso sin duplicados: cada proceso recibe un período de fechas y reemplaza los registros de ese período, por lo que una ejecución puede repetirse sin generar versiones duplicadas de un mismo dato.
- Calidad y trazabilidad: los controles de completitud, coherencia y valores anómalos se aplican antes de generar las variables de entrenamiento, y los valores corregidos se conservan junto con los originales.

- Referencia temporal y geográfica común: las marcas temporales se expresan en hora local con la convención horaria de CAMMESA, y las estaciones y regiones se vinculan mediante dimensiones con períodos de vigencia.
- Coherencia entre entrenamiento y producción: cada variable se define de la misma manera para los datos observados, utilizados en el entrenamiento, y para los pronosticados, utilizados en la generación de pronósticos.

La información calendaria se obtiene de tablas existentes en las bases de datos de CAMMESA y se combina con las series eléctricas y meteorológicas mediante la fecha.

El último criterio condicionó el cálculo de la temperatura aparente. Open-Meteo pone a disposición esta variable a través de su API y la calcula según la formulación de Steadman [30], con las adaptaciones de su implementación [31], que se expresan en la ecuación 3.1:

$$AT = T + 0{,}348\, e - 0{,}70\, v_2 + 0{,}70\, \frac{Q}{v_2 + 10} - 4{,}25 \tag{3.1}$$

donde T es la temperatura del aire en °C, $e = \frac{HR}{100}\, 6{,}105\, \exp\left(\frac{17{,}27\, T}{237{,}7 + T}\right)$ es la presión de vapor en hPa, HR es la humedad relativa en porcentaje, $v_2 = 0{,}75\, v_{10}$ es la velocidad del viento reducida a 2 m de altura en m/s y $Q = \max(0;\ 0{,}1\,(G - 550))$, con G igual a la radiación solar global en W/m^2.

En consecuencia, la temperatura aparente de los datos observados se calcula con la misma expresión. Se utilizan la temperatura, la humedad y el viento provistos por el SMN, y la radiación de Open-Meteo para la misma estación y hora (ya que el SMN no informa datos de radiación ni nubosidad observados). Una formulación sin radiación produciría valores sistemáticamente inferiores en las horas de mayor insolación, y el modelo recibiría en producción una variable con una distribución distinta de la utilizada durante el entrenamiento.

3.1.2. Flujo de demanda eléctrica

La demanda eléctrica constituye la variable objetivo de los modelos. Su flujo obtiene las mediciones del SOTR, calcula la demanda de cada región eléctrica con resolución de diez minutos y, a partir de ella, genera las series horarias depuradas y los valores diarios utilizados como objetivos de pronóstico.

Cálculo de la demanda regional

La demanda eléctrica se obtiene desde PI System mediante PIconnect. Debido a que esta fuente solo es accesible desde la red interna, la extracción se ejecuta en la infraestructura local. El proceso se implementó como un activo de Dagster que consulta valores interpolados con un paso de diez minutos, calcula la demanda por región eléctrica y escribe el resultado en el warehouse de Fabric.

El cálculo regional combina generación e intercambios medidos en el SOTR. Para la partición en regiones del SADI se utilizó la definición implementada por CAMMESA, que se presenta en la figura 3.2 y comprende las siguientes regiones:

- GBA: Gran Buenos Aires.

- Referencia temporal y geográfica común: las marcas temporales se expresan en hora local con la convención horaria de CAMMESA, y las estaciones y regiones se vinculan mediante dimensiones con períodos de vigencia.
- Coherencia entre entrenamiento y producción: cada variable se define de la misma manera para los datos observados, utilizados en el entrenamiento, y para los pronosticados, utilizados en la generación de pronósticos.

La información calendaria se obtiene de tablas existentes en las bases de datos de CAMMESA y se combina con las series eléctricas y meteorológicas mediante la fecha.

El último criterio condicionó el cálculo de la temperatura aparente. Open-Meteo pone a disposición esta variable a través de su API y la calcula según la formulación de Steadman [28], con las adaptaciones de su implementación [29], que se expresan en la ecuación 3.1:

$$AT = T + 0{,}348\, e - 0{,}70\, v_2 + 0{,}70\, \frac{Q}{v_2 + 10} - 4{,}25 \tag{3.1}$$

donde T es la temperatura del aire en °C, e es la presión de vapor en hPa, v_2 es la velocidad del viento a 2 m de altura en m/s y Q es la radiación absorbida. Estas tres magnitudes se obtienen según las ecuaciones 3.2, 3.3 y 3.4:

$$e = \frac{HR}{100}\, 6{,}105\, \exp\left(\frac{17{,}27\, T}{237{,}7 + T}\right) \tag{3.2}$$

$$v_2 = 0{,}75\, v_{10} \tag{3.3}$$

$$Q = \max\left(0;\ 0{,}1\,(G - 550)\right) \tag{3.4}$$

donde HR es la humedad relativa en porcentaje, v_{10} es la velocidad del viento a 10 m de altura en m/s y G es la radiación solar global en W/m^2.

En consecuencia, la temperatura aparente de los datos observados se calcula con la misma expresión. Se utilizan la temperatura, la humedad y el viento provistos por el SMN, y la radiación de Open-Meteo para la misma estación y hora (ya que el SMN no informa datos de radiación ni nubosidad observados). Una formulación sin radiación produciría valores sistemáticamente inferiores en las horas de mayor insolación, y el modelo recibiría en producción una variable con una distribución distinta de la utilizada durante el entrenamiento.

3.1.2. Flujo de demanda eléctrica

La demanda eléctrica constituye la variable objetivo de los modelos. Su flujo obtiene las mediciones del SOTR, calcula la demanda de cada región eléctrica con resolución de diez minutos y, a partir de ella, genera las series horarias depuradas y los valores diarios utilizados como objetivos de pronóstico.

- CEN: provincias de Córdoba y San Luis.
- LIT: provincias de Santa Fe y Entre Ríos.
- CUY: provincias de Mendoza y San Juan.
- NEA: provincias de Corrientes, Misiones, Chaco y Formosa.
- NOA: provincias de Salta, Jujuy, Catamarca, La Rioja, Tucumán y Santiago del Estero.
- COM: provincias de Rio Negro, Neuquén y La Pampa.
- PBA: provincia de Buenos Aires. Es importante mencionar que, para el pronóstico de demanda, esta región se divide en norte (PBN) y sur (PBS). Esto se debe a que presentan patrones de consumo distintos, en primer lugar por la variación de condiciones climáticas producto de la gran extensión territorial y, en segundo lugar, por las características de los usuarios (el norte está notablemente más industrializado que el sur).
- PAT: provincias de Chubut, Santa Cruz y Tierra del Fuego.



FIGURA 3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA.

El SOTR provee medidores de demanda por regiones, pero no son aptos para el pronóstico de demanda debido a que no incluyen las pérdidas que se producen en las líneas eléctricas que vinculan las regiones. Por este motivo, fue necesario desarrollar un algoritmo que obtenga los valores de generación e intercambios de

Cálculo de la demanda regional

La demanda eléctrica se obtiene desde PI System mediante PIconnect. Debido a que esta fuente solo es accesible desde la red interna, la extracción se ejecuta en la infraestructura local. El proceso se implementó como un activo de Dagster que consulta valores interpolados con un paso de diez minutos, calcula la demanda por región eléctrica y escribe el resultado en el warehouse de Fabric.

El cálculo regional combina generación e intercambios medidos en el SOTR. Para la partición en regiones del SADI se utilizó la definición implementada por CAMMESA, que se presenta en la figura 3.2 y comprende las siguientes regiones:

- GBA: Ciudad Autónoma de Buenos Aires y partidos del Gran Buenos Aires.
- CEN: provincias de Córdoba y San Luis.
- LIT: provincias de Santa Fe y Entre Ríos.
- CUY: provincias de Mendoza y San Juan.
- NEA: provincias de Corrientes, Misiones, Chaco y Formosa.
- NOA: provincias de Salta, Jujuy, Catamarca, La Rioja, Tucumán y Santiago del Estero.
- COM: provincias de Rio Negro, Neuquén y La Pampa.
- PBA: provincia de Buenos Aires, excepto los partidos del Gran Buenos Aires.
- PAT: provincias de Chubut, Santa Cruz y Tierra del Fuego.

Para el pronóstico de demanda, la región PBA se divide en norte (PBN) y sur (PBS). Ambas subregiones presentan patrones de consumo distintos, en primer lugar por la variación de las condiciones climáticas asociada con la gran extensión territorial y, en segundo lugar, por las características de los usuarios, ya que el norte está notablemente más industrializado que el sur.

cada región y, realizando la sumatoria correspondiente, calcule la demanda. Por otra parte, se hizo una repartición de las pérdidas entre corredores, asignando la mitad a cada una de las regiones asociadas al vínculo.

En términos formales, sea G_r la generación de la región r, $\mathcal{N}_r$ el conjunto de regiones vinculadas y $F_{r\to j}$ y $F_{j\to r}$ las mediciones del intercambio en ambos extremos del corredor. La demanda regional se calcula según la ecuación 3.2:

$$D_r = G_r - \sum_{j\in\mathcal{N}_r} \frac{F_{r\to j} - F_{j\to r}}{2} \tag{3.2}$$

donde los intercambios son positivos cuando representan una exportación desde la región r. La semidiferencia entre las mediciones de ambos extremos permite repartir las pérdidas del corredor en partes iguales entre las regiones vinculadas.

La figura 3.3, tomada del SOTR, muestra el estado de generación e intercambio entre algunas regiones para un instante determinado.

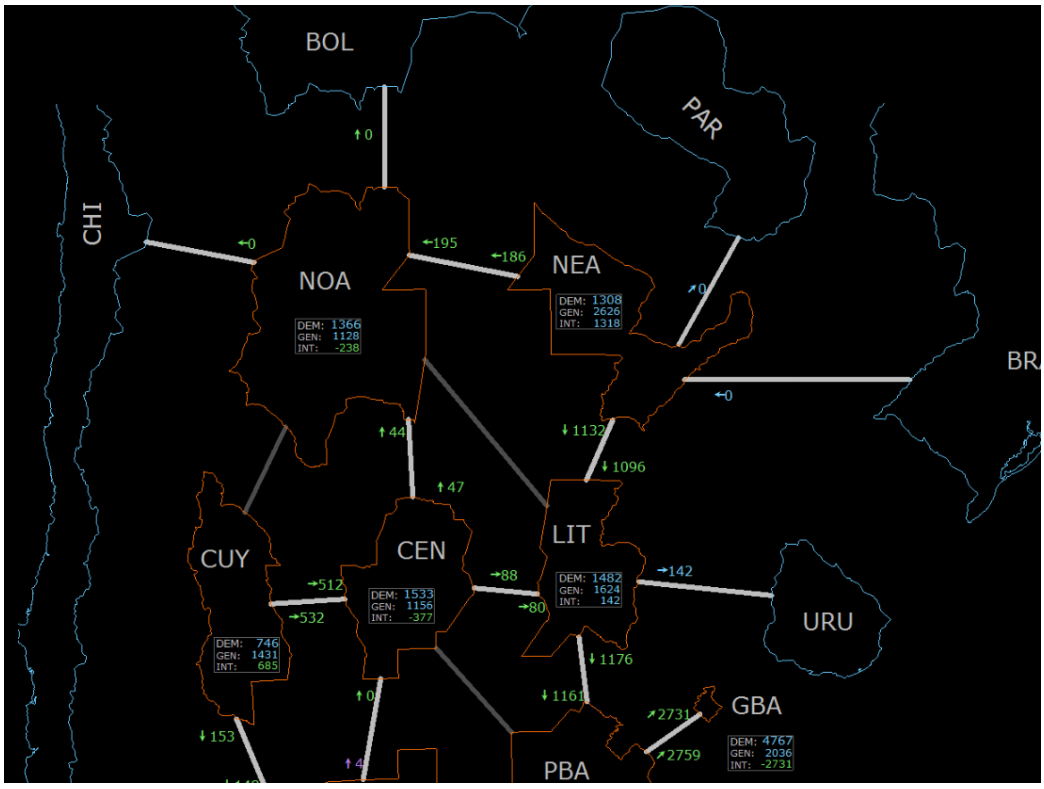


FIGURA 3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado.

A modo de ejemplo, la demanda de LIT corregida por pérdidas para el instante de la figura se calcula según la ecuación 3.3. El intercambio con Uruguay es igual en ambos extremos, ya que corresponde a un vínculo interno de la central Salto Grande.



FIGURA 3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA.

El SOTR provee medidores de demanda por regiones, pero no son aptos para el pronóstico de demanda debido a que no incluyen las pérdidas que se producen en las líneas eléctricas que vinculan las regiones. Por este motivo, fue necesario desarrollar un algoritmo que obtenga los valores de generación e intercambios de cada región y, realizando la sumatoria correspondiente, calcule la demanda. Por otra parte, se hizo una repartición de las pérdidas entre corredores, asignando la mitad a cada una de las regiones asociadas al vínculo.

En términos formales, sea G_r la generación de la región r, $\mathcal{N}_r$ el conjunto de regiones vinculadas y $F_{r\to j}$ y $F_{j\to r}$ las mediciones del intercambio en ambos extremos del corredor. La demanda regional se calcula según la ecuación 3.5:

$$D_r = G_r - \sum_{j\in\mathcal{N}_r} \frac{F_{r\to j} - F_{j\to r}}{2} \tag{3.5}$$

donde los intercambios son positivos cuando representan una exportación desde la región r. La semidiferencia entre las mediciones de ambos extremos permite repartir las pérdidas del corredor en partes iguales entre las regiones vinculadas.

La figura 3.3, tomada del SOTR, muestra el estado de generación e intercambio entre algunas regiones para un instante determinado.

$$D_{\mathrm{LIT}} = 1624 - \left[\frac{-1096 - 1132}{2} + \frac{-80 - 88}{2} + \frac{142 - (-142)}{2} + \frac{1176 - (-1161)}{2}\right] \tag{3.3}$$

Resolviendo,

$$D_{\mathrm{LIT}} = 1624 - (-1114 - 84 + 142 + 1168{,}5) = 1511{,}5\ \mathrm{MW} \tag{3.4}$$

El valor obtenido, de 1511,5 MW, difiere de los 1482 MW que resultan sin considerar las pérdidas. En caso de no aplicar esta corrección, la demanda nacional agregada presentaría un error considerable introducido en los datos de entrenamiento de los modelos.

La implementación de esta corrección requirió definir todos los intercambios entre regiones y consultar una cantidad de medidores del SOTR sustancialmente mayor que si se hubiesen podido utilizar los medidores de demanda existentes.

Por otra parte, se aplican ajustes específicos para representar de forma consistente la demanda utilizada en la programación. Entre ellos se encuentran la exclusión de consumos asociados con centrales de bombeo, que se ponen en servicio para almacenamiento de energía, y la demanda de grandes acerías que informan su consumo previsto.

El proceso genera también variables de control. La demanda MEM calculada como suma de las regiones se compara con un medidor nacional de referencia. Se almacenan la diferencia absoluta y porcentual entre ambos valores. Para PBA se conservan la demanda original, los valores directos de PBN y PBS y las diferencias asociadas con la partición. Asimismo, se calcula la suma de los intercambios internos, que debe permanecer próxima a cero porque las exportaciones de una región son importaciones de otra. Estos campos no constituyen objetivos de pronóstico, pero permiten verificar la coherencia del cálculo y detectar cambios en los medidores o en las reglas de negocio.

La salida se persiste en la tabla `DEMANDA.DEMANDA_REGIONES_10M`. Su clave está formada por fecha, hora e intervalo. Las columnas de demanda se almacenan en formato ancho, con una columna por región, junto con MEM y las variables de control. Esta tabla actúa como fuente para los procesos que generan resoluciones horarias y diarias.

La tarea de Dagster que ejecuta este proceso está programada cada 20 minutos, con el objetivo de mantener la tabla lo suficientemente actualizada para cualquier otro uso.

Resolución horaria y control de calidad

La transformación horaria se implementó en un notebook de Fabric. El proceso lee la tabla de diez minutos, controla la disponibilidad de nuevos registros y procesa únicamente el intervalo necesario. Para admitir correcciones tardías en la fuente se vuelve a considerar el día anterior al último registro persistido. Si no existen horas nuevas completas, el notebook finaliza sin efectuar escrituras.

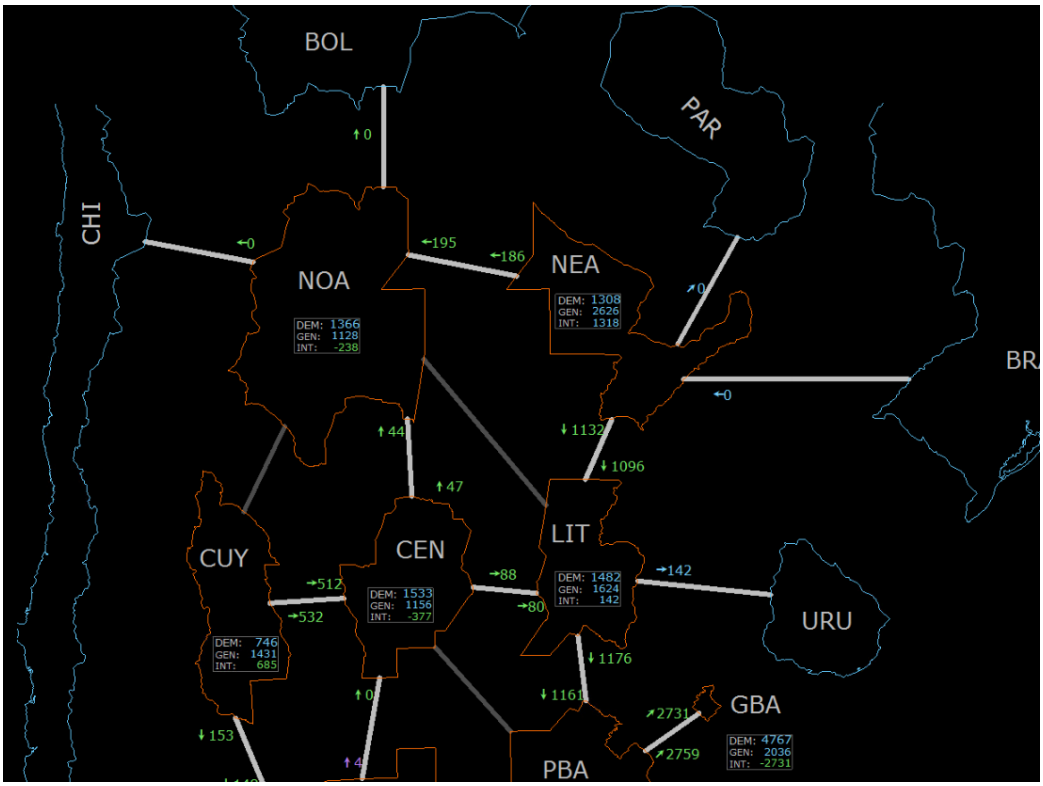


FIGURA 3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado.

A modo de ejemplo, la demanda de LIT corregida por pérdidas para el instante de la figura se calcula según la ecuación 3.6. El intercambio con Uruguay es igual en ambos extremos, ya que corresponde a un vínculo interno de la central Salto Grande.

$$D_{\mathrm{LIT}} = 1624 - \left[\frac{-1096 - 1132}{2} + \frac{-80 - 88}{2} + \frac{142 - (-142)}{2} + \frac{1176 - (-1161)}{2}\right] \tag{3.6}$$

Al resolver las operaciones, resulta:

$$D_{\mathrm{LIT}} = 1624 - (-1114 - 84 + 142 + 1168{,}5) = 1511{,}5\ \mathrm{MW} \tag{3.7}$$

El valor obtenido, de 1511,5 MW, difiere de los 1482 MW que resultan sin considerar las pérdidas. En caso de no aplicar esta corrección, la demanda nacional agregada presentaría un error considerable introducido en los datos de entrenamiento de los modelos.

La implementación de esta corrección requirió definir todos los intercambios entre regiones y consultar una cantidad de medidores del SOTR sustancialmente mayor que si se hubiesen podido utilizar los medidores de demanda existentes.

Por otra parte, se aplican ajustes específicos para representar de forma consistente la demanda utilizada en la programación. Entre ellos se encuentran la exclusión

Una hora se considera completa cuando contiene los seis intervalos esperados de diez minutos. Este criterio evita calcular promedios horarios a partir de observaciones parciales. Luego, la tabla en formato ancho se transforma a formato largo, con una fila por fecha, hora y región. La transformación facilita aplicar reglas homogéneas de limpieza y vincular cada observación con la dimensión de regiones.

La limpieza se realiza en dos etapas. Primero se identifican valores extremos por región mediante el rango intercuartílico. Los límites se establecen a partir del primer y tercer cuartil y un factor de tres veces el rango intercuartílico. Los valores que quedan fuera de esos límites se reemplazan temporalmente por valores nulos y se estiman mediante interpolación lineal en el eje temporal. En la figura 3.4 puede verse un caso de corrección de valores extremos.

El método de eliminación de outliers es eficiente para fallas de medición, donde se alcanzan valores extremos durante intervalos breves. Las correcciones más desafiantes son aquellas que corresponden a fallas eléctricas reales del sistema eléctrico (por ejemplo, la desconexión intempestiva de una línea de transmisión que hace caer la demanda abruptamente). En estos casos, es deseable poder inferir el valor de demanda si no hubiese existido la falla, ya que, a los fines del entrenamiento de un modelo predictivo, esto representa un error que debe ser desestimado.

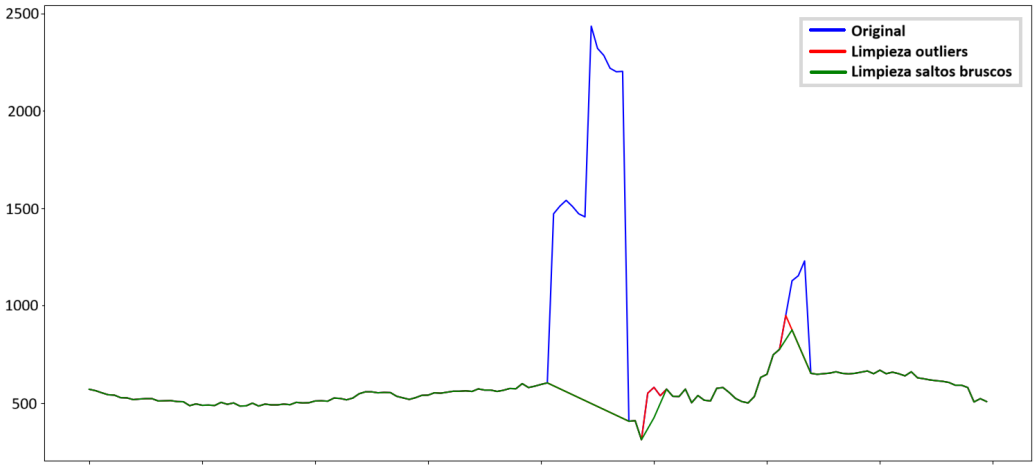


FIGURA 3.4. Corrección de valores extremos.

Por este motivo, en la segunda etapa se detectan escalones abruptos dentro de un mismo día. Un cambio se considera candidato a corrección cuando supera simultáneamente un umbral relativo del 7 % y un umbral absoluto de 100 MW. Estos valores fueron determinados a partir de la recomendación de los especialistas de CAMMESA en combinación con el análisis de amplios rangos temporales. La detección y corrección se ejecuta de manera iterativa, con un máximo de diez iteraciones. Los puntos identificados se interpolan y, cuando la interpolación no resulta posible en los extremos, se completan mediante propagación hacia adelante o hacia atrás. En la figura 3.5 puede verse un caso de corrección de saltos bruscos.

de consumos asociados con centrales de bombeo, que se ponen en servicio para almacenamiento de energía, y la demanda de grandes acerías que informan su consumo previsto.

El proceso genera también variables de control. La demanda MEM calculada como suma de las regiones se compara con un medidor nacional de referencia. Se almacenan la diferencia absoluta y porcentual entre ambos valores. Para PBA se conservan la demanda original, los valores directos de PBN y PBS y las diferencias asociadas con la partición. Asimismo, se calcula la suma de los intercambios internos, que debe permanecer próxima a cero porque las exportaciones de una región son importaciones de otra. Estos campos no constituyen objetivos de pronóstico, pero permiten verificar la coherencia del cálculo y detectar cambios en los medidores o en las reglas de negocio.

La salida se persiste en la tabla `DEMANDA.DEMANDA_REGIONES_10M`. Su clave está formada por fecha, hora e intervalo. Las columnas de demanda se almacenan en formato ancho, con una columna por región, junto con MEM y las variables de control. Esta tabla actúa como fuente para los procesos que generan resoluciones horarias y diarias.

La tarea de Dagster que ejecuta este proceso está programada cada 20 minutos, con el objetivo de mantener la tabla lo suficientemente actualizada para cualquier otro uso.

Resolución horaria y control de calidad

La transformación horaria se implementó en un notebook de Fabric. El proceso lee la tabla de diez minutos, controla la disponibilidad de nuevos registros y procesa únicamente el intervalo necesario. Para admitir correcciones tardías en la fuente se vuelve a considerar el día anterior al último registro persistido. Si no existen horas nuevas completas, el notebook finaliza sin efectuar escrituras.

Una hora se considera completa cuando contiene los seis intervalos esperados de diez minutos. Este criterio evita calcular promedios horarios a partir de observaciones parciales. Luego, la tabla en formato ancho se transforma a formato largo, con una fila por fecha, hora y región. La transformación facilita aplicar reglas homogéneas de limpieza y vincular cada observación con la dimensión de regiones.

La limpieza se realiza en dos etapas. Primero se identifican valores extremos por región mediante el rango intercuartílico. Los límites se establecen a partir del primer y tercer cuartil y un factor de tres veces el rango intercuartílico. Los valores que quedan fuera de esos límites se reemplazan temporalmente por valores nulos y se estiman mediante interpolación lineal en el eje temporal. En la figura 3.4 puede verse un caso de corrección de valores extremos.

El método de eliminación de outliers es eficiente para fallas de medición, donde se alcanzan valores extremos durante intervalos breves. Las correcciones más desafiantes son aquellas que corresponden a fallas eléctricas reales del sistema eléctrico (por ejemplo, la desconexión intempestiva de una línea de transmisión que hace caer la demanda abruptamente). En estos casos, es deseable poder inferir el valor de demanda si no hubiese existido la falla, ya que, a los fines del entrenamiento de un modelo predictivo, esto representa un error que debe ser desestimado.

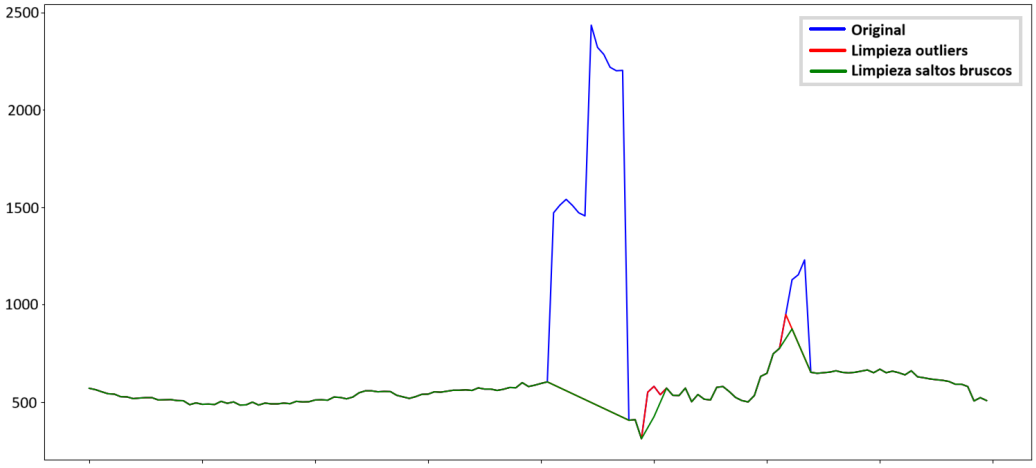


FIGURA 3.4. Corrección de valores extremos.

Por este motivo, en la segunda etapa se detectan escalones abruptos dentro de un mismo día. Un cambio se considera candidato a corrección cuando supera simultáneamente un umbral relativo del 7 % y un umbral absoluto de 100 MW. Estos valores fueron determinados a partir de la recomendación de los especialistas de CAMMESA en combinación con el análisis de amplios rangos temporales. La detección y corrección se ejecuta de manera iterativa, con un máximo de diez iteraciones. Los puntos identificados se interpolan y, cuando la interpolación no resulta posible en los extremos, se completan mediante propagación hacia adelante o hacia atrás. En la figura 3.5 puede verse un caso de corrección de saltos bruscos.

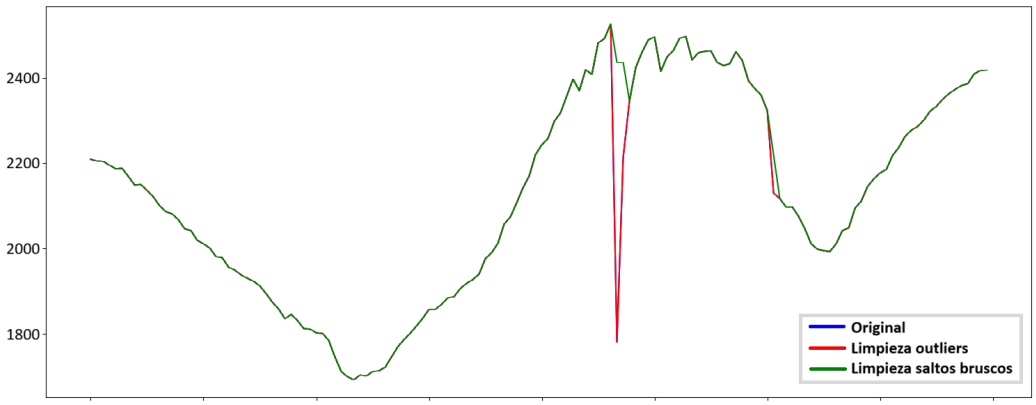


FIGURA 3.5. Corrección de saltos bruscos.

Después de la limpieza se calcula el promedio de los seis registros de cada hora. Se conservan tanto el valor resultante como el promedio obtenido a partir de los datos anteriores a la corrección. La columna `FLAG_CORREGIDO` indica si ambos valores difieren. De este modo, los modelos pueden utilizar la serie depurada sin perder la posibilidad de auditar qué observaciones fueron modificadas.

Cada registro se vincula con la dimensión regional mediante la clave `RGE_ID` y el período de vigencia correspondiente. La tabla final contiene `FECHA`, `HORA`, `RGE_ID`, `VALOR`, `FLAG_CORREGIDO` y `VALOR_ORIGINAL`. Antes de persistir, se

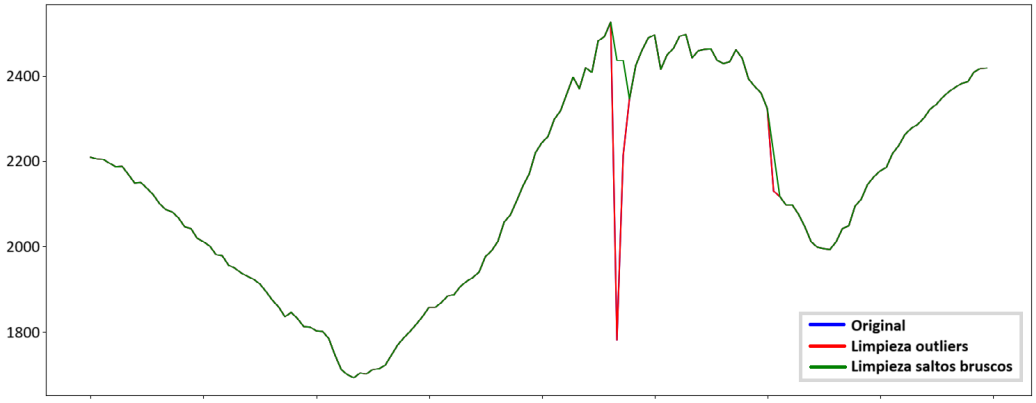


FIGURA 3.5. Corrección de saltos bruscos.

Después de la limpieza se calcula el promedio de los seis registros de cada hora. Se conservan tanto el valor resultante como el promedio obtenido a partir de los datos anteriores a la corrección. La columna `FLAG_CORREGIDO` indica si ambos valores difieren. De este modo, los modelos pueden utilizar la serie depurada sin perder la posibilidad de auditar qué observaciones fueron modificadas.

Cada registro se vincula con la dimensión regional mediante la clave `RGE_ID` y el período de vigencia correspondiente. La tabla final contiene `FECHA`, `HORA`, `RGE_ID`, `VALOR`, `FLAG_CORREGIDO` y `VALOR_ORIGINAL`. Antes de persistir, se verifica la existencia de la clave compuesta en el destino para evitar duplicados. Los registros nuevos se incorporan en `DEMANDA.DEMANDA_REGIONES_1H`.

A partir de la demanda horaria se obtienen variables diarias utilizadas como objetivos. La energía diaria se almacena por región en la tabla del esquema DEMANDA llamada `DEMANDA_REGIONES_DIARIA`. Las vistas del warehouse suman los valores regionales para obtener la demanda del MEM y calculan las potencias máxima y mínima sobre los intervalos horarios definidos para cada variable. Así, se mantiene una fuente regional común para los objetivos nacionales y permite comprobar que el agregado del MEM sea consistente con sus componentes.

3.1.3. Flujo de datos meteorológicos observados

El flujo de datos meteorológicos observados integra las mediciones de las estaciones del SMN con los valores de Open-Meteo para las mismas ubicaciones. Estas series se utilizan para construir las variables explicativas empleadas en el entrenamiento de los modelos.

Ingesta en capa 1

La primera etapa se ejecuta en el notebook `NB_METEO_L1`. Para el SMN se procesan los archivos de observaciones diarias y de datos horarios. Para Open-Meteo se realizan consultas por coordenadas asociadas con estaciones de referencia. El rango de fechas se recibe como parámetro y, cuando no se informa, el notebook utiliza el día anterior a la ejecución.

Los archivos descargados del SMN se conservan en un lakehouse. Esta copia permite mantener el insumo original y volver a procesarlo si resulta necesario. Los datos interpretados se escriben en la base KQL `EH_PSYD`, utilizada como capa 1.

verifica la existencia de la clave compuesta en el destino para evitar duplicados. Los registros nuevos se incorporan en `DEMANDA.DEMANDA_REGIONES_1H`.

A partir de la demanda horaria se obtienen las variables diarias utilizadas como objetivos. La vista `DEMANDA.DEMANDAS_MEM` suma los valores regionales de cada hora para obtener la demanda del MEM y, a partir de ella, calcula la energía diaria y las potencias máxima y mínima sobre los intervalos horarios definidos para cada variable. De este modo, los objetivos nacionales se derivan de una fuente regional común y puede comprobarse que el agregado del MEM sea consistente con sus componentes.

3.1.3. Flujo de datos meteorológicos observados

El flujo de datos meteorológicos observados integra las mediciones de las estaciones del SMN con los valores de Open-Meteo para las mismas ubicaciones. Estas series se utilizan para construir las variables explicativas empleadas en el entrenamiento de los modelos.

Ingesta en capa 1

La primera etapa se ejecuta en el notebook `NB_METEO_L1`. Para el SMN se procesan los archivos de observaciones diarias y de datos horarios. Para Open-Meteo se realizan consultas por coordenadas asociadas con estaciones de referencia. El rango de fechas se recibe como parámetro y, cuando no se informa, el notebook utiliza el día anterior a la ejecución.

Los archivos descargados del SMN se conservan en un lakehouse. Esta copia permite mantener el insumo original y volver a procesarlo si resulta necesario. Los datos interpretados se escriben en la base KQL `EH_PSYD`, utilizada como capa 1. Allí se almacenan, entre otras variables, temperatura, humedad relativa, presión, dirección y velocidad del viento para la resolución horaria, y temperaturas máxima y mínima para la resolución diaria. Las tablas de Open-Meteo incorporan, además, temperatura aparente, nubosidad, precipitación y radiación solar, según la resolución de cada conjunto.

La persistencia en KQL se realiza por lotes y, cuando el volumen serializado supera el tamaño previsto para una operación, la carga se divide en bloques. El resultado de esta etapa es una representación cercana a las fuentes, separada por proveedor y resolución.

Transformación a capa 2

La transferencia desde la capa 1 hacia la capa 2 se orquesta mediante el pipeline `PPLN_METEO`, que se presenta en la figura 3.6. El pipeline ejecuta el notebook y consulta en el warehouse las estaciones cuya vigencia se superpone con el período procesado. Esta validación evita incorporar estaciones que no correspondan al intervalo analizado y permite asociar cada nombre de estación con su identificador `EMET_ID`.

Allí se almacenan, entre otras variables, temperatura, humedad relativa, presión, dirección y velocidad del viento para la resolución horaria, y temperaturas máxima y mínima para la resolución diaria. Las tablas de Open-Meteo incorporan además temperatura aparente, nubosidad, precipitación y radiación solar, según la resolución de cada conjunto.

La persistencia en KQL se realiza por lotes y, cuando el volumen serializado supera el tamaño previsto para una operación, la carga se divide en bloques. El resultado de esta etapa es una representación cercana a las fuentes, separada por proveedor y resolución.

Transformación a capa 2

La transferencia desde la capa 1 hacia la capa 2 se orquesta mediante el pipeline `PPLN_METEO`, que se presenta en la figura 3.6. El pipeline ejecuta el notebook y consulta en el warehouse las estaciones cuya vigencia se superpone con el período procesado. Esta validación evita incorporar estaciones que no correspondan al intervalo analizado y permite asociar cada nombre de estación con su identificador `EMET_ID`.

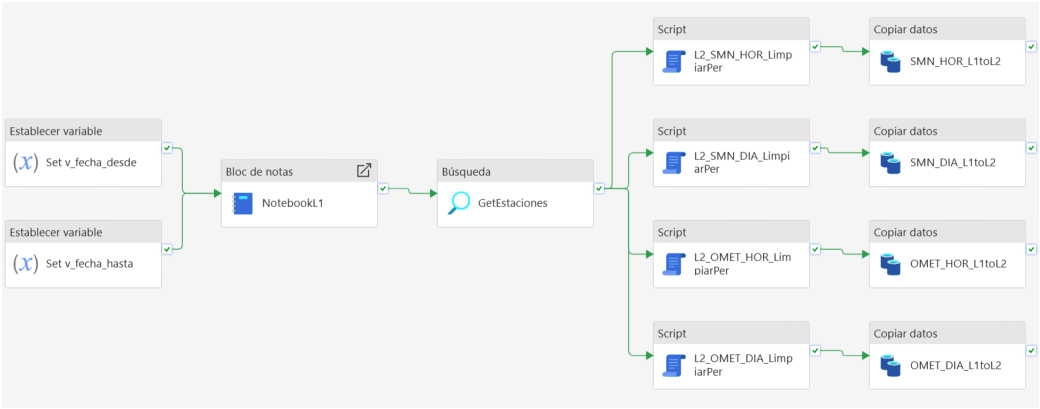


FIGURA 3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados.

Para los datos horarios del SMN, la actividad de copia filtra el rango de fechas, conserva las estaciones vigentes y construye la marca temporal `FECHA_HORA`. También ajusta la numeración horaria para compatibilizarla con la convención utilizada en CAMMESA. A partir de la temperatura, la humedad relativa y la velocidad del viento observadas, junto con la radiación de Open-Meteo, se calcula la temperatura aparente según la ecuación 3.1. Finalmente, las variables se redondean y tipifican antes de escribirlas en el esquema `METEO` del warehouse.

La escritura de los datos meteorológicos utiliza claves temporales y de estación. Para los valores horarios, la combinación de `FECHA_HORA` y `EMET_ID` identifica cada observación. Las tablas diarias emplean la fecha y el identificador de estación. Esta estructura permite comparar proveedores para una misma ubicación, seleccionar estaciones representativas de cada región eléctrica y construir agregados diarios sin perder el origen del dato.

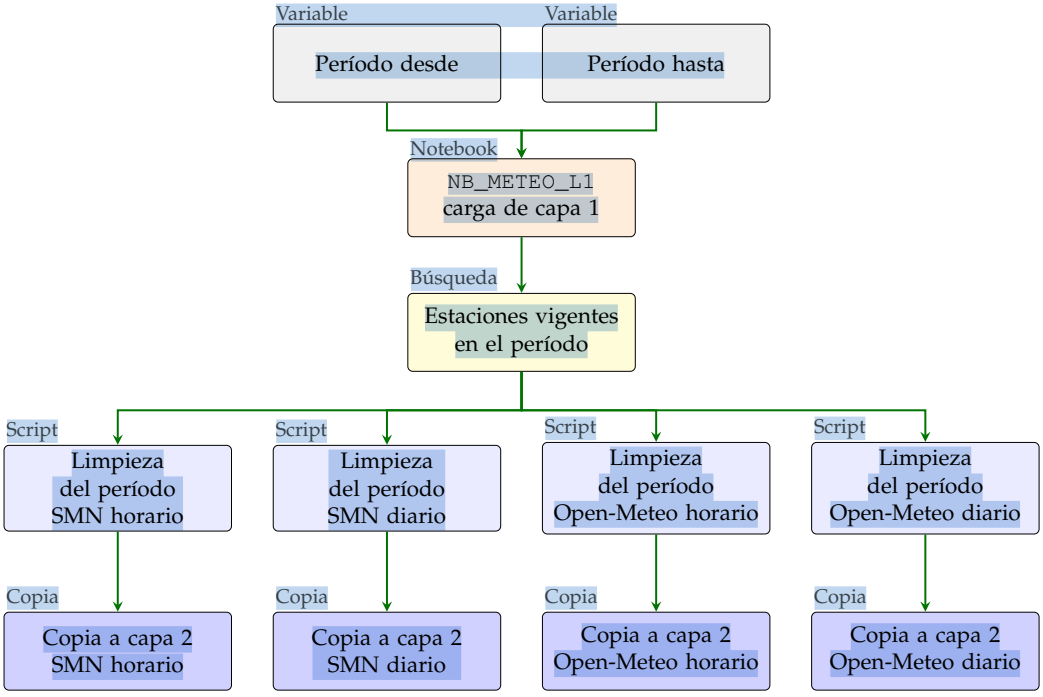


FIGURA 3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados.

Para los datos horarios del SMN, la actividad de copia filtra el rango de fechas, conserva las estaciones vigentes y construye la marca temporal `FECHA_HORA`. También ajusta la numeración horaria para compatibilizarla con la convención utilizada en CAMMESA. A partir de la temperatura, la humedad relativa y la velocidad del viento observadas, junto con la radiación de Open-Meteo, se calcula la temperatura aparente según la ecuación 3.1. Finalmente, las variables se redondean y tipifican antes de escribirlas en el esquema `METEO` del warehouse.

La escritura de los datos meteorológicos utiliza claves temporales y de estación. Para los valores horarios, la combinación de `FECHA_HORA` y `EMET_ID` identifica cada observación. Las tablas diarias emplean la fecha y el identificador de estación. Esta estructura permite comparar proveedores para una misma ubicación, seleccionar estaciones representativas de cada región eléctrica y construir agregados diarios sin perder el origen del dato.

3.1.4. Flujo de pronósticos meteorológicos

Los pronósticos meteorológicos constituyen la información exógena disponible al momento de estimar la demanda futura. A diferencia de una observación, un valor pronosticado depende de la fecha en que fue emitido. Para un mismo día objetivo existen tantos valores como ejecuciones del modelo lo incluyen, y su precisión disminuye a medida que aumenta la anticipación. Por este motivo, el flujo se diseñó para conservar cada ejecución identificada por su fecha de cálculo (`FECHA_CALCULO`) y por el modelo o servicio que la generó (`PRON_ID`). Esta estructura permite evaluar los modelos de demanda con la información que efectivamente habría estado disponible en cada fecha y evita utilizar observaciones posteriores como si fueran pronósticos.

3.1.4. Flujo de pronósticos meteorológicos

Los pronósticos meteorológicos constituyen la información exógena disponible al momento de estimar la demanda futura. A diferencia de una observación, un valor pronosticado depende de la fecha en que fue emitido. Para un mismo día objetivo existen tantos valores como corridas lo incluyen, y su precisión disminuye a medida que aumenta la anticipación. Por este motivo, el flujo se diseñó para conservar cada corrida identificada por su fecha de cálculo (`FECHA_CALCULO`) y por el modelo o servicio que la generó (`PRON_ID`). Esta estructura permite evaluar los modelos de demanda con la información que efectivamente habría estado disponible en cada fecha y evita utilizar observaciones posteriores como si fueran pronósticos.

Fuentes e ingesta en capa 1

La tabla 3.1 resume las fuentes incorporadas y el proceso que obtiene cada una.

TABLA 3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline.

Fuente	Proceso de ingesta	Resolución y horizonte	Variables principales
Open-Meteo (modelos IFS [24], ICON [25], GFS [26] y UKMO [27])	Notebook en Fabric.	Horaria, entre 15 y 16 días según el modelo.	Temperatura, temperatura aparente, humedad, presión, viento, nubosidad, precipitación y radiación solar.
The Weather Channel	Notebook en Fabric.	Diaria, con partes día y noche, hasta 15 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.
SMN	Activo de Dagster en el servidor local.	Diaria, con franjas de mañana y tarde, hasta 7 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.

Para Open-Meteo se utilizó la API de corridas individuales (*Single Runs*) [28], que devuelve el horizonte completo de una inicialización específica de cada modelo. Se adoptó la corrida de las 00 UTC (*Coordinated Universal Time*), que se publica durante la madrugada en Argentina y queda disponible antes del cálculo diario. La API de pronósticos históricos (*Historical Forecast*) de Open-Meteo [29] no resulta adecuada para este fin porque entrega una combinación de distintas corridas, lo que no permite contar con la misma información que se utilizará en producción.

Los modelos, sus horizontes y sus períodos de vigencia se leen de una tabla del warehouse llamada `PRONOS.PRONOS_TOTALES`, y las consultas se realizan por las coordenadas de las estaciones vigentes en cada fecha de cálculo. El notebook

Fuentes e ingesta en capa 1

La tabla 3.1 resume las fuentes incorporadas y el proceso que obtiene cada una.

TABLA 3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline.

Fuente	Proceso de ingesta	Resolución y horizonte	Variables principales
Open-Meteo (modelos IFS [30], ICON [31], GFS [32] y UKMO [33])	Notebook en Fabric.	Horaria, entre 15 y 16 días según el modelo.	Temperatura, temperatura aparente, humedad, presión, viento, nubosidad, precipitación y radiación solar.
The Weather Channel	Notebook en Fabric.	Diaria, con partes día y noche, hasta 15 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.
SMN	Activo de Dagster en el servidor local.	Diaria, con franjas de mañana y tarde, hasta 7 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.

Para Open-Meteo se utilizó la API de ejecuciones individuales (*Single Runs*) [34], que devuelve el horizonte completo de una inicialización específica de cada modelo. Se adoptó la ejecución de las 00 UTC (*Coordinated Universal Time*), que se publica durante la madrugada en Argentina y queda disponible antes del cálculo diario. La API de pronósticos históricos (*Historical Forecast*) de Open-Meteo [35] no resulta adecuada para este fin porque entrega una combinación de distintas ejecuciones, lo que no permite contar con la misma información que se utilizará en producción.

Los modelos, sus horizontes y sus períodos de vigencia se leen de una tabla del warehouse llamada `PRONOS.PRONOS_TOTALES`, y las consultas se realizan por las coordenadas de las estaciones vigentes en cada fecha de cálculo. El notebook de Open-Meteo recibe un rango de fechas, procesa cada ejecución de manera independiente y convierte las estampas de tiempo a hora local, con el mismo criterio aplicado a los datos observados.

The Weather Channel (TWC) y el SMN solo publican el pronóstico vigente, por lo que su historia se construye a partir de la ejecución diaria. El SMN se consulta desde el servidor local mediante Dagster, por las restricciones de acceso descritas en el capítulo 2. Los resultados de todas las fuentes se almacenan en la base KQL, en una tabla de capa 1 por fuente.

Reconstrucción de la historia de pronósticos

El período de tiempo establecido para el conjunto de datos de test se fijó desde el 01/09/2025 hasta el 31/08/2026, con el objetivo de poder evaluar el desempeño de los modelos en todas las estaciones del año.

Sin embargo, no todas las fuentes tienen este período disponible. Open-Meteo conserva las ejecuciones del modelo IFS desde marzo de 2024 y las del resto de

de Open-Meteo recibe un rango de fechas, procesa cada corrida de manera independiente y convierte las estampas de tiempo a hora local, con el mismo criterio aplicado a los datos observados.

The Weather Channel (TWC) y el SMN solo publican el pronóstico vigente, por lo que su historia se construye a partir de la ejecución diaria. El SMN se consulta desde el servidor local mediante Dagster, por las restricciones de acceso descritas en el capítulo 2. Los resultados de todas las fuentes se almacenan en la base KQL, en una tabla de capa 1 por fuente.

Reconstrucción de la historia de pronósticos

El período de tiempo establecido para el conjunto de datos de test se fijó desde el 01/09/2025 hasta el 31/08/2026, con el objetivo de poder evaluar el desempeño de los modelos en todas las estaciones del año.

Sin embargo, no todas las fuentes tienen este período disponible. Open-Meteo conserva las corridas del modelo IFS desde marzo de 2024 y las del resto de los modelos desde abril de 2026, mientras que el SMN y TWC no permiten recuperar pronósticos pasados. Para cubrir el período faltante se utilizaron archivos acumulados por un proceso previo de CAMMESA, con el que se completó la historia del SMN, TWC y el modelo ICON. Por lo tanto, para los modelos GFS y UKMO la fecha inicial quedó en abril de 2026. Los datos se cargaron en las tablas de capa 1 mediante un proceso implementado en un notebook de Fabric que los recuperó y acondicionó para almacenarlos con el mismo formato.

Los archivos del proceso previo están organizados por región eléctrica y no por estación. Cada región se asoció con una estación meteorológica: para el SMN y TWC, a partir de la localidad consultada; para el modelo ICON, mediante la estación cuya serie de Open-Meteo presentó menor diferencia con la serie del archivo en los períodos que se contaba con ambos pronósticos.

Transformación a capa 2 y orquestación

La capa 2 de pronósticos se compone de dos tablas del esquema `PRONOS`. La tabla horaria `L2_VALORES_HORARIOS_PRONOS` contiene los valores de Open-Meteo con la convención horaria utilizada en CAMMESA y la anticipación en días. La tabla diaria `L2_VALORES_DIARIOS_PRONOS` integra las tres fuentes con las mismas variables que la tabla diaria de observaciones. Para Open-Meteo, los valores diarios se agregan a partir de los horarios con los criterios de los datos observados y solo se conservan los días con las 24 horas disponibles. Para TWC y el SMN, los valores informados por franjas se asignan a las horas de referencia más próximas: el día y la noche a las 15 y 21 horas, y la mañana y la tarde a las 8 y 15 horas. Esta asignación constituye una aproximación, dado que dichos valores representan un intervalo y no una hora puntual. Las variables que una fuente no provee quedan sin valor.

La orquestación se implementó en el pipeline `PPLN_PRONOS`, que se presenta en la figura 3.7. El pipeline recibe un período de fechas de cálculo y, en la ejecución diaria, procesa la fecha en curso. En primer lugar, ejecuta en paralelo los notebooks de Open-Meteo y TWC, junto con un notebook que verifica la carga del SMN realizada por Dagster. Esta validación espera hasta una hora a que estén disponibles todas las estaciones vigentes. Luego, cada tabla de capa 2 se actualiza

los modelos desde abril de 2026, mientras que el SMN y TWC no permiten recuperar pronósticos pasados. Para cubrir el período faltante se utilizaron archivos acumulados por un proceso previo de CAMMESA, con el que se completó la historia del SMN, TWC y el modelo ICON. Por lo tanto, para los modelos GFS y UKMO la fecha inicial quedó en abril de 2026. Los datos se cargaron en las tablas de capa 1 mediante un proceso implementado en un notebook de Fabric que los recuperó y acondicionó para almacenarlos con el mismo formato.

Los archivos del proceso previo están organizados por región eléctrica y no por estación. Cada región se asoció con una estación meteorológica: para el SMN y TWC, a partir de la localidad consultada; para el modelo ICON, mediante la estación cuya serie de Open-Meteo presentó menor diferencia con la serie del archivo en los períodos que se contaba con ambos pronósticos.

Transformación a capa 2 y orquestación

La capa 2 de pronósticos se compone de dos tablas del esquema `PRONOS`. La tabla horaria `L2_VALORES_HORARIOS_PRONOS` contiene los valores de Open-Meteo con la convención horaria utilizada en CAMMESA y la anticipación en días. La tabla diaria `L2_VALORES_DIARIOS_PRONOS` integra las tres fuentes con las mismas variables que la tabla diaria de observaciones. Para Open-Meteo, los valores diarios se agregan a partir de los horarios con los criterios de los datos observados y solo se conservan los días con las 24 horas disponibles. Para TWC y el SMN, los valores informados por franjas se asignan a las horas de referencia más próximas: el día a las 15 y la noche a las 21 horas, y la mañana y la tarde a las 8 y 15 horas, respectivamente. Esta asignación constituye una aproximación, dado que dichos valores representan un intervalo y no una hora puntual. Las variables que una fuente no provee quedan sin valor.

La orquestación se implementó en el pipeline `PPLN_PRONOS`, que se presenta en la figura 3.7. El pipeline recibe un período de fechas de cálculo y, en la ejecución diaria, procesa la fecha en curso. En primer lugar, ejecuta en paralelo los notebooks de Open-Meteo y TWC, junto con un notebook que verifica la carga del SMN realizada por Dagster. Esta validación espera hasta una hora a que estén disponibles todas las estaciones vigentes. Luego, cada tabla de capa 2 se actualiza mediante la eliminación del período a insertar (para evitar duplicación de datos) y una actividad de copia desde la base KQL (capa 1). Si el pronóstico del SMN no se completa, la tabla diaria se actualiza igualmente con las fuentes restantes y la ejecución finaliza con error para advertir el faltante. Como todas las cargas son idempotentes por fecha de cálculo, basta con repetir la ejecución para ese día una vez resuelto el problema.

mediante la eliminación del período a insertar (para evitar duplicación de datos) y una actividad de copia desde la base KQL (capa 1). Si el pronóstico del SMN no se completa, la tabla diaria se actualiza igualmente con las fuentes restantes y la ejecución finaliza con error para advertir el faltante. Como todas las cargas son idempotentes por fecha de cálculo, basta con repetir la ejecución para ese día una vez resuelto el problema.

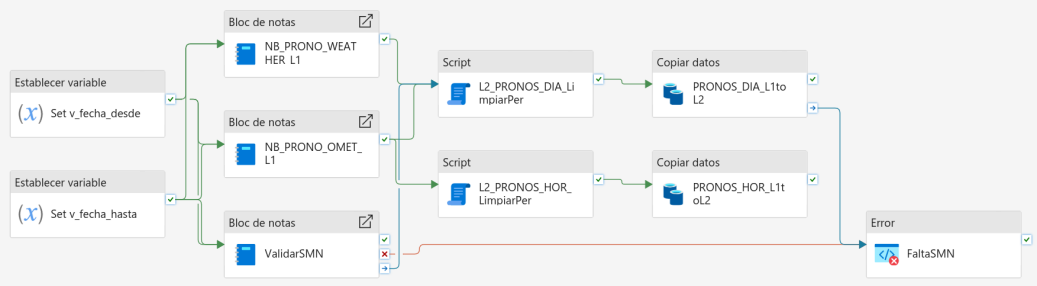


FIGURA 3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos.

De esta manera, el flujo deja disponibles los pronósticos de cuatro modelos numéricos y dos servicios meteorológicos con una estructura común y con definiciones de variables compatibles con las observaciones. Sobre esta base se construyen las variables exógenas de los modelos descritos en las secciones siguientes.

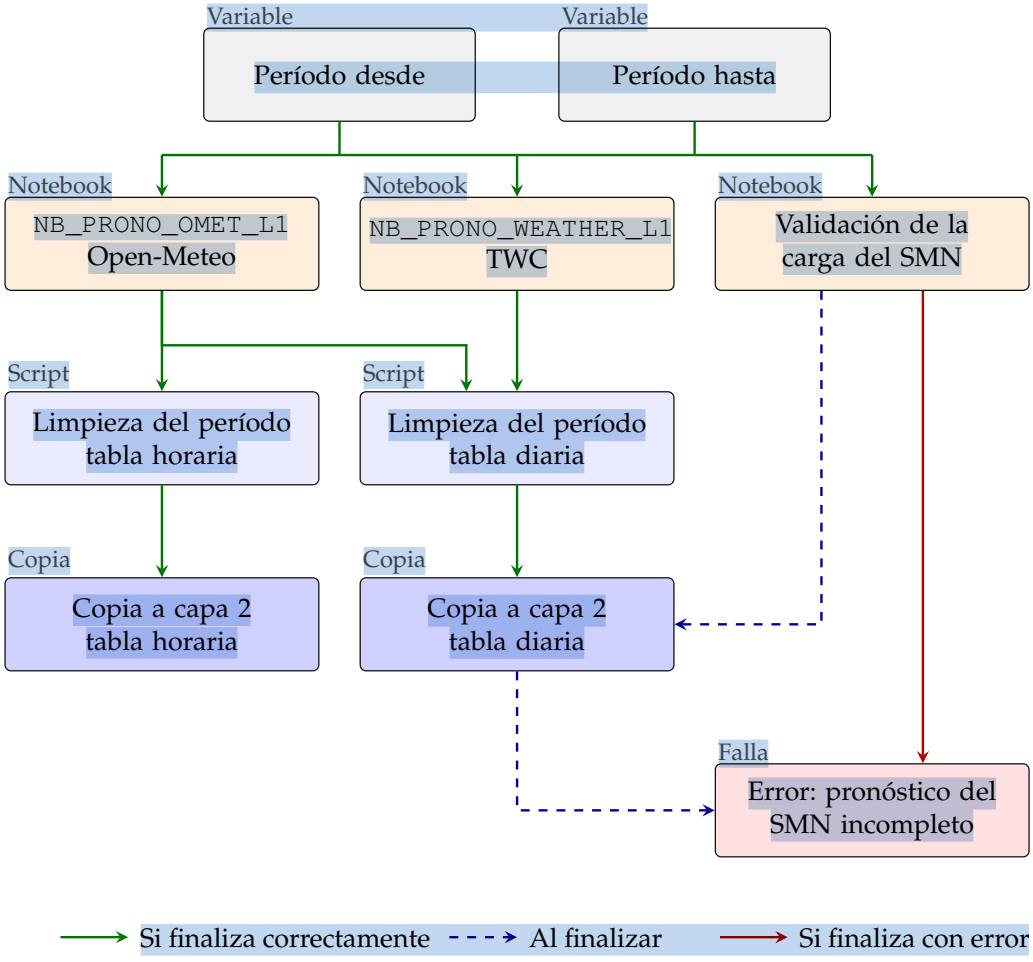


FIGURA 3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos.

De esta manera, el flujo deja disponibles los pronósticos de cuatro modelos numéricos y dos servicios meteorológicos con una estructura común y con definiciones de variables compatibles con las observaciones. Sobre esta base se construyen las variables exógenas de los modelos descritos en las secciones siguientes.

3.2. Desarrollo de modelos

El desarrollo de los modelos tuvo como objetivo obtener pronósticos de la energía diaria (EN) y de las potencias pico (PI) y mínima (MI) para cada región eléctrica, con un horizonte de 14 días. Se organizó en dos etapas. En la primera se seleccionó un modelo de referencia (baseline) entre algoritmos clásicos de aprendizaje automático. En la segunda se desarrollaron modelos de aprendizaje profundo, modelos fundacionales y ensambles, que se compararon con el baseline bajo un mismo procedimiento de validación. Todos los modelos se implementaron con la biblioteca Darts [13], que ofrece una interfaz común para algoritmos clásicos y redes neuronales, admite el entrenamiento sobre múltiples series y la incorporación de covariables.

Ambas etapas comparten la formulación del problema. En cada fecha de cálculo D se dispone de la demanda observada hasta el día $D - 1$, ya que el día en

Bibliografía

[1] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: 10.48550/arXiv.2509.19374. arXiv: 2509.19374 [eess.SP]. URL: https://arxiv.org/abs/2509.19374.

[2] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: 10.1016/j.aei.2026.104419. URL: https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/.

[3] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: 10.3390/en13061407. URL: https://doi.org/10.3390/en13061407.

[4] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: 10.3390/en16217444. URL: https://doi.org/10.3390/en16217444.

[5] Boris N. Oreshkin et al. «N-BEATS Neural Network for Mid-Term Electricity Load Forecasting». En: *Applied Energy* 293 (2021), pág. 116918. DOI: 10.1016/j.apenergy.2021.116918.

[6] Cristian Challu et al. «N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6. 2023, págs. 6989-6997. DOI: 10.1609/aaai.v37i6.25854. URL: https://doi.org/10.1609/aaai.v37i6.25854.

[7] Yuqi Nie et al. «A Time Series Is Worth 64 Words: Long-Term Forecasting with Transformers». En: *International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=Jbdc0vTOcol.

[8] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: 10.1109/ACCESS.2025.3648056.

[9] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks (visitado 12-09-2026).

[10] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: https://microsoftlearning.github.io/mslearn-fabric/ (visitado 12-09-2026).

[11] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: https://docs.dagster.io/ (visitado 12-09-2026).

[12] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: https://docs.dagster.io/api/dagster/assets (visitado 12-09-2026).

[13] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: https://piconnect.readthedocs.io/en/main/ (visitado 12-09-2026).

[14] SMN. *Datos Abiertos SMN*. 2026. URL: https://www.smn.gob.ar/descarga-de-datos (visitado 13-09-2026).

curso está incompleto, y se pronostican los días D a $D + 14$, es decir, con anticipaciones de 0 a 14 días. El pronóstico del día D se incluye porque, en los modelos recursivos, constituye la entrada del pronóstico del día siguiente. Las covariables futuras corresponden a la información calendaria, conocida de antemano, y a las variables meteorológicas de cada día pronosticado.

El entrenamiento utiliza la meteorología observada, mientras que para predecir se utilizan las covariables pronosticadas de cada modelo meteorológico emitida en la fecha de cálculo, según la estructura descrita en la sección 3.1.4. De este modo, cada pronóstico de demanda se genera con la información que habría estado disponible en ese momento, con el objetivo de reproducir lo que sucede en producción. Adicionalmente, se generan pronósticos con la meteorología observada como escenario de referencia, lo que permite distinguir el error atribuible al modelo de demanda del error introducido por el pronóstico meteorológico. Cuando una fuente cubre un horizonte menor que 14 días, como el SMN, solo se evalúan las anticipaciones disponibles.

La evaluación se realizó mediante un esquema de origen móvil con reentrenamiento periódico y ventana de entrenamiento creciente, sobre el período de prueba comprendido entre el 01/09/2025 y el 31/08/2026. En cada fecha de reentrenamiento R, el modelo se entrena con los datos disponibles hasta $R - 1$ y genera los pronósticos de todas las fechas de cálculo comprendidas hasta el siguiente reentrenamiento, utilizando la demanda observada hasta el día anterior. La figura 3.8 ilustra el procedimiento.

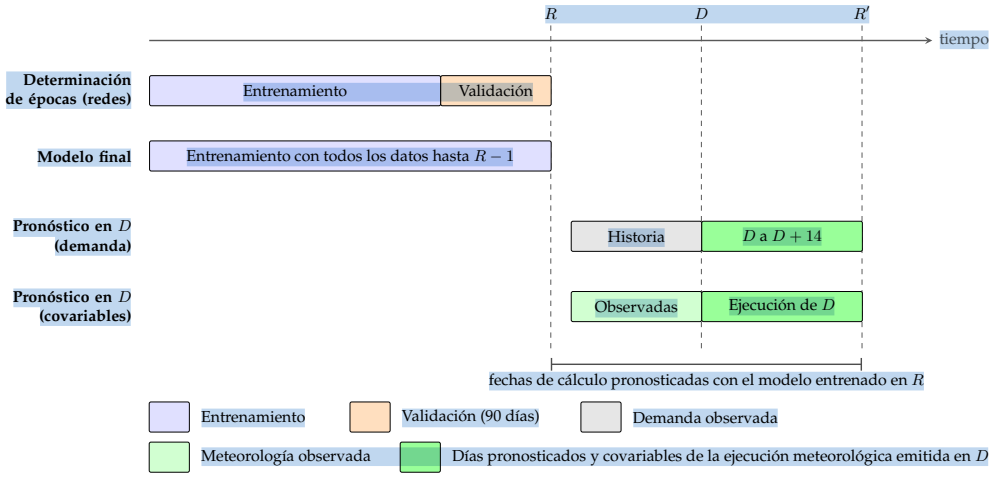


FIGURA 3.8. Esquema de validación con origen móvil: reentrenamiento en la fecha R y pronóstico de una fecha de cálculo D hasta el reentrenamiento siguiente R'.

3.2.1. Selección del modelo de referencia

El modelo de referencia cumple dos funciones: establecer el nivel de desempeño que deben superar los modelos más complejos y servir como alternativa productiva de bajo costo computacional. Se evaluaron cuatro algoritmos: regresión lineal (RLIN), Random Forest (RF) [36], XGBoost (XGB) [37] y LightGBM (LGBM) [38]. Como referencia mínima se incorporó un modelo ingenuo estacional semanal (SNAIVE), que repite los valores de la última semana observada.

Se entrenó un modelo por algoritmo, variable objetivo y región, identificado como `{MODELO}_{TARGET}_{REGION}`, por ejemplo `LGBM_EN_GBA`. Los modelos aplican una estrategia recursiva: predicen un día por vez a partir de los rezagos de 1, 2, 7 y 14 días de la variable objetivo y de las covariables del día pronosticado, y cada predicción se utiliza como rezago para el día siguiente. Esta estrategia permite emplear un único modelo para todo el horizonte y aprovechar la información más reciente, aunque el error se acumula a medida que aumenta la anticipación. Se utilizaron los hiperparámetros por defecto de cada biblioteca, ya que el propósito de esta etapa fue establecer una referencia y no optimizar cada algoritmo.

Las covariables se organizaron en cinco grupos de complejidad creciente, presentados en la tabla 3.2. Todos los grupos incluyen variables calendarias y el cuadrado de la temperatura, necesario para que la regresión lineal represente la relación no lineal entre temperatura y demanda: el consumo aumenta tanto con el frío como con el calor. Los dos primeros grupos difieren en la codificación del tipo de día. La codificación simple distingue días hábiles, sábados y domingos o feriados, mientras que la completa incluye una variable indicadora por día de la semana y el indicador de feriado, que toma valores fraccionarios en las jornadas de actividad reducida. El mes se representa mediante su seno y coseno, para preservar la continuidad entre diciembre y enero.

TABLA 3.2. Grupos de covariables evaluados en la selección del modelo de referencia.

Grupo	Calendario	Variables meteorológicas
G1	Codificación simple y mes.	Temperatura media y su cuadrado.
G2	Codificación completa y mes.	Temperatura media y su cuadrado.
G3	Codificación completa y mes.	Temperaturas máxima y mínima y sus cuadrados.
G4	Codificación completa y mes.	Temperaturas aparentes máxima, mínima y media, y sus cuadrados.
G5	Codificación completa y mes.	Variables de G4, humedad relativa y velocidad del viento a las 15 horas, nubosidad media y radiación solar acumulada.

Los grupos G1 a G3 utilizan variables que informan todas las fuentes de pronóstico. Los grupos G4 y G5, en cambio, requieren temperatura aparente, nubosidad y radiación, que solo proveen los modelos numéricos obtenidos de Open-Meteo. Por este motivo, se consideró que una fuente puede alimentar un grupo cuando informa sus variables en al menos el 95 % de los registros, y cada fuente se evaluó únicamente con los grupos que satisface.

La selección se realizó en dos fases. En la primera se eligió el grupo de covariables de cada modelo mediante validación con origen móvil entre el 01/09/2024 y el 31/08/2025, con meteorología observada y reentrenamiento mensual. Las fechas de cálculo se limitaron de modo que todos los días pronosticados quedaran dentro de ese período, por lo que el conjunto de prueba no intervino en la elección. Para cada algoritmo, variable objetivo y región se adoptó el grupo con menor MAPE promedio sobre las 15 anticipaciones. En la segunda fase, los modelos se entrenaron con datos hasta el 31/08/2025 y se evaluaron sobre el período de prueba con reentrenamiento semanal, tanto con la meteorología observada como con los pronósticos de cada fuente. Cuando el mejor grupo requería variables

que una fuente no provee, se utilizó para esa fuente el siguiente grupo del orden obtenido en la primera fase.

Dentro de cada escenario meteorológico, los modelos se compararon sobre el mismo conjunto de regiones, fechas de cálculo y anticipaciones, para evitar que las diferencias de cobertura entre fuentes afectaran la comparación. A partir de esta evaluación se seleccionó LightGBM como modelo de referencia para la etapa siguiente. Los resultados que fundamentan esta elección se presentan en el capítulo 4.

3.2.2. Modelos de aprendizaje profundo y fundacionales

La segunda etapa evaluó si arquitecturas más recientes mejoran el pronóstico respecto del modelo de referencia. Se consideraron redes recurrentes, arquitecturas diseñadas para el pronóstico directo de múltiples pasos, un modelo fundacional y ensambles de modelos. La tabla 3.3 resume los modelos implementados y sus principales hiperparámetros.

TABLA 3.3. Modelos de aprendizaje profundo y fundacionales implementados.

Modelo	**Arquitectura**	**Estrategia**	**Hiperparámetros principales**
LSTM [39]	Red recurrente con celdas LSTM.	Recursiva, día a día.	2 capas de 64 unidades; *dropout* 0,1.
GRU [40]	Red recurrente con celdas GRU.	Recursiva, día a día.	2 capas de 64 unidades; *dropout* 0,1.
TFT [8]	Codificador recurrente con atención multicabezal y selección de variables.	Directa, 15 días.	Dimensión oculta 32; 4 cabezales de atención; *dropout* 0,1.
TiDE [9]	Codificador y decodificador basados en perceptrones multicapa.	Directa, 15 días.	Dimensión oculta 128; *dropout* 0,1.
TSMixer [10]	Perceptrones multicapa que mezclan las dimensiones temporal y de variables.	Directa, 15 días.	2 bloques; dimensión oculta 64; *dropout* 0,1.
Chronos-2 [23]	Modelo fundacional basado en Transformers, con atención grupal entre la serie y sus covariables.	Directa, 15 días.	Contexto de 512 días; sin ajuste y con ajuste mediante LoRA.

La selección de arquitecturas priorizó aquellas que admiten covariables futuras, dado que la información calendaria y el pronóstico meteorológico de los días pronosticados constituyen los principales determinantes de la demanda. Por este motivo, se descartaron las arquitecturas que en Darts solo admiten covariables pasadas, y se incluyeron modelos de tres familias: redes recurrentes, arquitecturas basadas en atención y arquitecturas basadas en perceptrones multicapa.

A diferencia del modelo de referencia, los modelos neuronales se entrenaron de forma global para cada variable objetivo: un mismo modelo aprende de las diez regiones, que se identifican mediante una covariable estática con codificación *one-hot*. En LSTM y GRU, que no admiten covariables estáticas, esa codificación se incorporó como covariables futuras constantes. El entrenamiento global multiplica

la cantidad de ejemplos disponibles para cada modelo y permite compartir patrones comunes entre regiones, lo que resulta relevante para redes con un número de parámetros mucho mayor que el de los modelos basados en árboles.

Se utilizó el grupo de covariables G5, que reúne la caracterización meteorológica más completa y resultó el grupo con mejor desempeño en la primera fase de la selección del modelo de referencia. Dado que sus variables solo están disponibles en los modelos de Open-Meteo, la evaluación con pronósticos se realizó con los modelos IFS e ICON, además del escenario de meteorología observada. La variable objetivo y las covariables se estandarizaron por región con la media y el desvío del período de entrenamiento de cada reentrenamiento.

Los modelos reciben una ventana de 56 días, equivalente a ocho semanas, y las covariables de esa ventana y de los días pronosticados. TFT, TiDE y TSMixer generan los 15 días en un único paso. LSTM y GRU se implementaron con una formulación recursiva, en la que la red recorre la historia hasta $D - 1$ y avanza un día por vez con las covariables del día pronosticado y su propia predicción del día anterior. Esta formulación garantiza que el estado de la red incorpore la demanda más reciente en todas las anticipaciones.

El entrenamiento utilizó la pérdida L1, el optimizador Adam con una tasa de aprendizaje de 10^{-3}, lotes de 64 ejemplos y semillas fijas. En cada reentrenamiento mensual se aplicó un procedimiento en dos pasos. En el primero, el modelo se entrenó con los datos disponibles hasta 90 días antes de la fecha de reentrenamiento, con detención temprana (*early stopping*) sobre esos 90 días, una paciencia de 5 épocas y un máximo de 50, y se registró la época con menor error de validación. En el segundo, se entrenó un modelo nuevo con todos los datos hasta el día anterior al reentrenamiento durante esa cantidad de épocas. De este modo, la validación regula la extensión del entrenamiento sin excluir del modelo final la información más reciente, del mismo modo que en el modelo de referencia.

Chronos-2 es un modelo fundacional de 120 millones de parámetros que procesa la serie objetivo y sus covariables mediante un mecanismo de atención grupal, sin requerir entrenamiento específico [23]. Se evaluó en dos variantes. La primera lo utiliza sin ajuste (*zero-shot*) a través de Darts, con un contexto de 512 días y las mismas covariables que el resto de los modelos. La segunda lo ajusta en cada reentrenamiento mensual con los datos disponibles hasta el día anterior, mediante la biblioteca oficial del modelo, ya que Darts no admite su ajuste. Se aplicó LoRA (*Low-Rank Adaptation*) [41], que entrena matrices de bajo rango agregadas a las capas del modelo y mantiene fijos los pesos preentrenados. El ajuste se realizó con 500 pasos de optimización, una tasa de aprendizaje de 10^{-5} y las covariables declaradas como conocidas a futuro, partiendo en cada mes del modelo preentrenado.

Para que la comparación con el modelo de referencia dependiera únicamente del modelo, LightGBM se volvió a evaluar bajo el mismo protocolo, con el grupo G5 y reentrenamiento mensual. Sobre las predicciones de los modelos individuales se construyeron dos ensambles, que combinan LightGBM, TFT y TSMixer, es decir, un modelo basado en árboles, uno basado en atención y uno basado en perceptrones multicapa. El primero promedia sus predicciones. El segundo aplica un metamodelo de regresión lineal con pesos no negativos y sin término independiente, ajustado por variable objetivo, escenario y anticipación. En cada mes, el

metamodelo se ajusta solo con las predicciones de los meses anteriores cuyo valor real ya se conocía, por lo que no utiliza información futura. Las observaciones se ponderan por la inversa del cuadrado del valor real, de modo que el ajuste minimiza el error relativo, coherente con el MAPE.

Los modelos neuronales se entrenaron en Google Colab con aceleración por GPU, a partir de una copia de los datos del warehouse exportada mediante un script de consulta. Las predicciones de cada modelo y variable objetivo se almacenaron a medida que se generaban, lo que permitió retomar las ejecuciones interrumpidas sin repetir cálculos y conservar un registro de las épocas y los tiempos de entrenamiento. La elección del modelo o los modelos productivos se basa en la comparación presentada en el capítulo 4, que considera el error por variable objetivo, región y anticipación, y el comportamiento en los días de alta demanda.

3.3. Integración y puesta en producción

La puesta en producción integra el pipeline de datos y los modelos seleccionados en un proceso automático que genera diariamente los pronósticos de demanda, los almacena junto con la información necesaria para su trazabilidad y calcula sus métricas a medida que se dispone de los valores reales. La solución se implementó íntegramente sobre Microsoft Fabric y reutiliza los criterios aplicados en el pipeline de datos: procesos parametrizados por fecha, cargas idempotentes y validaciones previas a la escritura.

3.3.1. Arquitectura de ejecución

La figura 3.9 presenta los componentes del sistema en producción. El proceso diario se orquesta mediante el pipeline `PPLN_MODELOS`, que se ejecuta una vez finalizada la carga de pronósticos meteorológicos de `PPLN_PRONOS`. El reentrenamiento se orquesta en un pipeline independiente, `PPLN_REENTRENO`, con frecuencia semanal. Ambos procesos leen las vistas de capa 3 de los esquemas `DEMANDA`, `METEO` y `PRONOS`, de modo que los modelos consumen en producción los mismos datos que se utilizaron durante el desarrollo.

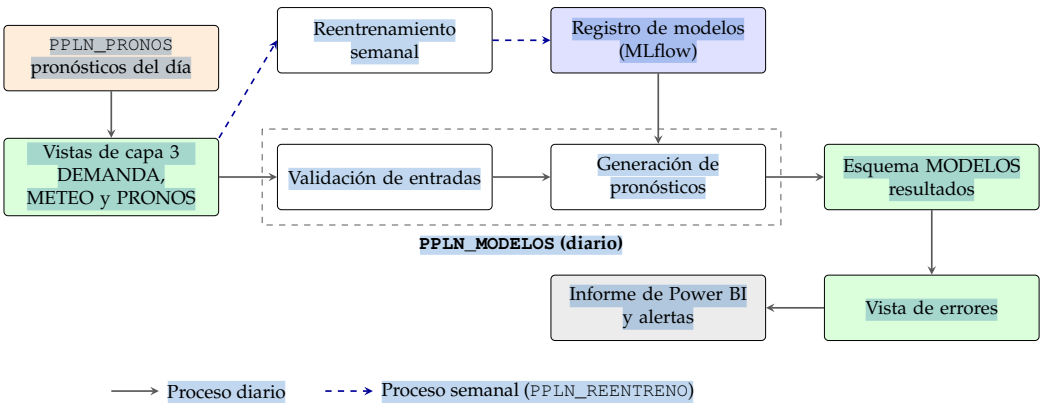


FIGURA 3.9. Arquitectura del sistema de pronóstico en producción.

La construcción de las series de entrada y de las covariables se encapsuló en un módulo de Python compartido por los notebooks de desarrollo, de reentrenamiento y de generación de pronósticos. De esta forma, las transformaciones aplicadas en producción coinciden exactamente con las utilizadas durante la evaluación, y se evita que el modelo reciba variables con definiciones o escalas distintas de las del entrenamiento.

3.3.2. Generación diaria de pronósticos

El pipeline diario comienza con un notebook de validación que verifica las condiciones necesarias para pronosticar. Se controla que la demanda del día anterior esté completa, con las 24 horas de todas las regiones, y que la fuente meteorológica principal disponga de la ejecución del día con todas las variables requeridas por los modelos para los 15 días del horizonte. Si la fuente principal no está disponible, se utiliza una fuente alternativa definida para cada modelo y se registra cuál se empleó. Si ninguna fuente cumple las condiciones, la ejecución finaliza con error y no se escriben resultados parciales.

A continuación, el notebook de pronóstico obtiene del registro de modelos la versión vigente de cada modelo productivo y genera, para cada variable objetivo y región, los pronósticos de los días D a $D + 14$ con la demanda observada hasta $D - 1$. Además de la fuente principal, se generan pronósticos con las demás fuentes disponibles, lo que permite comparar en forma continua el efecto de cada pronóstico meteorológico sobre el error de demanda.

Los resultados se escriben en la tabla `MODELOS.RESULTADOS_MODELOS`, con la fecha de cálculo, la fecha pronosticada, la anticipación, el identificador del modelo, la fuente meteorológica utilizada y la versión del modelo. Como en el resto del pipeline, la escritura elimina previamente los registros de la fecha de cálculo procesada, por lo que una ejecución puede repetirse sin generar duplicados.

3.3.3. Reentrenamiento y registro de modelos

El reentrenamiento reproduce el procedimiento aplicado durante el desarrollo. Se ejecuta el primer día de cada mes y entrena cada modelo productivo con todos los datos disponibles hasta el día anterior. En los modelos neuronales se aplica el mismo procedimiento en dos pasos: la cantidad de épocas se determina con detención temprana sobre los últimos 90 días y el modelo final se entrena con la totalidad de los datos.

Cada modelo entrenado se registra en MLflow junto con sus hiperparámetros, el período de datos utilizado, la cantidad de épocas y el error obtenido sobre el último mes. La nueva versión reemplaza a la vigente solo si su error en ese período no supera al de la versión anterior en más de un margen establecido. En caso contrario, se mantiene la versión vigente y se emite una notificación para su revisión. Dado que cada pronóstico almacenado incluye la versión del modelo que lo generó, es posible reconstruir en cualquier momento qué modelo y qué datos produjeron un valor determinado.

3.3.4. Monitoreo del desempeño

La vista `MODELOS.ERRORES_MODELOS` vincula cada pronóstico con el valor real de la variable objetivo, a partir de la vista `DEMANDAS_DIARIA_REGIONES` del

esquema `DEMANDA`, y calcula el error, el error absoluto y el error porcentual absoluto. Los valores se incorporan automáticamente a medida que se completa la demanda de cada día, de modo que las métricas se actualizan sin intervención manual.

Sobre esta vista se construyó un informe de Power BI que presenta el MAE, el RMSE y el MAPE en ventanas móviles, desagregados por modelo, variable objetivo, región, anticipación y fuente meteorológica. El informe permite comparar el desempeño reciente con el obtenido en la evaluación del capítulo 4, seguir el comportamiento de los modelos en los días de alta demanda y analizar períodos particulares, como olas de calor o feriados.

Capítulo 4

Ensayos y resultados

A desarrollar.

Apéndice A

Modelo de datos del warehouse

En este apéndice se describen las tablas y vistas del warehouse `WH_PSYD` que intervienen en el pipeline de datos presentado en la sección 3.1. Se detallan los esquemas DEMANDA, METEO y PRONOS, junto con las dimensiones que los vinculan. Para cada objeto se indican la capa a la que pertenece, su clave y su contenido. Las variables comunes a varias tablas se describen una única vez.

A.1. Relaciones entre esquemas

Los esquemas se vinculan mediante tres identificadores. `RGE_ID` identifica las regiones eléctricas, definidas en la tabla `REGIONES_ELECTRICAS_TOTALES` del esquema `GENERAL`. Luego, `EMET_ID` identifica las estaciones meteorológicas, y `PRON_ID` identifica los modelos y servicios de pronóstico. Las tablas de dimensiones incluyen períodos de vigencia (`FECHA_DESDE` y `FECHA_HASTA`), por lo que las vistas de capa 3 asocian cada estación con su región según la fecha del dato. La figura A.1 resume estas relaciones.

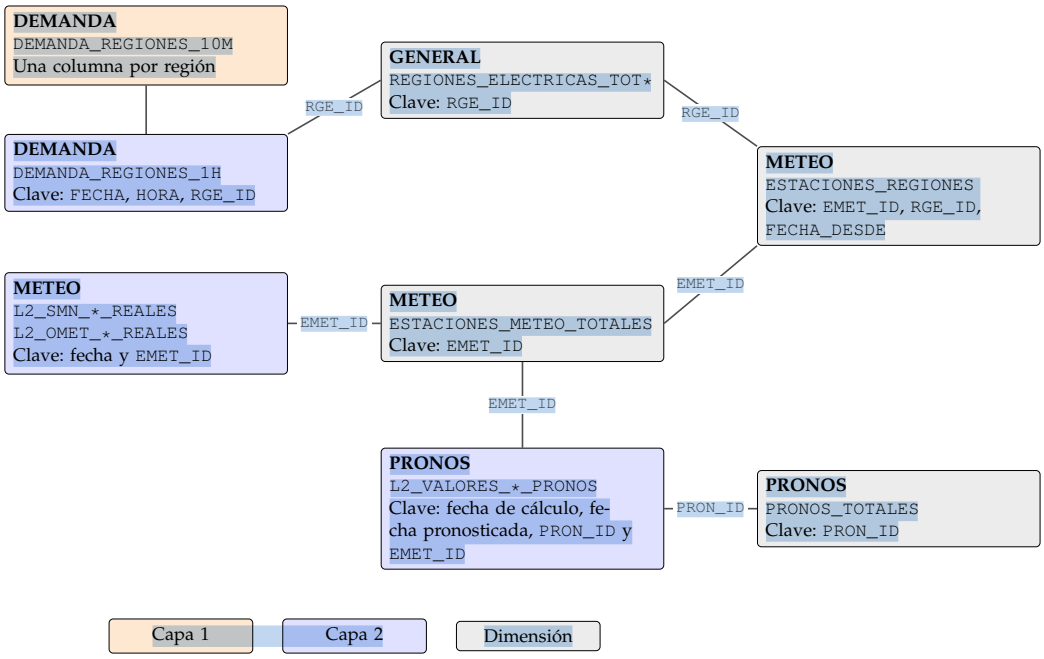


FIGURA A.1. Relaciones entre las tablas principales de los esquemas DEMANDA, METEO y PRONOS.

A.2. Esquema DEMANDA

El esquema DEMANDA contiene la demanda eléctrica calculada a partir del SOTR y las variables objetivo de los modelos. La tabla A.1 describe sus objetos.

TABLA A.1. Tablas y vistas del esquema DEMANDA.

Objeto	Tipo y capa	Clave	Contenido
DEMANDA_REGIONES_10M	Tabla, capa 1	FECHA, HORA, INTERVALO	Demanda en MW cada diez minutos, en formato ancho, con una columna por región y otra para el MEM, junto con las variables de control del cálculo.
DEMANDA_REGIONES_1H	Tabla, capa 2	FECHA, HORA, RGE_ID	Demanda horaria depurada por región, con el valor original anterior a la limpieza y la marca de corrección.
DEMANDAS_MEM	Vista, capa 3	FECHA, TARGET_ID_ASOCIADO	Variables objetivo diarias del MEM: energía (1), potencia máxima entre las 6 y las 24 horas (2) y potencia mínima entre las 0 y las 12 horas (3).

La tabla A.2 detalla las columnas de las dos tablas del esquema.

TABLA A.2. Columnas de las tablas del esquema DEMANDA.

Columna	Descripción
Tabla DEMANDA_REGIONES_10M	
FECHA, HORA, INTERVALO	Fecha, hora e intervalo de diez minutos de la medición.
MEM	Demanda del MEM, calculada como suma de las regiones, en MW.
GBA, CEN, LIT, CUY, NEA, NOA, COM, PBN, PBS, PAT	Demanda de cada región eléctrica corregida por pérdidas, en MW.
CHK_MEM_TAG, CHK_MEM_DIF, CHK_MEM_DIF_PORC	Medidor nacional de referencia y diferencias absoluta y porcentual respecto del MEM calculado.
CHK_PBA, CHK_PBN_TAG, CHK_PBS_TAG, CHK_PBA_PARTICION, CHK_DIF_PBN, CHK_DIF_PBS, CHK_DIF_PBN_PORC, CHK_DIF_PBS_PORC	Controles de la partición de PBA: demanda original de la región, mediciones directas de PBN y PBS y diferencias absolutas y porcentuales asociadas con la partición.
CHK_INTERCAMBIOS	Suma de los intercambios entre regiones, que debe permanecer próxima a cero.
Tabla DEMANDA_REGIONES_1H	
FECHA, HORA	Fecha y hora, con la convención horaria de CAMMESA (1 a 24).
RGE_ID	Identificador de la región eléctrica.
VALOR	Demanda horaria depurada, en MW.
VALOR_ORIGINAL	Demanda horaria calculada con los datos anteriores a la limpieza, en MW.
FLAG_CORREGIDO	Indica si VALOR difiere de VALOR_ORIGINAL.

A.3. Esquema METEO

El esquema METEO contiene las estaciones meteorológicas, su asociación con las regiones eléctricas y los datos observados del SMN y de Open-Meteo. La tabla A.3 describe sus objetos. Las tablas de capa 2 se separan por fuente y por resolución, mientras que las vistas de capa 3 integran ambas fuentes: para cada variable toman el valor del SMN y, si no está disponible, el de Open-Meteo.

TABLA A.3. Tablas y vistas del esquema METEO.

Objeto	Tipo y capa	Clave	Contenido
ESTACIONES_METEO_TOTALES	Dimensión	EMET_ID	Estaciones meteorológicas: nombre, código OACI, provincia, región y prioridad dentro de ella, coordenadas, altura, localidad del SMN y vigencia.
ESTACIONES_REGIONES	Dimensión	EMET_ID, RGE_ID	Estación representativa de cada región eléctrica y su período de vigencia.
L2_SMN_VALORES_HORARIOS_REALES	Tabla, capa 2	FECHA_HORA, EMET_ID	Observaciones horarias del SMN y temperatura aparente calculada.
L2_SMN_VALORES_DIARIOS_REALES	Tabla, capa 2	FECHA, EMET_ID	Valores diarios del SMN, sin nubosidad, precipitación ni radiación.
L2_OMET_VALORES_HORARIOS_REALES	Tabla, capa 2	FECHA_HORA, EMET_ID	Valores horarios de Open-Meteo para las coordenadas de cada estación.
L2_OMET_VALORES_DIARIOS_REALES	Tabla, capa 2	FECHA, EMET_ID	Valores diarios de Open-Meteo para las coordenadas de cada estación.
L3_METEO_VALORES_HORARIOS_REALES	Vista, capa 3	FECHA_HORA, EMET_ID	Valores horarios por estación que integran ambas fuentes.
L3_METEO_VALORES_DIARIOS_REALES	Vista, capa 3	FECHA, EMET_ID	Valores diarios por estación que integran ambas fuentes.
L3_METEO_VALORES_HORARIOS_REALES_REGIONES	Vista, capa 3	FECHA_HORA, RGE_ID	Valores horarios de la estación vigente para cada región eléctrica.
L3_METEO_VALORES_DIARIOS_REALES_REGIONES	Vista, capa 3	FECHA, RGE_ID	Valores diarios de la estación vigente para cada región eléctrica.

Las tablas A.4 y A.5 describen las variables meteorológicas horarias y diarias. Son las mismas en las tablas de datos observados y en las de pronósticos. Cada tabla contiene solo las variables que su fuente provee. Todas incluyen, además, la columna ULT_FECHA, con la fecha y hora de la última actualización del registro.

TABLA A.4. Variables meteorológicas horarias.

Columna	Unidad	Descripción
FECHA_HORA	–	Fecha y hora local (UTC-3) del valor.
FECHA, HORA	–	Fecha y hora con la convención horaria de CAMMESA (1 a 24).
TEMPERATURA	°C	Temperatura del aire a 2 m de altura.
HUMEDAD_RELATIVA	%	Humedad relativa a 2 m de altura.
PRESION_HPA	hPa	Presión atmosférica.
VIENTO_VEL_KMH	km/h	Velocidad del viento a 10 m de altura.
VIENTO_DIR_GRADOS	°	Dirección del viento.
NUBOSIDAD_PORC	%	Cobertura nubosa total.
TEMPERATURA_APARENTE	°C	Temperatura aparente según la ecuación 3.1. En la tabla del SMN se denomina TEMP_APARENTE_CALC.
PRECIPITACION_MM	mm	Precipitación acumulada en la hora.
RADIACION_SOLAR_GHI_WM2	W/m^2	Radiación solar global media de la hora.

TABLA A.5. Variables meteorológicas diarias.

Columna	Unidad	Descripción
FECHA	–	Fecha del valor.
TEMP_MAX, TEMP_MIN	°C	Temperaturas máxima y mínima del día.
TEMP_MED	°C	Semisuma de las temperaturas máxima y mínima.
TEMP_AVG	°C	Promedio de las temperaturas del día.
TEMP_APARENTE_MAX, TEMP_APARENTE_MIN, TEMP_APARENTE_MED, TEMP_APARENTE_AVG	°C	Valores análogos para la temperatura aparente.
VIENTO_VEL_8HS_KMH, VIENTO_VEL_15HS_KMH, VIENTO_VEL_21HS_KMH	km/h	Velocidad del viento a las 8, 15 y 21 horas.
VIENTO_DIR_8HS_GRADOS, VIENTO_DIR_15HS_GRADOS, VIENTO_DIR_21HS_GRADOS	°	Dirección del viento a las 8, 15 y 21 horas.
HUMEDAD_RELATIVA_15HS	%	Humedad relativa a las 15 horas.
NUBOSIDAD_MEDIA_PORC	%	Cobertura nubosa media del día.
PRECIPITACION_ACUM_MM	mm	Precipitación acumulada en el día.
RADIACION_SOLAR_ACUM_MJ_M2	MJ/m^2	Radiación solar global acumulada en el día.

A.4. Esquema PRONOS

El esquema PRONOS contiene los modelos y servicios de pronóstico meteorológico y los valores pronosticados. La tabla A.6 describe sus objetos. A diferencia del esquema METEO, las tablas de capa 2 integran todas las fuentes y las distinguen mediante PRON_ID. Las vistas de capa 3 presentan los valores por región eléctrica, según la estación vigente en la fecha de cálculo.

TABLA A.6. Tablas y vistas del esquema PRONOS.

Objeto	Tipo y capa	Clave	Contenido
PRONOS_TOTALES	Dimensión	PRON_ID, FECHA_DESDE	Modelos y servicios de pronóstico: servicio, modelo, horizonte en días, descripción, parámetro de consulta a la API y vigencia.
L2_VALORES_HORARIOS_PRONOS	Tabla, capa 2	FECHA_CALCULO, FECHA_HORA_PRONOS, PRON_ID, EMET_ID	Valores horarios pronosticados por los modelos de Open-Meteo.
L2_VALORES_DIARIOS_PRONOS	Tabla, capa 2	FECHA_CALCULO, FECHA_PRONOS, PRON_ID, EMET_ID	Valores diarios pronosticados por Open-Meteo, TWC y el SMN.
L3_VALORES_HORARIOS_PRONOS_REGIONES	Vista, capa 3	FECHA_CALCULO, FECHA_HORA_PRONOS, PRON_ID, RGE_ID	Valores horarios pronosticados para cada región eléctrica.
L3_VALORES_DIARIOS_PRONOS_REGIONES	Vista, capa 3	FECHA_CALCULO, FECHA_PRONOS, PRON_ID, RGE_ID	Valores diarios pronosticados para cada región eléctrica.

Las variables meteorológicas de estas tablas son las descritas en las tablas A.4 y A.5. La tabla A.7 detalla las columnas propias de los pronósticos.

TABLA A.7. Columnas propias de las tablas y vistas del esquema PRONOS.

Columna	Descripción
FECHA_CALCULO	Fecha de la ejecución del modelo o de la consulta al servicio que generó el pronóstico.
FECHA_PRONOS, FECHA_HORA_PRONOS	Fecha, o fecha y hora local, a la que corresponde el valor pronosticado.
ANTICIPACION_DIAS	Diferencia en días entre la fecha pronosticada y la fecha de cálculo.
PRON_ID, MODELO	Identificador y nombre del modelo o servicio de pronóstico.
EMET_ID, NOMBRE_ESTACION	Identificador y nombre de la estación cuyas coordenadas se utilizaron en la consulta.
RGE_ID, RGE_NEMO	Identificador y abreviatura de la región eléctrica (solo en las vistas de capa 3).

Bibliografía

[1] Congreso de la Nación Argentina. *Ley 24.065: Régimen de la energía eléctrica*. Boletín Oficial de la República Argentina, 16 de enero de 1992. https://mepriv.mecon.gob.ar/Normas/24065.htm. Consultado el 5 de octubre de 2026. 1992.

[2] Poder Ejecutivo Nacional. *Decreto 1192/1992: Constitución de la Compañía Administradora del Mercado Mayorista Eléctrico Sociedad Anónima*. https://mepriv.mecon.gob.ar/Normas/1192-92.htm. Consultado el 5 de octubre de 2026. 1992.

[3] CAMMESA. *Empresa*. https://cammesaweb.cammesa.com/empresa/. Consultado el 5 de octubre de 2026.

[4] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: 10.48550/arXiv.2509.19374. arXiv: 2509.19374 [eess.SP]. URL: https://arxiv.org/abs/2509.19374.

[5] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: 10.1016/j.aei.2026.104419. URL: https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/.

[6] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: 10.3390/en13061407. URL: https://doi.org/10.3390/en13061407.

[7] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: 10.3390/en16217444. URL: https://doi.org/10.3390/en16217444.

[8] Bryan Lim et al. «Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting». En: *International Journal of Forecasting* 37.4 (2021), págs. 1748-1764.

[9] Abhimanyu Das et al. «Long-term Forecasting with TiDE: Time-series Dense Encoder». En: *Transactions on Machine Learning Research* (2023).

[10] Si-An Chen et al. «TSMixer: An All-MLP Architecture for Time Series Forecasting». En: *Transactions on Machine Learning Research* (2023).

[11] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: 10.1109/ACCESS.2025.3648056.

[12] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks (visitado 12-09-2026).

[13] Julien Herzen et al. «Darts: User-Friendly Modern Machine Learning for Time Series». En: *Journal of Machine Learning Research* 23.124 (2022), págs. 1-6.

[15] Open-Meteo. *Historical Weather API*. 2026. URL: https://open-meteo.com/en/docs/historical-weather-api (visitado 12-09-2026).

[16] Open-Meteo. *Historical Forecast API*. 2026. URL: https://open-meteo.com/en/docs/historical-forecast-api (visitado 12-09-2026).

[17] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: https://weather.com/es-AR/ar/city/buenos-aires/today (visitado 13-09-2026).

[18] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: https://openreview.net/forum?id=gerNCVqqtR.

[19] Abhimanyu Das et al. «A Decoder-Only Foundation Model for Time-Series Forecasting». En: *Proceedings of the 41st International Conference on Machine Learning*. Vol. 235. Proceedings of Machine Learning Research. PMLR, 2024, págs. 10148-10167. URL: https://proceedings.mlr.press/v235/das24c.html.

[20] Microsoft. *Analyze data in a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with (visitado 12-09-2026).

[21] Microsoft. *Documentación de Data Warehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-warehouse/ (visitado 13-09-2026).

[22] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview (visitado 13-09-2026).

[23] Microsoft. *Documentación de Pipeline*. 2026. URL: https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview (visitado 13-09-2026).

[24] European Centre for Medium-Range Weather Forecasts. *IFS documentation*. https://www.ecmwf.int/en/publications/ifs-documentation. Consultado el 28 de septiembre de 2026.

[25] Günther Zängl et al. «The ICON (ICOsahedral Non-hydrostatic) modelling framework of DWD and MPI-M: Description of the non-hydrostatic dynamical core». En: *Quarterly Journal of the Royal Meteorological Society* 141.687 (2015), págs. 563-579. DOI: 10.1002/qj.2378.

[26] National Centers for Environmental Information. *Global Forecast System (GFS)*. https://www.ncei.noaa.gov/products/weather-climate-models/global-forecast. Consultado el 28 de septiembre de 2026.

[27] David Walters et al. «The Met Office Unified Model Global Atmosphere 7.0/7.1 and JULES Global Land 7.0 configurations». En: *Geoscientific Model Development* 12.5 (2019), págs. 1909-1963. DOI: 10.5194/gmd-12-1909-2019.

[28] Open-Meteo. *Single Runs API*. https://open-meteo.com/en/docs/single-runs-api. Consultado el 28 de septiembre de 2026.

[29] Open-Meteo. *Historical Forecast API*. https://open-meteo.com/en/docs/historical-forecast-api. Consultado el 28 de septiembre de 2026.

[30] Robert G. Steadman. «Norms of apparent temperature in Australia». En: *Australian Meteorological Magazine* 43 (1994), págs. 1-16.

[31] Open-Meteo. *Open-Meteo: código fuente del módulo* `Meteorology.swift`. https://github.com/open-meteo/open-meteo/blob/main/Sources/App/Helper/Meteorology.swift. Consultado el 28 de septiembre de 2026.

[14] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: https://microsoftlearning.github.io/mslearn-fabric/ (visitado 12-09-2026).
[15] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: https://docs.dagster.io/ (visitado 12-09-2026).
[16] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: https://docs.dagster.io/api/dagster/assets (visitado 12-09-2026).
[17] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: https://piconnect.readthedocs.io/en/main/ (visitado 12-09-2026).
[18] SMN. *Datos Abiertos SMN*. 2026. URL: https://www.smn.gob.ar/descarga-de-datos (visitado 13-09-2026).
[19] Open-Meteo. *Historical Weather API*. 2026. URL: https://open-meteo.com/en/docs/historical-weather-api (visitado 12-09-2026).
[20] Open-Meteo. *Historical Forecast API*. 2026. URL: https://open-meteo.com/en/docs/historical-forecast-api (visitado 12-09-2026).
[21] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: https://weather.com/es-AR/ar/city/buenos-aires/today (visitado 13-09-2026).
[22] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: https://openreview.net/forum?id=gerNCVqqtR.
[23] Abdul Fatir Ansari, Oleksandr Shchur, Jaris Küken et al. *Chronos-2: From Univariate to Universal Forecasting*. https://arxiv.org/abs/2510.15821. 2025. arXiv: 2510.15821.
[24] Microsoft. *Analyze data in a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with (visitado 12-09-2026).
[25] Microsoft. *Documentación de Data Warehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-warehouse/ (visitado 13-09-2026).
[26] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview (visitado 13-09-2026).
[27] Microsoft. *Documentación de Pipeline*. 2026. URL: https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview (visitado 13-09-2026).
[28] Robert G. Steadman. «Norms of apparent temperature in Australia». En: *Australian Meteorological Magazine* 43 (1994), págs. 1-16.
[29] Open-Meteo. *Open-Meteo: código fuente del módulo* `Meteorology.swift`. https://github.com/open-meteo/open-meteo/blob/main/Sources/App/Helper/Meteorology.swift. Consultado el 28 de septiembre de 2026.
[30] European Centre for Medium-Range Weather Forecasts. *IFS documentation*. https://www.ecmwf.int/en/publications/ifs-documentation. Consultado el 28 de septiembre de 2026.
[31] Günther Zängl et al. «The ICON (ICOsahedral Non-hydrostatic) modelling framework of DWD and MPI-M: Description of the non-hydrostatic dynamical core». En: *Quarterly Journal of the Royal Meteorological Society* 141.687 (2015), págs. 563-579. DOI: 10.1002/qj.2378.
[32] National Centers for Environmental Information. *Global Forecast System (GFS)*. https://www.ncei.noaa.gov/products/weather-climate-models/global-forecast. Consultado el 28 de septiembre de 2026.
[33] David Walters et al. «The Met Office Unified Model Global Atmosphere 7.0/7.1 and JULES Global Land 7.0 configurations». En: *Geoscientific Model Development* 12.5 (2019), págs. 1909-1963. DOI: 10.5194/gmd-12-1909-2019.
[34] Open-Meteo. *Single Runs API*. https://open-meteo.com/en/docs/single-runs-api. Consultado el 28 de septiembre de 2026.

[35] Open-Meteo. *Historical Forecast API*. https://open-meteo.com/en/docs/historical-forecast-api. Consultado el 28 de septiembre de 2026.

[36] Leo Breiman. «Random Forests». En: *Machine Learning* 45.1 (2001), págs. 5-32.

[37] Tianqi Chen y Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 785-794.

[38] Guolin Ke et al. «LightGBM: A Highly Efficient Gradient Boosting Decision Tree». En: *Advances in Neural Information Processing Systems 30*. 2017.

[39] Sepp Hochreiter y Jürgen Schmidhuber. «Long Short-Term Memory». En: *Neural Computation* 9.8 (1997), págs. 1735-1780.

[40] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. 2014, págs. 1724-1734.

[41] Edward J. Hu et al. «LoRA: Low-Rank Adaptation of Large Language Models». En: *International Conference on Learning Representations*. 2022.