

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Demanda eléctrica y operación del sistema argentino	1
1.2. Contexto y motivación	2
1.3. Estado del arte	3
1.4. Objetivos y alcance	5
2. Introducción específica	7
2.1. Frameworks para procesamiento y modelado	7
2.2. Fuentes de datos para el pronóstico de demanda	8
2.3. Modelos fundacionales para series temporales	10
2.4. Infraestructura híbrida de datos y cómputo	10
3. Diseño e implementación	13
Bibliografía	15

Índice de figuras

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.	5
2.1. Fuentes de datos utilizadas en el trabajo.	9

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI).

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA), en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas [1]. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas [2]. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño [3]. Aquila et al. revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico [4]. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles, como XGBoost, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En el trabajo, XGBoost se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar horizontes de múltiples pasos y representar patrones en distintas escalas. Oreshkin et al. aplicaron N-BEATS al pronóstico de demanda eléctrica de mediano plazo sobre 35 series nacionales europeas y obtuvieron mejoras frente a métodos estadísticos, de aprendizaje automático e híbridos [5]. El resultado aporta evidencia específica sobre la utilidad de las arquitecturas residuales para modelar tendencias, estacionalidades y fluctuaciones de la demanda, aunque trabaja con series mensuales y un horizonte diferente del considerado en este trabajo.

Otras arquitecturas, entre ellas N-HiTS y modelos basados en Transformers como PatchTST, extienden esta línea mediante mecanismos de procesamiento multiescala y segmentación temporal [6, 7]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos y aprovechar ventanas históricas extensas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se pre-entrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo [8]. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [1]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [2]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [3]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Oreshkin et al. [5]	N-BEATS	Demanda mensual de 35 países europeos.	Mejora de la precisión y del sesgo frente a diez métodos.
Meyer et al. [8]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del sistema como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendario necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando un modelo XGBoost como referencia.
- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.

- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, bibliotecas, fuentes de datos e infraestructura de cómputo utilizadas como soporte del trabajo. El propósito es describir los componentes de terceros y el entorno tecnológico utilizados.

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Aquellas actividades que requerían acceso directo a sistemas internos o ejecución desde la red local se alojaron en una instalación de Dagster ejecutada en infraestructura propia de la empresa.

2.1. Frameworks para procesamiento y modelado

El lenguaje principal utilizado fue Python, debido a su amplia adopción en ciencia de datos y a la disponibilidad de bibliotecas para aprendizaje automático, series temporales y acceso a fuentes heterogéneas. Su utilización permitió mantener una base tecnológica común entre los notebooks ejecutados en Fabric y los procesos alojados en el servidor local.

Para la preparación y análisis de datos se utilizó principalmente la librería *pandas*, que proporciona estructuras tabulares y operaciones para selección, agrupamiento y transformación de datos. Esta herramienta resulta apropiada para el tratamiento de series temporales de demanda y meteorología, especialmente en las etapas que pueden resolverse en memoria sobre un único nodo.

Cuando el volumen de datos o la integración con los servicios de Fabric lo requirió, se empleó PySpark. Los notebooks de Fabric admiten procesamiento distribuido mediante Apache Spark y permiten combinar DataFrames de Spark con *pandas*. Esta alternativa proporciona escalabilidad para el tratamiento de datos históricos con resolución horaria o inferior, sin abandonar el ecosistema Python utilizado en el resto de la solución [9].

Para los modelos de referencia se previó el uso de regresiones lineales y algoritmos basados en árboles, particularmente XGBoost. Las regresiones lineales ofrecen una línea de base simple e interpretable, útil para verificar que modelos más complejos aporten una mejora real. XGBoost, por su parte, permite representar relaciones no lineales e interacciones entre variables históricas, meteorológicas y calendarias. La interfaz compatible con *scikit-learn* facilita la preparación de experimentos, el ajuste de hiperparámetros y el cálculo homogéneo de métricas.

Los modelos neuronales abarcan redes recurrentes, como LSTM y GRU, y arquitecturas más recientes diseñadas para el pronóstico de múltiples pasos. Para su

implementación se consideraron bibliotecas especializadas en series temporales que utilizan PyTorch como motor de entrenamiento. Este enfoque permite evaluar familias de modelos con una interfaz común y reducir diferencias de implementación que podrían afectar la comparación.

El seguimiento de experimentos y modelos se apoyó en MLflow, integrado en las capacidades de ciencia de datos de Fabric. MLflow permite registrar parámetros, métricas y artefactos asociados con cada ejecución, además de conservar versiones de los modelos. Su elección respondió a la necesidad de comparar alternativas de manera reproducible y mantener trazabilidad entre los datos utilizados, la configuración de entrenamiento y los resultados obtenidos. Fabric incorpora esta herramienta dentro de sus notebooks y experiencias de ciencia de datos [10].

En el entorno local se utilizó Dagster como orquestador de datos. Su modelo basado en activos permite representar tablas, archivos y otros productos persistentes como elementos con dependencias explícitas, historial de ejecuciones y políticas de actualización [11, 12]. Esta característica resulta adecuada para los procesos que obtienen información desde sistemas internos y posteriormente la escriben en Fabric. pandas y NumPy se utilizaron también en este entorno, junto con bibliotecas de Azure para autenticación y acceso a servicios en la nube.

Para la lectura de series operativas se utilizó PIconnect, conector de Python para PI System y PI Asset Framework. La biblioteca permite consultar valores registrados o interpolados mediante el SDK de PI, por lo que posibilita acceder desde el servidor local a la información histórica del Sistema Operativo en Tiempo Real (SOTR) de CAMMESA [13].

Finalmente, Power BI se empleó como herramienta de visualización, tanto para los pronósticos como para las métricas de desempeño. Su integración con Fabric permite construir informes sobre los datos centralizados sin incorporar una capa adicional de exportación.

2.2. Fuentes de datos para el pronóstico de demanda

Los conjuntos de datos utilizados fueron contruidos a partir de fuentes internas de CAMMESA y servicios meteorológicos externos. No se trató, por lo tanto, de un dataset público preparado previamente para aprendizaje automático, sino de información operativa que debió integrarse con distintas resoluciones, coberturas geográficas y condiciones de acceso.

La variable principal provino de registros de demanda eléctrica del sistema SOTR, almacenados en PI System. Las series poseen una resolución original de diez minutos y representan la demanda del SADI y de sus regiones eléctricas. A partir de estas series se obtienen las variables diarias que actúan como objetivos de pronóstico: energía y potencias mínima y máxima.

También se incorporó información calendaria, como día de la semana, feriados y otras clasificaciones utilizadas habitualmente por los especialistas. Estas variables permiten representar modificaciones del consumo asociadas con la actividad residencial, comercial e industrial.

La información meteorológica se obtuvo de tres fuentes. La primera correspondió al Servicio Meteorológico Nacional (SMN), cuyos datos se consideraron prioritarios por su carácter oficial. Se utilizaron archivos de observaciones diarias y

datos horarios publicados en formato de texto [14]. Debido a restricciones de acceso desde direcciones IP externas al país, la descargas automáticas se realizan desde el servidor local y los archivos se almacenan en un Lakehouse de Fabric para su posterior lectura. Los registros incluyen, entre otras variables, temperatura, humedad relativa, presión y viento. La desventaja que presentan los datos de pronóstico del SMN es que su horizonte máximo es de 7 días, incluyendo el día en curso.

La segunda fuente fue Open-Meteo, utilizada para obtener datos históricos y pronósticos meteorológicos mediante interfaces de programación (API). Tiene múltiples variables disponibles, como temperatura, humedad, presión, viento, nubosidad, precipitación, radiación solar y temperatura aparente con resolución horaria o agregación diaria. La posibilidad de consultas por coordenadas facilita asociar las variables con puntos representativos de las regiones eléctricas. Para los pronósticos se seleccionaron algunos de los modelos disponibles, según el horizonte de cálculo y disponibilidad geográfica [15, 16].

La tercera fuente de pronósticos corresponde a The Weather Channel [17]. Su inclusión permite disponer de una referencia meteorológica adicional, que además es habitualmente consultada por el área de Programación Semanal y Diaria de CAMMESA. Esta fuente presenta un horizonte máximo de pronóstico de 15 días, que se ajusta al requerimiento para predicción de demanda.

La tabla 2.1 resume las fuentes consideradas.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	Contenido principal	Resolución y cobertura	Condición de uso
SOTR PI System	Demanda eléctrica del SADI y sus regiones.	Series de diez minutos, con cobertura nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, fines de semana, feriados y clasificaciones especiales.	Información con resolución diaria.	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios de estaciones argentinas.	Datos abiertos oficiales con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Datos horarios y diarios consultados por coordenadas geográficas.	Datos sujetos a las condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Datos horarios y diarios para ubicaciones seleccionadas.	Servicio de terceros para uso institucional.

2.3. Modelos fundacionales para series temporales

Además de los modelos entrenados específicamente con datos del SADI, se consideró la incorporación de modelos fundacionales para series temporales. Estos modelos se preentrenan sobre colecciones amplias y heterogéneas de series, con el objetivo de aprender patrones generales de tendencia, estacionalidad y dependencia temporal. Luego pueden aplicarse a nuevas series sin reentrenamiento, modalidad conocida como *zero-shot*, o adaptarse mediante procedimientos de ajuste.

Entre las alternativas consideradas se encuentran Chronos y TimesFM. Chronos representa los valores de una serie mediante una discretización que permite emplear arquitecturas derivadas de modelos de lenguaje para producir distribuciones de pronóstico [18]. TimesFM utiliza una arquitectura basada en Transformers con procesamiento por segmentos y fue preentrenado sobre grandes volúmenes de series reales y sintéticas [19]. Ambos constituyen modelos desarrollados por terceros y sus pesos preentrenados no fueron generados como parte del trabajo.

La principal ventaja de estos modelos es que permiten obtener una referencia sin entrenar una red desde cero para cada variable o región. Esto resulta especialmente útil para comprobar si el conocimiento adquirido durante el preentrenamiento se transfiere a series de demanda eléctrica del SADI. Sin embargo, su utilización plantea limitaciones. Algunos modelos preentrenados procesan de forma nativa solo la historia de la variable objetivo, mientras que el problema tratado requiere aprovechar información meteorológica y calendaria. Además, los datos de preentrenamiento pueden no representar adecuadamente las particularidades del consumo argentino, su sensibilidad térmica ni las diferencias entre regiones.

Por este motivo, estos modelos se consideraron como una familia adicional de métodos y no como sustitutos directos de los modelos supervisados. La comparación debe realizarse sobre los mismos períodos y métricas, diferenciando los resultados obtenidos sin ajuste de aquellos que eventualmente requieran adaptación.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura adoptó un esquema híbrido compuesto por Microsoft Fabric y un servidor local de CAMMESA. Fabric concentró la mayor parte del almacenamiento, procesamiento, experimentación y visualización, mientras que el entorno local atendió los procesos que requerían conectividad con sistemas internos.

Dentro de Fabric se utilizaron distintos tipos de elementos según la función requerida. Una base de datos KQL actuó como capa inicial o bronce para recibir información con un grado mínimo de elaboración. Las bases KQL están orientadas al análisis de datos temporales y pueden ser consultadas desde notebooks mediante *Kusto Query Language* [20]. El repositorio relacional central se implementó con un *Data Warehouse* [21], con el objetivo de alojar las capas plata y oro. Allí se almacenaron datos normalizados, integrados y preparados para el consumo analítico mediante tablas y vistas T-SQL. También se utilizó un *Data Lakehouse* [22], que se reservó principalmente para archivos auxiliares y para aquellos formatos que no requerían almacenamiento relacional.

Los notebooks de Fabric [9] proporcionaron los entornos de ejecución para Python, pandas y PySpark. También sirvieron como espacio para la experimentación con modelos y para la integración con MLflow. Por otra parte, se utilizaron *Pipelines* [23] para la orquestación entre notebooks, consultas y actividades de copia de datos.

La conexión con bases Oracle instaladas en la infraestructura de CAMMESA se realizó mediante una puerta de enlace de datos alojada en servidores de la empresa. Este componente permite que los servicios de Fabric accedan de manera controlada a fuentes locales sin exponer directamente las bases internas.

El servidor local ejecutó Dagster y las bibliotecas necesarias para comunicarse con PI System y Fabric. Allí se programaron activos encargados de consultar las series internas, procesarlas con pandas y NumPy, y persistir los resultados en el Warehouse mediante autenticación de Azure. El enfoque basado en activos de Dagster facilita describir dependencias y programar actualizaciones periódicas, manteniendo separados el código de acceso a fuentes locales y los servicios administrados en la nube [11, 12].

Esta distribución de responsabilidades respondió a restricciones tecnológicas existentes y a la conveniencia de utilizar la plataforma institucional de CAMMESA. Fabric aporta almacenamiento centralizado, capacidad de procesamiento y servicios integrados de ciencia de datos, mientras que el servidor local conserva el acceso a fuentes que no están disponibles desde la nube. El diseño específico de los flujos, las dependencias entre componentes y los mecanismos de ejecución se desarrollan en el Capítulo 3.

Capítulo 3

Diseño e implementación

Bibliografía

- [1] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: [10.48550 / arXiv.2509.19374](https://doi.org/10.48550/arXiv.2509.19374). arXiv: [2509.19374](https://arxiv.org/abs/2509.19374) [eess.SP]. URL: <https://arxiv.org/abs/2509.19374>.
- [2] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: [10.1016 / j.aei.2026.104419](https://doi.org/10.1016/j.aei.2026.104419). URL: <https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/>.
- [3] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: [10.3390/en13061407](https://doi.org/10.3390/en13061407). URL: <https://doi.org/10.3390/en13061407>.
- [4] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: [10.3390/en16217444](https://doi.org/10.3390/en16217444). URL: <https://doi.org/10.3390/en16217444>.
- [5] Boris N. Oreshkin et al. «N-BEATS Neural Network for Mid-Term Electricity Load Forecasting». En: *Applied Energy* 293 (2021), pág. 116918. DOI: [10.1016/j.apenergy.2021.116918](https://doi.org/10.1016/j.apenergy.2021.116918).
- [6] Cristian Challu et al. «N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6. 2023, págs. 6989-6997. DOI: [10.1609 / aaai.v37i6.25854](https://doi.org/10.1609/aaai.v37i6.25854). URL: <https://doi.org/10.1609/aaai.v37i6.25854>.
- [7] Yuqi Nie et al. «A Time Series Is Worth 64 Words: Long-Term Forecasting with Transformers». En: *International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [8] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: [10.1109 / ACCESS.2025.3648056](https://doi.org/10.1109/ACCESS.2025.3648056).
- [9] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks> (visitado 12-09-2026).
- [10] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: <https://microsoftlearning.github.io/mslearn-fabric/> (visitado 12-09-2026).
- [11] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: <https://docs.dagster.io/> (visitado 12-09-2026).
- [12] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: <https://docs.dagster.io/api/dagster/assets> (visitado 12-09-2026).
- [13] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: <https://piconnect.readthedocs.io/en/main/> (visitado 12-09-2026).
- [14] SMN. *Datos Abiertos SMN*. 2026. URL: <https://www.smn.gob.ar/descarga-de-datos> (visitado 13-09-2026).

- [15] Open-Meteo. *Historical Weather API*. 2026. URL: <https://open-meteo.com/en/docs/historical-weather-api> (visitado 12-09-2026).
- [16] Open-Meteo. *Historical Forecast API*. 2026. URL: <https://open-meteo.com/en/docs/historical-forecast-api> (visitado 12-09-2026).
- [17] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: <https://weather.com/es-AR/ar/city/buenos-aires/today> (visitado 13-09-2026).
- [18] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: <https://openreview.net/forum?id=gerNCVqqtR>.
- [19] Abhimanyu Das et al. «A Decoder-Only Foundation Model for Time-Series Forecasting». En: *Proceedings of the 41st International Conference on Machine Learning*. Vol. 235. Proceedings of Machine Learning Research. PMLR, 2024, págs. 10148-10167. URL: <https://proceedings.mlr.press/v235/das24c.html>.
- [20] Microsoft. *Analyze data in a KQL database*. 2026. URL: <https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with> (visitado 12-09-2026).
- [21] Microsoft. *Documentación de Data Warehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-warehouse/> (visitado 13-09-2026).
- [22] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: <https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview> (visitado 13-09-2026).
- [23] Microsoft. *Documentación de Pipeline*. 2026. URL: <https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview> (visitado 13-09-2026).