.UBAfiuba
FACULTAD DE INGENIERÍA

Optimización y despliegue de modelos de demanda de energía eléctrica de Argentina

Ing. Daniel Gerardo Paniagua

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Joel Alexander Spak (Nasini S.A.)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2026

Resumen

En la presente memoria se aborda la optimización y puesta en producción de modelos para pronosticar la demanda de energía eléctrica en Argentina, con un horizonte de hasta 14 días. El trabajo se desarrolló para la Compañía Administradora del Mercado Mayorista Eléctrico y su implementación permitió automatizar la generación de pronósticos, estructurar el almacenamiento de datos y supervisar el desempeño de los modelos.

Para su realización se pusieron en práctica conocimientos de aprendizaje profundo aplicado a series temporales, ingeniería de datos y visualización de información.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. Demanda eléctrica y operación del sistema argentino 1
1.2. Contexto y motivación 2
1.3. Estado del arte 3
1.4. Objetivos y alcance 5

2. Introducción específica 7
2.1. Frameworks para procesamiento y modelado 7
2.2. Fuentes de datos para el pronóstico de demanda 8
2.3. Modelos de pronóstico 8
2.3.1. Algoritmos de aprendizaje automático 9
2.3.2. Redes neuronales 9
2.3.3. Modelos fundacionales 10
2.3.4. Ensambles 10
2.3.5. Representación de la temperatura y corrección de pronósticos 10
2.4. Infraestructura híbrida de datos y cómputo 11

3. Diseño e implementación 13
3.1. Pipeline de datos 13
3.1.1. Arquitectura y criterios de diseño 13
3.1.2. Flujo de demanda eléctrica 15
Cálculo de la demanda regional 16
Resolución horaria y control de calidad 18
3.1.3. Flujo de datos meteorológicos observados 20
Ingesta en capa 1 20
Transformación a capa 2 21
3.1.4. Flujo de pronósticos meteorológicos 22
Fuentes e ingesta en capa 1 22
Reconstrucción de la historia de pronósticos 23
Transformación a capa 2 y orquestación 23
3.2. Desarrollo de modelos 25
3.2.1. Selección del modelo de referencia 26
3.2.2. Modelos de aprendizaje profundo, fundacionales y ensambles 27
3.2.3. Covariables, fuentes meteorológicas y nivel de agregación . 29
3.2.4. Representación de la respuesta a la temperatura 30
3.2.5. Corrección y combinación de los pronósticos 31
3.3. Integración y puesta en producción 32
3.3.1. Configuración productiva 32
3.3.2. Arquitectura de ejecución 33
3.3.3. Generación diaria de pronósticos 33

3.3.4. Reentrenamiento y registro de modelos 34
3.3.5. Monitoreo del desempeño 34

4. Ensayos y resultados **37**
4.1. Plan de evaluación 37
4.1.1. Métricas 38
4.1.2. Alcance y condiciones de comparación 38
4.2. Evaluación del modelo 39
4.2.1. Modelo de referencia 39
4.2.2. Modelos de aprendizaje profundo y fundacionales 41
4.2.3. Covariables, fuentes meteorológicas y nivel de agregación . 43
Grupos de pronósticos 43
Indicador de actividad económica 44
Potencias del MEM y comparación con el modelo de producción 44

A. Modelo de datos del warehouse **47**
A.1. Relaciones entre esquemas 47
A.2. Esquema DEMANDA 48
A.3. Esquema METEO 49
A.4. Esquema PRONOS 50
A.5. Esquema MODELOS 51

Bibliografía **53**

Índice de figuras

3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia. 14
3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA. 16
3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado. 17
3.4. Corrección de valores extremos. 19
3.5. Corrección de saltos bruscos. 20
3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados. 21
3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos. 24
3.8. Esquema de validación con origen móvil: reentrenamiento en la fecha R y pronóstico de una fecha de cálculo D hasta el reentrenamiento siguiente R'. 26
3.9. Arquitectura del sistema de pronóstico en producción. 33

4.1. MAPE de la energía del MEM por anticipación de los modelos evaluados en la selección del modelo de referencia. 40
4.2. Distribución del error porcentual de la energía del MEM por anticipación de LightGBM con el pronóstico de IFS. Las cajas representan los percentiles 25 y 75, y los bigotes, los percentiles 5 y 95. . . . 40
4.3. MAPE de la energía del MEM por anticipación de modelos seleccionados de la segunda etapa. 42
4.4. Distribución del error porcentual de la energía del MEM por anticipación de LGBM_OPT y TSMixer con el pronóstico de IFS. Las cajas representan los percentiles 25 y 75, y los bigotes, los percentiles 5 y 95. 42
4.5. MAPE de la energía del MEM por anticipación de ENS_STACK en la configuración Regional G5A, según el pronóstico meteorológico utilizado. 44

A.1. Relaciones entre las tablas principales de los esquemas DEMANDA, METEO y PRONOS. 47

Índice de tablas

1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica. 5

2.1. Fuentes de datos utilizadas en el trabajo. 8
2.2. Modelos de pronóstico evaluados. 9

3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline. . . 22
3.2. Grupos de covariables evaluados en la selección del modelo de referencia. 27
3.3. Configuración de los modelos de aprendizaje profundo y fundacionales. 27
3.4. Espacio de búsqueda de los hiperparámetros de LGBM_OPT. . . . 28
3.5. Grupos de pronósticos evaluados. 29
3.6. Umbrales de grados-día por región eléctrica, en °C. 30
3.7. Configuraciones de modelos evaluadas. 31

4.1. Períodos utilizados en el entrenamiento y la evaluación de los modelos. 37
4.2. Métricas de la energía del MEM de los modelos evaluados en la selección del modelo de referencia, promedio de las anticipaciones 0 a 14. MAPE y sesgo en %, RMSE en GWh. 39
4.3. Métricas de la energía del MEM de los modelos de aprendizaje profundo y fundacionales, y tiempo medio de entrenamiento. MAPE y sesgo en %, RMSE en GWh y tiempo en segundos. 41
4.4. MAPE (%) de la energía del MEM según la configuración, promedio de las anticipaciones 0 a 14. G5 y G5A corresponden a las configuraciones regionales. 43
4.5. MAPE (%) de la configuración MEM G5 por variable objetivo, promedio de las anticipaciones 0 a 14. 44

A.1. Tablas y vistas del esquema DEMANDA. 48
A.2. Columnas de las tablas del esquema DEMANDA. 48
A.3. Tablas y vistas del esquema METEO. 49
A.4. Variables meteorológicas horarias. 50
A.5. Variables meteorológicas diarias. 50
A.6. Tablas y vistas del esquema PRONOS. 51
A.7. Columnas propias de las tablas y vistas del esquema PRONOS. . . 51
A.8. Tablas y vistas del esquema MODELOS. 52

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se describen las principales características de la demanda eléctrica en la República Argentina y los desafíos que presenta pronosticar su comportamiento. Además, se pone de manifiesto su relevancia en la planificación y operación del Sistema Argentino de Interconexión (SADI) [1].

1.1. Demanda eléctrica y operación del sistema argentino

La energía eléctrica constituye un insumo esencial para el funcionamiento de los hogares, la industria, el comercio, los servicios y la infraestructura de un país. Su disponibilidad debe garantizarse de manera continua, con niveles adecuados de calidad y seguridad. Dado que no puede almacenarse en grandes cantidades, la generación debe ajustarse permanentemente al consumo, junto con las pérdidas y los intercambios que se producen en la red.

La demanda eléctrica representa el consumo agregado de los usuarios conectados al sistema. Su comportamiento varía a lo largo del día según la actividad residencial, comercial e industrial. También presenta diferencias entre días hábiles, fines de semana y feriados, así como variaciones estacionales asociadas, entre otros factores, con las condiciones meteorológicas. Por lo tanto, constituye una variable temporal cuyo comportamiento depende de múltiples factores.

En la Argentina, el abastecimiento eléctrico se realiza principalmente a través del Sistema Argentino de Interconexión (SADI), que vincula centrales de generación, redes de transporte, instalaciones de distribución y grandes usuarios. Su operación requiere coordinar recursos con distintas características técnicas y económicas, entre ellos centrales térmicas, hidroeléctricas, nucleares y fuentes renovables variables. También deben considerarse los intercambios con países limítrofes, las restricciones de la red, las reservas operativas y la disponibilidad de combustibles y recursos hidráulicos.

La planificación de la operación permite anticipar estas condiciones y definir una estrategia para abastecer la demanda esperada. La programación semanal contempla decisiones relacionadas con la disponibilidad de generación, los mantenimientos, el uso de los recursos hidráulicos, la asignación de combustibles y los intercambios de energía. La programación diaria establece una previsión más detallada del funcionamiento del sistema para el día siguiente.

En ambas instancias, una subestimación de la demanda puede conducir a una programación insuficiente de recursos y reducir los márgenes disponibles para

responder ante contingencias. Por el contrario, una sobreestimación puede provocar la programación innecesaria de unidades de generación e incrementar los costos operativos. En consecuencia, la calidad del pronóstico influye en la confiabilidad, la seguridad y la eficiencia económica de la operación.

El pronóstico de la demanda consiste en estimar su evolución futura a partir de información histórica y de variables relacionadas con su comportamiento. Los pronósticos de corto plazo se utilizan principalmente en la programación y operación del sistema, mientras que los horizontes más extensos permiten evaluar inversiones, ampliaciones de infraestructura y escenarios de crecimiento. La naturaleza temporal de la demanda, su sensibilidad a factores meteorológicos y calendarios, y la necesidad de anticipar su evolución justifican el desarrollo de métodos capaces de representar relaciones complejas y adaptarse a diferentes condiciones operativas.

1.2. Contexto y motivación

El trabajo se realizó para la Compañía Administradora del Mercado Mayorista Eléctrico S.A. (CAMMESA) [2, 3], en particular para el área de Programación Semanal y Diaria de la Gerencia de Coordinación Operativa. Esta área requiere estimaciones de demanda con un horizonte de hasta 14 días para la programación semanal y un perfil horario para la programación del día siguiente.

Antes de la realización del trabajo, el área disponía de modelos de machine learning y deep learning destinados a pronosticar la demanda diaria del SADI. Sin embargo, estos modelos no contaban con un proceso sistemático de validación y monitoreo que permitiera evaluar su desempeño a lo largo del tiempo y bajo diferentes condiciones meteorológicas y calendarias. En consecuencia, no se disponía de información suficiente para determinar objetivamente la confiabilidad de las predicciones ni para detectar una posible degradación de su rendimiento.

Tanto en la programación semanal como en la diaria, los resultados de los modelos se utilizaban como referencia y se complementaban mediante la inspección manual de datos históricos de demanda y temperatura. Los especialistas analizaban períodos con características similares e inferían los valores esperados para los días siguientes. Este procedimiento requería revisar distintas fuentes de información y dependían en gran medida de la experiencia de los especialistas.

La ejecución de los modelos también presentaba dificultades operativas, ya que se encontraban funcionando en una única computadora de uso común y el flujo de datos tenía un bajo grado de automatización. Su utilización requería cargar datos de entrada, ejecutar macros para obtener o transformar información e iniciar manualmente los procesos correspondientes. Tampoco existía un mecanismo centralizado para almacenar las ejecuciones, las variables de entrada y las predicciones generadas, lo que dificultaba la comparación entre modelos, el cálculo periódico de métricas y el análisis de los errores.

Otra limitación correspondía al nivel de agregación geográfica. Los modelos diarios generaban pronósticos para la totalidad del SADI, pero no proporcionaban estimaciones por región eléctrica. CAMMESA también dispone de un modelo de demanda horaria limitado al Gran Buenos Aires, cuyos resultados pierden confiabilidad al extenderse el horizonte de predicción. Por lo tanto, las herramientas

existentes no permitían obtener pronósticos diarios regionales para el horizonte requerido por la programación semanal.

En este contexto, el trabajo se orientó a obtener una herramienta de pronóstico confiable y adecuada para su utilización operativa. Se automatizaron la obtención y el procesamiento de los datos, la ejecución de las predicciones y el almacenamiento de los resultados. También se incorporaron mecanismos de validación y monitoreo basados en métricas objetivas, se compararon diferentes modelos y se analizó la generación de pronósticos por región eléctrica.

Esta memoria describe el desarrollo y la evaluación de la solución implementada, que permite reducir la intervención manual, mejorar la trazabilidad y disponer de información objetiva sobre la calidad de las predicciones. De este modo, los especialistas pueden concentrarse en el análisis de situaciones particulares y utilizar los resultados como apoyo para la programación semanal y diaria del sistema eléctrico.

1.3. Estado del arte

El pronóstico de la demanda eléctrica ha sido abordado mediante modelos estadísticos, técnicas de aprendizaje automático y arquitecturas de aprendizaje profundo. La elección del método depende del horizonte de predicción, la resolución temporal, el nivel de agregación geográfica y la disponibilidad de variables explicativas. En sistemas con una participación residencial significativa, la temperatura y otras condiciones meteorológicas tienen una incidencia relevante sobre el consumo, principalmente por el uso de equipos de climatización. En un país de gran extensión territorial, este efecto varía entre regiones y estaciones del año, por lo que un pronóstico agregado puede ocultar comportamientos locales.

En la Argentina, Oviedo [4] desarrolló un modelo LSTM para pronosticar la demanda horaria de la provincia de Córdoba a partir de datos de consumo y variables climáticas, temporales y demográficas. El modelo alcanzó un error porcentual absoluto medio (MAPE) de 3,20 % y un coeficiente de determinación de 0,95. Por su parte, Uhrig et al. [5] estudiaron la demanda diaria de Entre Ríos mediante una LSTM multivariada con variables meteorológicas, temporales y energéticas. Los autores observaron mayores niveles de demanda ante temperaturas extremas y obtuvieron mejores resultados que con un método estadístico y una red GRU. Ambos antecedentes confirman la relevancia de las variables exógenas, aunque se limitan a una provincia y no consideran conjuntamente la demanda nacional y su desagregación regional.

Como antecedente latinoamericano de alcance nacional, Leme et al. [6] aplicaron modelos de Random Forest, Support Vector Machine (SVM) y Gradient Boosting al pronóstico de la demanda del sistema interconectado brasileño. Aquila et al. [7] revisaron los métodos utilizados para la planificación operativa de corto plazo en Brasil y destacaron la selección de variables, la segmentación según patrones similares y los enfoques jerárquicos de pronóstico. Debido a su extensión territorial y diversidad climática, el caso brasileño presenta mayor proximidad con el problema argentino que los estudios limitados a una empresa distribuidora o a grupos reducidos de usuarios.

La experiencia operativa de CAMMESA constituye otro antecedente directo del trabajo. Antes de su realización, el área de Programación Semanal y Diaria utilizaba modelos SARIMAX, XGBoost y LSTM para estimar la demanda agregada del SADI. Las evaluaciones internas mostraban valores de MAPE comprendidos aproximadamente entre 3 % para el día siguiente y 10 % para los horizontes más alejados, con diferencias según el modelo y las condiciones analizadas. Estos resultados no proceden de una publicación académica y, por lo tanto, no son directamente comparables con los trabajos citados. No obstante, documentan el desempeño de los métodos en el entorno de aplicación y muestran tanto el aumento del error con el horizonte como la necesidad de incorporar variables meteorológicas y calendarias identificadas por los especialistas.

Los métodos basados en árboles de decisión, como XGBoost y LightGBM, representan una referencia adecuada para este problema porque permiten modelar relaciones no lineales e incorporar variables exógenas con un costo computacional moderado. Sin embargo, requieren construir explícitamente atributos que describan la historia y la estacionalidad de la serie. En este trabajo, un modelo basado en árboles se utilizó como línea de base para determinar si enfoques más recientes mejoraban el pronóstico bajo un mismo procedimiento de validación.

La investigación reciente avanzó hacia arquitecturas neuronales diseñadas para generar pronósticos de múltiples pasos e incorporar covariables conocidas a futuro, como la información calendaria o los pronósticos meteorológicos. Lim et al. [8] propusieron el Temporal Fusion Transformer (TFT), que combina capas recurrentes con mecanismos de atención y de selección de variables, y lo evaluaron, entre otros conjuntos, sobre series de consumo eléctrico. Su diseño permite distinguir la información histórica, la conocida a futuro y la estática, y estimar la relevancia de cada variable en el pronóstico.

En paralelo, otras arquitecturas, como TiDE y TSMixer, mostraron que modelos basados en perceptrones multicapa pueden alcanzar un desempeño competitivo frente a los basados en Transformers, con un costo de entrenamiento menor [9, 10]. Su interés para el problema radica en la capacidad de producir pronósticos directos de varios pasos con covariables exógenas, pero su desempeño debe comprobarse con datos meteorológicos y regionales del sistema analizado.

Los modelos fundacionales constituyen una tendencia aún más reciente. Se preentrenan sobre grandes colecciones de series y pueden aplicarse a datos nuevos sin entrenamiento específico o con un ajuste limitado. Meyer et al. [11] compararon modelos fundacionales, entre ellos Chronos y TimesFM, con Transformers entrenados desde cero para pronosticar demanda eléctrica residencial de corto plazo. Los resultados indicaron desempeños comparables y, en algunos casos, superiores, con menor necesidad de entrenamiento específico. Este antecedente respalda su evaluación en el dominio eléctrico, aunque su escala residencial difiere de la demanda de un sistema nacional y no resuelve por sí mismo la incorporación de variables exógenas ni la desagregación regional.

La tabla 1.1 resume los antecedentes de mayor relación con el trabajo. La revisión mostró una disponibilidad limitada de estudios que reprodujeran las condiciones del problema considerado. Los antecedentes argentinos publicados se concentran en una provincia, mientras que los trabajos sobre arquitecturas modernas utilizan

otras escalas, horizontes o niveles de agregación. Tampoco se encontraron comparaciones que combinaran un horizonte diario de 14 días, variables meteorológicas, demanda total de un sistema eléctrico nacional y desagregación en regiones extensas.

TABLA 1.1. Antecedentes relacionados con el pronóstico de demanda eléctrica.

Referencia	Enfoque	Datos y alcance	Resultado o aporte
Oviedo [4]	LSTM	Demanda horaria de Córdoba y variables exógenas.	MAPE de 3,20 % y R^2 de 0,95.
Uhrig et al. [5]	LSTM multivariada	Demanda diaria de Entre Ríos y 21 variables.	Mejora frente a un método estadístico y una red GRU.
CAMMESA, evaluación interna	SARIMAX, XGBoost y LSTM	Demanda agregada del SADI, con un horizonte de hasta 14 días.	MAPE aproximado entre 3 % y 10 %, según el horizonte y el modelo.
Leme et al. [6]	RF, SVM y Gradient Boosting	Demanda del sistema interconectado brasileño.	Comparación de métodos sobre datos de alcance nacional.
Lim et al. [8]	Temporal Fusion Transformer	Series de consumo eléctrico y de otros dominios, con covariables conocidas a futuro.	Pronóstico de múltiples pasos con estimación de la relevancia de las variables.
Meyer et al. [11]	Modelos fundacionales y Transformers	Demanda residencial de corto plazo.	Desempeño competitivo con menor necesidad de entrenamiento específico.

1.4. Objetivos y alcance

El objetivo general del trabajo es desarrollar e implementar una solución automatizada para pronosticar la demanda eléctrica diaria del Sistema Argentino de Interconexión (SADI), con un horizonte de hasta 14 días. Las variables objetivo fueron la energía diaria y las potencias mínima y máxima, tanto para la totalidad del Mercado Eléctrico Mayorista (MEM) como para cada una de las regiones eléctricas consideradas.

Para alcanzar este propósito, se definieron los siguientes objetivos específicos:

- Integrar y procesar los datos históricos de demanda, las variables meteorológicas y la información calendaria necesarias para generar los pronósticos del SADI y de sus regiones eléctricas.
- Implementar y comparar modelos de aprendizaje automático, arquitecturas neuronales modernas y modelos preentrenados para series temporales, utilizando como referencia un modelo basado en árboles de decisión.

- Evaluar la capacidad de los modelos para pronosticar la energía diaria y las potencias mínima y máxima en cada uno de los 14 días del horizonte.
- Comparar el desempeño de los modelos mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), calculados sobre períodos no utilizados durante el entrenamiento.
- Analizar los errores según la variable pronosticada, el horizonte de predicción, la región eléctrica y las condiciones meteorológicas y calendarias.
- Automatizar la obtención y el procesamiento de los datos, la ejecución periódica de los modelos y el almacenamiento centralizado de sus entradas, predicciones y métricas.
- Implementar mecanismos de monitoreo que permitan consultar el desempeño histórico de los modelos, comparar sus resultados y detectar variaciones en la calidad de las predicciones.

El cumplimiento de estos objetivos permitió determinar qué enfoques resultaron más adecuados para las distintas variables, regiones y horizontes, y disponer de una herramienta trazable para apoyar las tareas de programación semanal y diaria de CAMMESA.

Capítulo 2

Introducción específica

En este capítulo se presentan las tecnologías, fuentes de datos, modelos e infraestructura de cómputo de terceros sobre los que se construyó la solución. La forma en que cada componente se configuró y se utilizó en este trabajo se desarrolla en el capítulo 3.

2.1. Frameworks para procesamiento y modelado

La solución se apoyó principalmente en Microsoft Fabric, plataforma adoptada por CAMMESA para el almacenamiento, procesamiento y análisis de datos. Las actividades que requerían acceso a sistemas internos se alojaron en Dagster, un orquestador basado en activos que representa tablas y archivos como elementos con dependencias explícitas e historial de ejecuciones [12, 13], ejecutado en un servidor de la empresa.

El lenguaje principal fue Python, por su amplia adopción en ciencia de datos y la disponibilidad de bibliotecas para series temporales y acceso a fuentes heterogéneas. La preparación de datos se realizó con pandas y NumPy y, cuando el volumen o la integración con Fabric lo requirieron, con PySpark, que permite el procesamiento distribuido en los notebooks de la plataforma [14]. Las series del sistema de tiempo real se leyeron con PIconnect, conector de Python para PI System [15].

Los modelos se implementaron con Darts [16], una biblioteca de series temporales que ofrece una interfaz común para entrenar y predecir con algoritmos clásicos y redes neuronales basadas en PyTorch. Darts admite el entrenamiento sobre múltiples series y covariables pasadas, futuras y estáticas, y resuelve la construcción de las ventanas de entrada y salida. Este enfoque permite evaluar familias de modelos distintas con un mismo procedimiento y reduce las diferencias de implementación que podrían afectar la comparación.

La búsqueda de hiperparámetros se realizó con Optuna [17]. Su muestreador por defecto, TPE (*Tree-structured Parzen Estimator*) [18], construye a partir de las pruebas anteriores un modelo probabilístico de las regiones del espacio con mejores resultados y propone las combinaciones siguientes en función de él, por lo que requiere menos evaluaciones que una búsqueda en grilla. El registro de experimentos y de versiones de modelos se apoyó en MLflow, integrado en Fabric [19], y la visualización de pronósticos y métricas, en Power BI [20].

2.2. Fuentes de datos para el pronóstico de demanda

Los datos no provienen de un conjunto público para aprendizaje automático, sino de información operativa de CAMMESA y de servicios meteorológicos externos, que debió integrarse con distintas resoluciones, coberturas y condiciones de acceso. La tabla 2.1 resume las fuentes utilizadas.

La variable principal proviene de los registros de demanda del Sistema Operativo en Tiempo Real (SOTR), almacenados en PI System con una resolución de diez minutos. A partir de ellos se obtienen las variables objetivo: la energía y las potencias pico y mínima diarias del SADI y de sus regiones. La información calendaria incluye el día de la semana, los feriados y otras clasificaciones utilizadas por los especialistas.

La información meteorológica proviene de tres fuentes. El Servicio Meteorológico Nacional (SMN) publica observaciones y pronósticos en archivos de texto [21]. Sus datos son prioritarios por su carácter oficial, pero sus pronósticos alcanzan solo siete días. Open-Meteo ofrece, mediante una API consultada por coordenadas, datos históricos y pronósticos de distintos modelos numéricos, con variables como temperatura, temperatura aparente, humedad, viento, nubosidad y radiación solar [22, 23]. The Weather Channel [24], consultado habitualmente por el área de Programación Semanal y Diaria, provee pronósticos con un horizonte de 15 días.

TABLA 2.1. Fuentes de datos utilizadas en el trabajo.

Fuente	Contenido principal	Resolución y cobertura	Condición de uso
SOTR (PI System)	Demanda eléctrica del SADI y sus regiones.	Diez minutos; nacional y regional.	Datos internos de CAMMESA.
Calendarios operativos	Días hábiles, feriados y clasificaciones especiales.	Diaria	Información propia y de fuentes oficiales.
SMN	Observaciones y pronósticos meteorológicos.	Horaria y diaria; estaciones argentinas.	Datos abiertos con atribución.
Open-Meteo	Observaciones y pronósticos meteorológicos.	Horaria; por coordenadas geográficas.	Condiciones de uso de la API.
The Weather Channel	Pronósticos meteorológicos.	Horaria y diaria; ubicaciones seleccionadas.	Servicio de terceros.

2.3. Modelos de pronóstico

Los modelos evaluados estiman los valores futuros de la variable objetivo a partir de su historia y de covariables. Las covariables pueden ser pasadas, cuando solo se conocen hasta el momento del pronóstico; futuras, cuando se conocen de antemano, como el calendario o un pronóstico meteorológico; o estáticas, cuando describen una característica constante de la serie, como su región. Para cubrir un horizonte de varios días, un modelo puede seguir una estrategia recursiva, en la que predice un día por vez y utiliza cada predicción como entrada del siguiente, o una estrategia directa, en la que genera todo el horizonte en un único paso. Además, un modelo es local cuando se entrena con una única serie, y global

cuando aprende de varias a la vez, lo que le permite disponer de más ejemplos y compartir patrones comunes [25]. La tabla 2.2 resume los modelos utilizados.

TABLA 2.2. Modelos de pronóstico evaluados.

Modelo	**Familia**	**Mecanismo principal**	**Covariables en Darts**
Regresión lineal	Aprendizaje automático	Combinación lineal de las variables explicativas.	Futuras y pasadas.
Random Forest [26]	Aprendizaje automático	Promedio de árboles entrenados sobre muestras aleatorias.	Futuras y pasadas.
XGBoost [27]	Aprendizaje automático	*Gradient boosting* con regularización de los árboles.	Futuras y pasadas.
LightGBM [28]	Aprendizaje automático	*Gradient boosting* con histogramas y crecimiento por hojas.	Futuras y pasadas.
LSTM [29]	Red recurrente	Celda de memoria con compuertas de entrada, olvido y salida.	Futuras
GRU [30]	Red recurrente	Compuertas de actualización y de reinicio.	Futuras
TFT [8]	Múltiples pasos	Selección de variables, codificador recurrente y atención multicabezal.	Estáticas, pasadas y futuras.
TiDE [9]	Múltiples pasos	Codificador y decodificador con bloques residuales densos.	Estáticas, pasadas y futuras.
TSMixer [10]	Múltiples pasos	Perceptrones que mezclan las dimensiones temporal y de variables.	Estáticas, pasadas y futuras.
Chronos-2 [31]	Fundacional	Transformer preentrenado con atención grupal entre la serie y sus covariables.	Pasadas y futuras.

2.3.1. Algoritmos de aprendizaje automático

La regresión lineal es interpretable y permite modelar relaciones lineales entre las variables. Para representar relaciones no lineales, como la respuesta de la demanda a la temperatura, es necesario incorporar transformaciones de las variables. Los demás algoritmos combinan árboles de decisión. Random Forest promedia árboles entrenados sobre muestras aleatorias para reducir la varianza, mientras que el *gradient boosting* [32] agrega árboles en forma secuencial, de modo que cada uno corrige los errores de los anteriores. XGBoost y LightGBM son implementaciones eficientes de este esquema. Sus principales hiperparámetros son la cantidad de árboles, la tasa de aprendizaje, la cantidad de hojas, el mínimo de observaciones por hoja, las fracciones de observaciones y de variables de cada árbol, y la regularización. Los modelos basados en árboles representan relaciones no lineales sin transformaciones previas, pero no extrapolan fuera del rango observado en el entrenamiento y requieren que la historia se presente como rezagos explícitos.

2.3.2. Redes neuronales

Las redes recurrentes procesan una secuencia de a un paso por vez y mantienen un estado interno que resume los pasos anteriores. LSTM [29] incorpora una celda de memoria regulada por compuertas, que facilita el aprendizaje de dependencias largas, y GRU [30] simplifica ese mecanismo con menos parámetros. En el pronóstico se utilizan habitualmente de forma recursiva.

Las arquitecturas de múltiples pasos pronostican el horizonte completo con covariables. TFT [8] combina la selección de variables, un codificador recurrente y atención multicabezal. TiDE [9] y TSMixer [10], basadas solo en perceptrones multicapa, alcanzan resultados comparables con un costo computacional menor. Otras arquitecturas difundidas, como N-BEATS [33] y N-HiTS [34], no se consideraron porque en Darts solo admiten covariables pasadas, y en este problema el calendario y el pronóstico meteorológico de los días pronosticados son determinantes.

2.3.3. Modelos fundacionales

Los modelos fundacionales se preentrenan sobre colecciones amplias de series para aprender patrones generales de tendencia, estacionalidad y dependencia temporal, y pueden aplicarse a series nuevas sin entrenamiento (*zero-shot*) o adaptarse mediante un ajuste. Se utilizó Chronos-2 [31], sucesor de Chronos [35]. Es un modelo de 120 millones de parámetros, preentrenado con series reales y sintéticas, cuya atención grupal procesa en forma conjunta la serie objetivo y sus covariables pasadas y futuras. Sus pesos no fueron generados como parte del trabajo.

Para el ajuste se utilizó LoRA (*Low-Rank Adaptation*) [36], que mantiene fijos los pesos preentrenados y entrena solo matrices de bajo rango agregadas a algunas capas, lo que reduce los parámetros ajustados y conserva el conocimiento del preentrenamiento. Estos modelos permiten obtener una referencia sin entrenar una red desde cero. Sin embargo, sus datos de preentrenamiento pueden no representar las particularidades del consumo argentino, por lo que se evaluaron como una familia adicional y no como sustitutos de los modelos supervisados.

2.3.4. Ensambles

Un ensamble combina las predicciones de varios modelos para compensar sus errores. El promedio reduce la varianza cuando los errores no están perfectamente correlacionados, mientras que el *stacking* [37] entrena un metamodelo que pondera las predicciones de los modelos base, con predicciones obtenidas sobre datos no utilizados en su entrenamiento. El mismo principio se aplica a la combinación de pronósticos obtenidos con distintas fuentes de información [38], como un mismo modelo de demanda alimentado con distintos pronósticos meteorológicos.

2.3.5. Representación de la temperatura y corrección de pronósticos

La demanda responde a la temperatura con una zona de confort, en la que casi no varía, y dos tramos en los que crece con el calor y con el frío, con pendientes distintas [39]. Los grados-día de refrigeración (CDD, *Cooling Degree Days*) y de calefacción (HDD, *Heating Degree Days*) representan cada tramo por separado, según la ecuación 2.1:

$$\mathrm{CDD}_t = \max\left(0;\ T_t - T^c\right), \qquad \mathrm{HDD}_t = \max\left(0;\ T^f - T_t\right) \tag{2.1}$$

donde T_t es la temperatura media del día t, y T^c y T^f son los umbrales a partir de los cuales la demanda responde al calor y al frío, que dependen del clima y del equipamiento de los usuarios de cada zona.

Los pronósticos de los modelos numéricos presentan, además, errores sistemáticos que dependen de la ubicación, la estación y la anticipación. Los métodos MOS (*Model Output Statistics*) [40] los corrigen mediante relaciones estadísticas entre los valores pronosticados y los observados. La forma más simple resta al pronóstico el error medio de un período reciente. El mismo principio permite ajustar un pronóstico de demanda con el sesgo de los días recientes, sin reentrenar el modelo.

2.4. Infraestructura híbrida de datos y cómputo

La infraestructura combinó Microsoft Fabric, que concentró el almacenamiento, el procesamiento, la experimentación y la visualización, con un servidor local de CAMMESA para los procesos que requerían conectividad con sistemas internos. Esta distribución respondió a restricciones de acceso y a la conveniencia de utilizar la plataforma institucional.

En Fabric, una base de datos KQL [41], orientada al análisis de datos temporales, actuó como capa inicial para recibir la información con una elaboración mínima. Un warehouse [42] alojó las capas de datos normalizados e integrados, mediante tablas y vistas T-SQL, y un lakehouse [43] almacenó los archivos auxiliares. Los notebooks proporcionaron los entornos de ejecución de Python y PySpark, y los pipelines [44] orquestaron notebooks, consultas y copias de datos. El acceso a las bases Oracle internas se realizó mediante una puerta de enlace de datos, que evita exponerlas a la red externa. El servidor local ejecutó Dagster y las bibliotecas de acceso a PI System, y escribió los resultados en el warehouse mediante autenticación de Azure.

La experimentación con los modelos se realizó en Google Colab [45], principalmente con GPU NVIDIA L4 para las redes neuronales y con entornos sin GPU para los algoritmos basados en árboles y la búsqueda de hiperparámetros. Los datos se exportaron desde el warehouse a archivos cargados en el entorno de ejecución. El diseño de los flujos y los mecanismos de ejecución se desarrollan en el capítulo 3.

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño y la implementación de la solución desarrollada para automatizar el pronóstico de la demanda eléctrica del SADI. En primer lugar, se presenta el pipeline implementado para obtener, validar, transformar y almacenar los datos de demanda y las variables meteorológicas utilizadas por los modelos. A continuación, se describen las etapas del desarrollo de los modelos: la configuración de cada uno, el procedimiento de entrenamiento y optimización, las covariables y las correcciones incorporadas a partir de los resultados, y el postproceso de los pronósticos. Finalmente, se detalla la integración de estos componentes en el sistema implementado, junto con las decisiones adoptadas para garantizar la trazabilidad y la reproducibilidad de las ejecuciones.

3.1. Pipeline de datos

El sistema de pronóstico requiere integrar series eléctricas, meteorológicas y calendarias con distintas resoluciones temporales, coberturas geográficas y condiciones de acceso. Para ello se diseñó un pipeline que automatiza la extracción, la validación, la transformación y la persistencia de los datos, con el objetivo de disponer de conjuntos consistentes y trazables tanto para el entrenamiento como para la ejecución periódica de los pronósticos. En esta sección se presentan, en primer lugar, la arquitectura y los criterios de diseño comunes y, a continuación, los tres flujos que componen el pipeline: demanda eléctrica, datos meteorológicos observados y pronósticos meteorológicos.

3.1.1. Arquitectura y criterios de diseño

La solución se implementó sobre la arquitectura híbrida presentada en el capítulo 2. Los procesos que requieren acceso a sistemas internos de CAMMESA, o a fuentes con restricciones de acceso desde el exterior, se ejecutan en un servidor local mediante Dagster. El almacenamiento y las transformaciones se concentran en Microsoft Fabric: una base de datos KQL recibe los datos meteorológicos con un grado mínimo de elaboración, el warehouse aloja las capas estructuradas, un lakehouse conserva los archivos de origen, y los notebooks y pipelines ejecutan y orquestan el procesamiento. La figura 3.1 resume los tres flujos y las etapas que atraviesa cada uno.

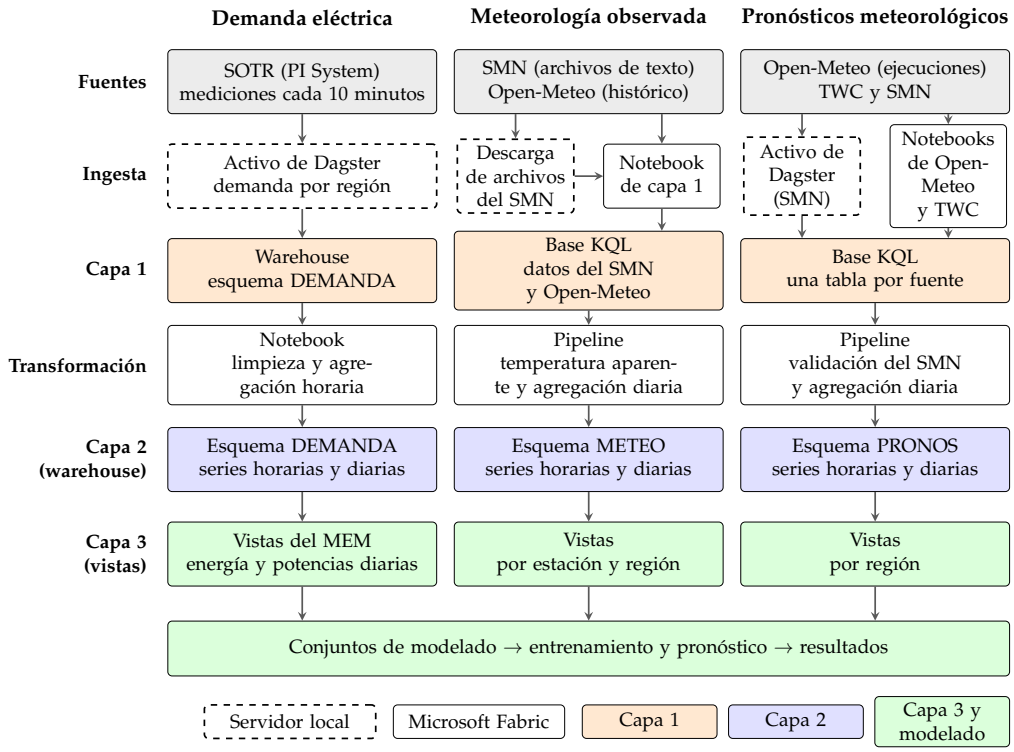


FIGURA 3.1. Diagrama general del pipeline de datos: flujos, etapas de procesamiento y capas de persistencia.

La persistencia se organizó en tres capas. La capa 1 conserva una representación cercana a la fuente, sin transformaciones irreversibles. La capa 2 contiene datos validados, tipificados e integrados con las dimensiones del warehouse, como las estaciones meteorológicas y las regiones eléctricas. La capa 3 está formada por vistas orientadas al consumo analítico y al modelado, como los agregados del MEM o los valores meteorológicos por región. La demanda constituye una excepción: al provenir de un proceso local, su capa 1 se escribe directamente en el warehouse. Esta separación permite repetir las transformaciones cuando se modifican las reglas de procesamiento, sin volver a consultar las fuentes. El apéndice A describe las tablas y vistas de cada esquema.

Sobre esta arquitectura se aplicaron los siguientes criterios, comunes a los tres flujos:

- Automatización: la obtención y la actualización de los datos se encapsularon en activos de Dagster, notebooks y pipelines, de modo que la ejecución diaria no requiera intervención manual.
- Preservación de la granularidad: la demanda se almacena con resolución de diez minutos y los datos meteorológicos con la resolución horaria o diaria de cada fuente. Las agregaciones se realizan en las capas posteriores.
- Reproceso sin duplicados: cada proceso recibe un período de fechas y reemplaza los registros de ese período, por lo que una ejecución puede repetirse sin generar versiones duplicadas de un mismo dato.
- Calidad y trazabilidad: los controles de completitud, coherencia y valores anómalos se aplican antes de generar las variables de entrenamiento, y los valores corregidos se conservan junto con los originales.

- Referencia temporal y geográfica común: las marcas temporales se expresan en hora local con la convención horaria de CAMMESA, y las estaciones y regiones se vinculan mediante dimensiones con períodos de vigencia.
- Coherencia entre entrenamiento y producción: cada variable se define de la misma manera para los datos observados, utilizados en el entrenamiento, y para los pronosticados, utilizados en la generación de pronósticos.

La información calendaria se obtiene de tablas existentes en las bases de datos de CAMMESA y se combina con las series eléctricas y meteorológicas mediante la fecha.

El último criterio condicionó el cálculo de la temperatura aparente. Open-Meteo pone a disposición esta variable a través de su API y la calcula según la formulación de Steadman [46], con las adaptaciones de su implementación [47], que se expresan en la ecuación 3.1:

$$AT = T + 0{,}348\, e - 0{,}70\, v_2 + 0{,}70\, \frac{Q}{v_2 + 10} - 4{,}25 \tag{3.1}$$

donde T es la temperatura del aire en °C, e es la presión de vapor en hPa, v_2 es la velocidad del viento a 2 m de altura en m/s y Q es la radiación absorbida. Estas tres magnitudes se obtienen según las ecuaciones 3.2, 3.3 y 3.4:

$$e = \frac{HR}{100}\, 6{,}105\, \exp\left(\frac{17{,}27\, T}{237{,}7 + T}\right) \tag{3.2}$$

$$v_2 = 0{,}75\, v_{10} \tag{3.3}$$

$$Q = \max\left(0;\ 0{,}1\,(G - 550)\right) \tag{3.4}$$

donde HR es la humedad relativa en porcentaje, v_{10} es la velocidad del viento a 10 m de altura en m/s y G es la radiación solar global en W/m^2.

En consecuencia, la temperatura aparente de los datos observados se calcula con la misma expresión. Se utilizan la temperatura, la humedad y el viento provistos por el SMN, y la radiación de Open-Meteo para la misma estación y hora (ya que el SMN no informa datos de radiación ni nubosidad observados). Una formulación sin radiación produciría valores sistemáticamente inferiores en las horas de mayor insolación, y el modelo recibiría en producción una variable con una distribución distinta de la utilizada durante el entrenamiento.

3.1.2. Flujo de demanda eléctrica

La demanda eléctrica constituye la variable objetivo de los modelos. Su flujo obtiene las mediciones del SOTR, calcula la demanda de cada región eléctrica con resolución de diez minutos y, a partir de ella, genera las series horarias depuradas y los valores diarios utilizados como objetivos de pronóstico.

Cálculo de la demanda regional

La demanda eléctrica se obtiene desde PI System mediante PIconnect. Debido a que esta fuente solo es accesible desde la red interna, la extracción se ejecuta en la infraestructura local. El proceso se implementó como un activo de Dagster que consulta valores interpolados con un paso de diez minutos, calcula la demanda por región eléctrica y escribe el resultado en el warehouse de Fabric.

El cálculo regional combina generación e intercambios medidos en el SOTR. Para la partición en regiones del SADI se utilizó la definición implementada por CAMMESA, que se presenta en la figura 3.2.



FIGURA 3.2. Regiones eléctricas del SADI según definición utilizada por CAMMESA.

La partición comprende las siguientes regiones:

- GBA: Ciudad Autónoma de Buenos Aires y partidos del Gran Buenos Aires.
- CEN: provincias de Córdoba y San Luis.
- LIT: provincias de Santa Fe y Entre Ríos.
- CUY: provincias de Mendoza y San Juan.
- NEA: provincias de Corrientes, Misiones, Chaco y Formosa.
- NOA: provincias de Salta, Jujuy, Catamarca, La Rioja, Tucumán y Santiago del Estero.
- COM: provincias de Rio Negro, Neuquén y La Pampa.
- PBA: provincia de Buenos Aires, excepto los partidos del Gran Buenos Aires.
- PAT: provincias de Chubut, Santa Cruz y Tierra del Fuego.

Para el pronóstico de demanda, la región PBA se divide en norte (PBN) y sur (PBS). Ambas subregiones presentan patrones de consumo distintos, en primer lugar por la variación de las condiciones climáticas asociada con la gran extensión territorial y, en segundo lugar, por las características de los usuarios, ya que el norte está notablemente más industrializado que el sur.

El SOTR provee medidores de demanda por regiones, pero no son aptos para el pronóstico de demanda debido a que no incluyen las pérdidas que se producen en las líneas eléctricas que vinculan las regiones. Por este motivo, fue necesario desarrollar un algoritmo que obtenga los valores de generación e intercambios de cada región y, realizando la sumatoria correspondiente, calcule la demanda. Por otra parte, se hizo una repartición de las pérdidas entre corredores, asignando la mitad a cada una de las regiones asociadas al vínculo.

En términos formales, sea G_r la generación de la región r, $\mathcal{N}_r$ el conjunto de regiones vinculadas y $F_{r\to j}$ y $F_{j\to r}$ las mediciones del intercambio en ambos extremos del corredor. La demanda regional se calcula según la ecuación 3.5:

$$D_r = G_r - \sum_{j\in\mathcal{N}_r} \frac{F_{r\to j} - F_{j\to r}}{2} \tag{3.5}$$

donde los intercambios son positivos cuando representan una exportación desde la región r. La semidiferencia entre las mediciones de ambos extremos permite repartir las pérdidas del corredor en partes iguales entre las regiones vinculadas.

La figura 3.3, tomada del SOTR, muestra el estado de generación e intercambio entre algunas regiones para un instante determinado.

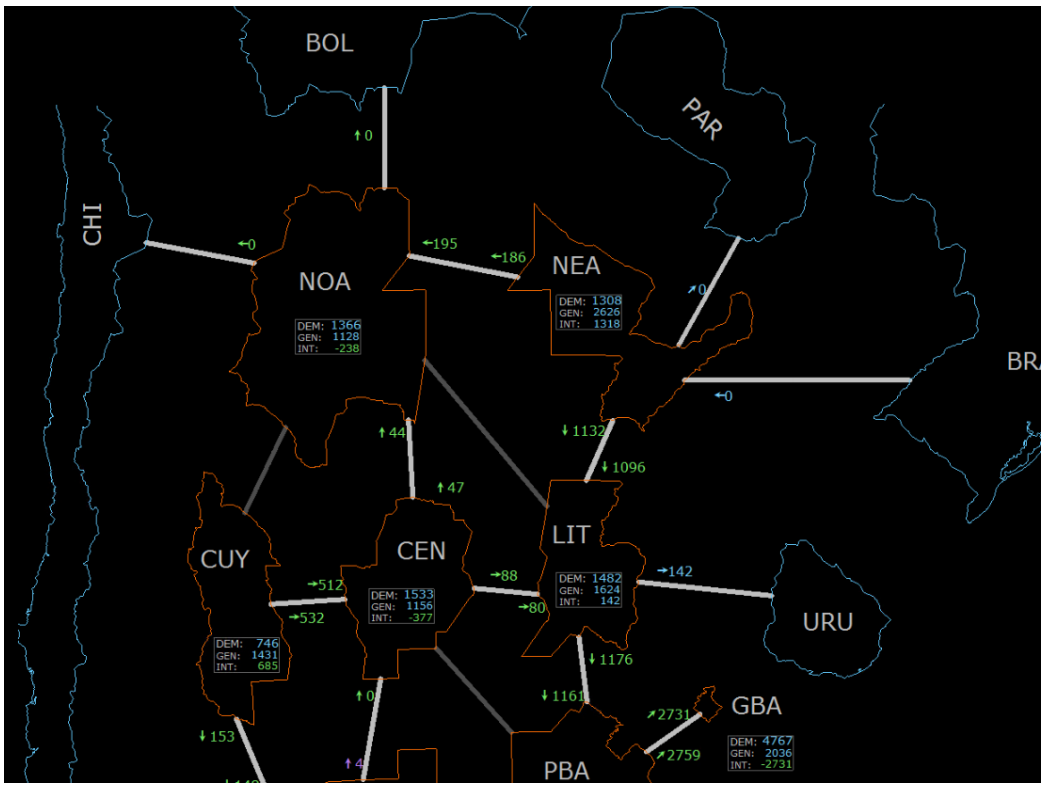


FIGURA 3.3. Generación e intercambios entre regiones. Imagen del SOTR de CAMMESA para un instante determinado.

A modo de ejemplo, la demanda de LIT corregida por pérdidas para el instante de la figura se calcula según la ecuación 3.6. El intercambio con Uruguay es igual en ambos extremos, ya que corresponde a un vínculo interno de la central Salto Grande.

$$D_{\mathrm{LIT}} = 1624 - \left[\frac{-1096 - 1132}{2} + \frac{-80 - 88}{2} + \frac{142 - (-142)}{2} + \frac{1176 - (-1161)}{2}\right] \tag{3.6}$$

Al resolver las operaciones, resulta:

$$D_{\mathrm{LIT}} = 1624 - (-1114 - 84 + 142 + 1168{,}5) = 1511{,}5\ \mathrm{MW} \tag{3.7}$$

El valor obtenido, de 1511,5 MW, difiere de los 1482 MW que resultan sin considerar las pérdidas. En caso de no aplicar esta corrección, la demanda nacional agregada presentaría un error considerable introducido en los datos de entrenamiento de los modelos.

La implementación de esta corrección requirió definir todos los intercambios entre regiones y consultar una cantidad de medidores del SOTR sustancialmente mayor que si se hubiesen podido utilizar los medidores de demanda existentes.

Por otra parte, se aplican ajustes específicos para representar de forma consistente la demanda utilizada en la programación. Entre ellos se encuentran la exclusión de consumos asociados con centrales de bombeo, que se ponen en servicio para almacenamiento de energía, y la demanda de grandes acerías que informan su consumo previsto.

El proceso genera también variables de control. La demanda MEM, calculada como suma de las regiones, se compara con un medidor nacional de referencia. Se almacenan la diferencia absoluta y porcentual entre ambos valores. Para PBA se conservan la demanda original, los valores directos de PBN y PBS y las diferencias asociadas con la partición. Asimismo, se calcula la suma de los intercambios internos, que debe permanecer próxima a cero porque las exportaciones de una región son importaciones de otra. Estos campos no constituyen objetivos de pronóstico, pero permiten verificar la coherencia del cálculo y detectar cambios en los medidores o en las reglas de negocio.

La salida se persiste en la tabla `DEMANDA.DEMANDA_REGIONES_10M`. Su clave está formada por fecha, hora e intervalo. Las columnas de demanda se almacenan en formato ancho, con una columna por región, junto con MEM y las variables de control. Esta tabla actúa como fuente para los procesos que generan resoluciones horarias y diarias.

La tarea de Dagster que ejecuta este proceso está programada cada 20 minutos, con el objetivo de mantener la tabla lo suficientemente actualizada para cualquier otro uso.

Resolución horaria y control de calidad

La transformación horaria se implementó en un notebook de Fabric. El proceso lee la tabla de diez minutos, controla la disponibilidad de nuevos registros y

procesa únicamente el intervalo necesario. Para admitir correcciones tardías en la fuente se vuelve a considerar el día anterior al último registro persistido. Si no existen horas nuevas completas, el notebook finaliza sin efectuar escrituras.

Una hora se considera completa cuando contiene los seis intervalos esperados de diez minutos. Este criterio evita calcular promedios horarios a partir de observaciones parciales. Luego, la tabla en formato ancho se transforma a formato largo, con una fila por fecha, hora y región. La transformación facilita aplicar reglas homogéneas de limpieza y vincular cada observación con la dimensión de regiones.

La limpieza se realiza en dos etapas. Primero se identifican valores extremos por región mediante el rango intercuartílico. Los límites se establecen a partir del primer y tercer cuartil y un factor de tres veces el rango intercuartílico. Los valores que quedan fuera de esos límites se reemplazan temporalmente por valores nulos y se estiman mediante interpolación lineal en el eje temporal. En la figura 3.4 puede verse un caso de corrección de valores extremos.

El método de eliminación de outliers es eficiente para fallas de medición, donde se alcanzan valores extremos durante intervalos breves. Las correcciones más desafiantes son aquellas que corresponden a fallas eléctricas reales del sistema eléctrico (por ejemplo, la desconexión intempestiva de una línea de transmisión que hace caer la demanda abruptamente). En estos casos, es deseable poder inferir el valor de demanda si no hubiese existido la falla, ya que, a los fines del entrenamiento de un modelo predictivo, esto representa un error que debe ser desestimado.

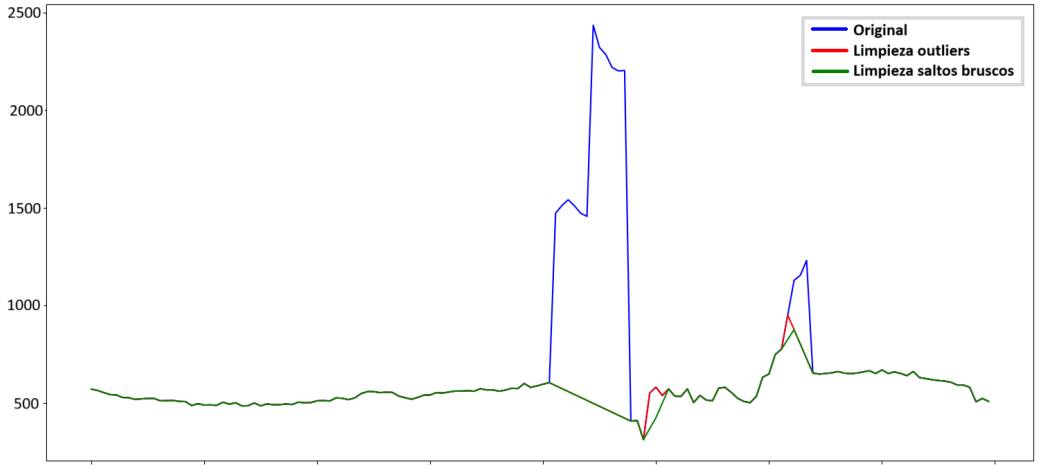


FIGURA 3.4. Corrección de valores extremos.

Por este motivo, en la segunda etapa se detectan escalones abruptos dentro de un mismo día. Un cambio se considera candidato a corrección cuando supera simultáneamente un umbral relativo del 7 % y un umbral absoluto de 100 MW. Estos valores fueron determinados a partir de la recomendación de los especialistas de CAMMESA en combinación con el análisis de amplios rangos temporales. La detección y corrección se ejecuta de manera iterativa, con un máximo de diez iteraciones. Los puntos identificados se interpolan y, cuando la interpolación no resulta posible en los extremos, se completan mediante propagación hacia adelante o hacia atrás. En la figura 3.5 puede verse un caso de corrección de saltos bruscos.

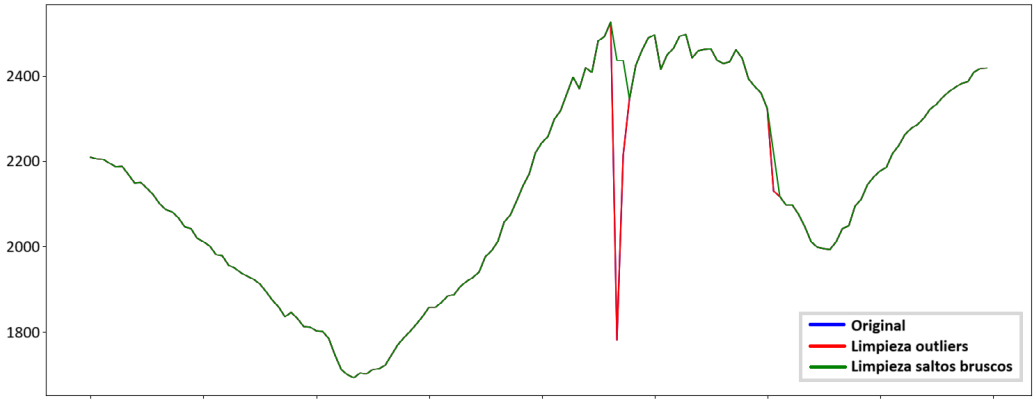


FIGURA 3.5. Corrección de saltos bruscos.

Después de la limpieza se calcula el promedio de los seis registros de cada hora. Se conservan tanto el valor resultante como el promedio obtenido a partir de los datos anteriores a la corrección. La columna `FLAG_CORREGIDO` indica si ambos valores difieren. De este modo, los modelos pueden utilizar la serie depurada sin perder la posibilidad de auditar qué observaciones fueron modificadas.

Cada registro se vincula con la dimensión regional mediante la clave `RGE_ID` y el período de vigencia correspondiente. La tabla final contiene `FECHA`, `HORA`, `RGE_ID`, `VALOR`, `FLAG_CORREGIDO` y `VALOR_ORIGINAL`. Antes de persistir, se verifica la existencia de la clave compuesta en el destino para evitar duplicados. Los registros nuevos se incorporan en `DEMANDA.DEMANDA_REGIONES_1H`.

A partir de la demanda horaria se obtienen las variables diarias utilizadas como objetivos. La vista `DEMANDA.DEMANDAS_MEM` suma los valores regionales de cada hora para obtener la demanda del MEM y, a partir de ella, calcula la energía diaria y las potencias máxima y mínima sobre los intervalos horarios definidos para cada variable. De este modo, los objetivos nacionales se derivan de una fuente regional común y puede comprobarse que el agregado del MEM sea consistente con sus componentes.

3.1.3. Flujo de datos meteorológicos observados

El flujo de datos meteorológicos observados integra las mediciones de las estaciones del SMN con los valores de Open-Meteo para las mismas ubicaciones. Estas series se utilizan para construir las variables explicativas empleadas en el entrenamiento de los modelos.

Ingesta en capa 1

La primera etapa se ejecuta en el notebook `NB_METEO_L1`. Para el SMN se procesan los archivos de observaciones diarias y de datos horarios. Para Open-Meteo se realizan consultas por coordenadas asociadas con estaciones de referencia. El rango de fechas se recibe como parámetro y, cuando no se informa, el notebook utiliza el día anterior a la ejecución.

Los archivos descargados del SMN se conservan en un lakehouse. Esta copia permite mantener el insumo original y volver a procesarlo si resulta necesario. Los datos interpretados se escriben en la base KQL `EH_PSYD`, utilizada como capa 1.

Allí se almacenan, entre otras variables, temperatura, humedad relativa, presión, dirección y velocidad del viento para la resolución horaria, y temperaturas máxima y mínima para la resolución diaria. Las tablas de Open-Meteo incorporan, además, temperatura aparente, nubosidad, precipitación y radiación solar, según la resolución de cada conjunto.

La persistencia en KQL se realiza por lotes y, cuando el volumen serializado supera el tamaño previsto para una operación, la carga se divide en bloques. El resultado de esta etapa es una representación cercana a las fuentes, separada por proveedor y resolución.

Transformación a capa 2

La transferencia desde la capa 1 hacia la capa 2 se orquesta mediante el pipeline `PPLN_METEO`, que se presenta en la figura 3.6. El pipeline ejecuta el notebook y consulta en el warehouse las estaciones cuya vigencia se superpone con el período procesado. Esta validación evita incorporar estaciones que no correspondan al intervalo analizado y permite asociar cada nombre de estación con su identificador `EMET_ID`.

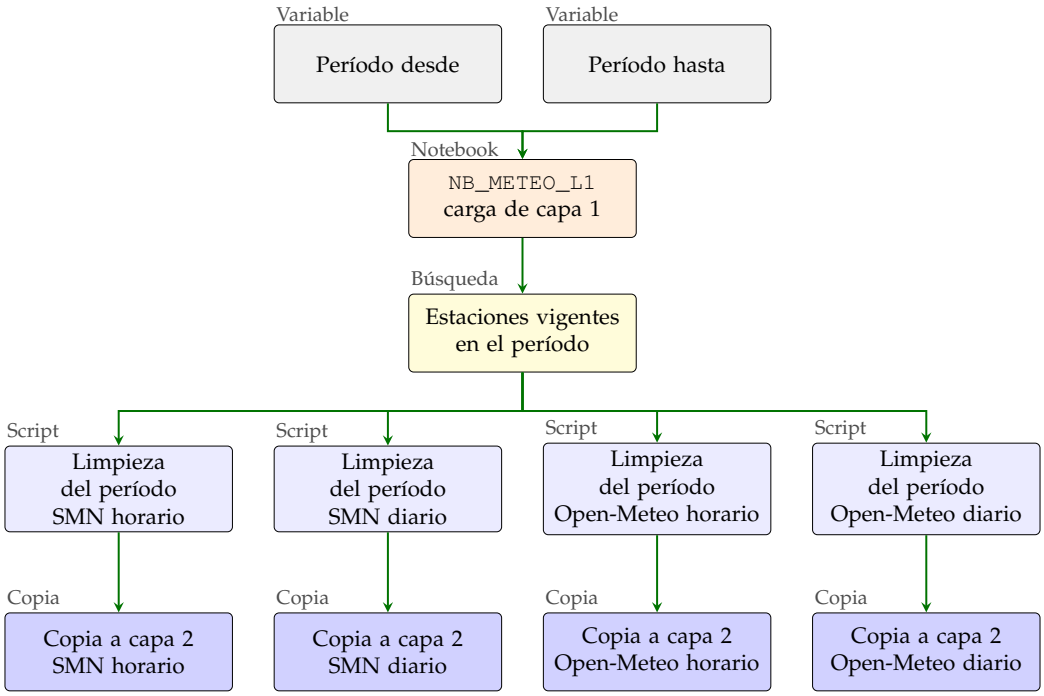


FIGURA 3.6. Pipeline de Fabric para la orquestación de datos meteorológicos observados.

Para los datos horarios del SMN, la actividad de copia filtra el rango de fechas, conserva las estaciones vigentes y construye la marca temporal `FECHA_HORA`. También ajusta la numeración horaria para compatibilizarla con la convención utilizada en CAMMESA. A partir de la temperatura, la humedad relativa y la velocidad del viento observadas, junto con la radiación de Open-Meteo, se calcula la temperatura aparente según la ecuación 3.1. Finalmente, las variables se redondean y tipifican antes de escribirlas en el esquema `METEO` del warehouse.

La escritura de los datos meteorológicos utiliza claves temporales y de estación. Para los valores horarios, la combinación de `FECHA_HORA` y `EMET_ID` identifica cada observación. Las tablas diarias emplean la fecha y el identificador de estación. Esta estructura permite comparar proveedores para una misma ubicación, seleccionar estaciones representativas de cada región eléctrica y construir agregados diarios sin perder el origen del dato.

3.1.4. Flujo de pronósticos meteorológicos

Los pronósticos meteorológicos constituyen la información exógena disponible al momento de estimar la demanda futura. A diferencia de una observación, un valor pronosticado depende de la fecha en que fue emitido. Para un mismo día objetivo existen tantos valores como ejecuciones del modelo lo incluyen, y su precisión disminuye a medida que aumenta la anticipación. Por este motivo, el flujo se diseñó para conservar cada ejecución identificada por su fecha de cálculo (`FECHA_CALCULO`) y por el modelo o servicio que la generó (`PRON_ID`). Esta estructura permite evaluar los modelos de demanda con la información que efectivamente habría estado disponible en cada fecha y evita utilizar observaciones posteriores como si fueran pronósticos.

Fuentes e ingesta en capa 1

La tabla 3.1 resume las fuentes incorporadas y el proceso que obtiene cada una.

TABLA 3.1. Fuentes de pronósticos meteorológicos incorporadas al pipeline.

Fuente	Proceso de ingesta	Resolución y horizonte	Variables principales
Open-Meteo (modelos IFS [48], ICON [49], GFS [50] y UKMO [51])	Notebook en Fabric.	Horaria, entre 7 y 16 días según el modelo.	Temperatura, temperatura aparente, humedad, presión, viento, nubosidad, precipitación y radiación solar.
The Weather Channel	Notebook en Fabric.	Diaria, con partes día y noche, hasta 15 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.
SMN	Activo de Dagster en el servidor local.	Diaria, con franjas de mañana y tarde, hasta 7 días.	Temperaturas máxima y mínima, viento, humedad y descripción del estado del tiempo.

Para Open-Meteo se utilizó la API de ejecuciones individuales (*Single Runs*) [52], que devuelve el horizonte completo de una inicialización específica de cada modelo. Se adoptó la ejecución de las 00 UTC (*Coordinated Universal Time*), que se publica durante la madrugada en Argentina y queda disponible antes del cálculo diario. La API de pronósticos históricos (*Historical Forecast*) de Open-Meteo [53] no resulta adecuada para este fin porque entrega una combinación de distintas ejecuciones, lo que no permite contar con la misma información que se utilizará en producción.

Los modelos, sus horizontes y sus períodos de vigencia se leen de una tabla del warehouse llamada `PRONOS.PRONOS_TOTALES`. El horizonte registrado para cada modelo corresponde a la última anticipación que este cubre en forma completa: 14 días para IFS, 15 para GFS y 6 para ICON y UKMO. Las consultas se realizan por las coordenadas de las estaciones vigentes en cada fecha de cálculo. El notebook de Open-Meteo recibe un rango de fechas, procesa cada ejecución de manera independiente y convierte las estampas de tiempo a hora local, con el mismo criterio aplicado a los datos observados.

La serie de una ejecución de las 00 UTC comienza a las 21 horas del día anterior en hora local, y la API cuenta los días solicitados desde ese momento. Por este motivo, se solicitan dos días más que el horizonte registrado: con la cantidad de días exacta, el último día pronosticado quedaría incompleto y se descartaría.

The Weather Channel (TWC) y el SMN solo publican el pronóstico vigente, por lo que su historia se construye a partir de la ejecución diaria. El SMN se consulta desde el servidor local mediante Dagster, por las restricciones de acceso descritas en el capítulo 2. Los resultados de todas las fuentes se almacenan en la base KQL, en una tabla de capa 1 por fuente.

Reconstrucción de la historia de pronósticos

El período de tiempo establecido para el conjunto de datos de test se fijó desde el 01/09/2025 hasta el 31/08/2026, con el objetivo de poder evaluar el desempeño de los modelos en todas las estaciones del año.

Sin embargo, no todas las fuentes tienen este período disponible. Open-Meteo conserva las ejecuciones del modelo IFS desde marzo de 2024 y las del resto de los modelos desde abril de 2026, mientras que el SMN y TWC no permiten recuperar pronósticos pasados. Para cubrir el período faltante se utilizaron archivos acumulados por un proceso previo de CAMMESA, con el que se completó la historia del SMN, TWC y el modelo ICON. Por lo tanto, para los modelos GFS y UKMO la fecha inicial quedó en abril de 2026. Los datos se cargaron en las tablas de capa 1 mediante un proceso implementado en un notebook de Fabric que los recuperó y acondicionó para almacenarlos con el mismo formato.

Los archivos del proceso previo están organizados por región eléctrica y no por estación. Cada región se asoció con una estación meteorológica: para el SMN y TWC, a partir de la localidad consultada; para el modelo ICON, mediante la estación cuya serie de Open-Meteo presentó menor diferencia con la serie del archivo en los períodos que se contaba con ambos pronósticos.

Transformación a capa 2 y orquestación

La capa 2 de pronósticos se compone de dos tablas del esquema `PRONOS`. La tabla horaria `L2_VALORES_HORARIOS_PRONOS` contiene los valores de Open-Meteo con la convención horaria utilizada en CAMMESA y la anticipación en días. La tabla diaria `L2_VALORES_DIARIOS_PRONOS` integra las tres fuentes con las mismas variables que la tabla diaria de observaciones.

Para Open-Meteo, los valores diarios se agregan a partir de los horarios con los criterios de los datos observados y solo se conservan los días con al menos 22 horas con dato de temperatura (para incluir el último día del horizonte, que queda desfasado por la zona horaria).

Para TWC y el SMN, los valores informados por franjas se asignan a las horas de referencia más próximas: el día a las 15 y la noche a las 21 horas, y la mañana y la tarde a las 8 y 15 horas, respectivamente. Esta asignación constituye una aproximación, dado que dichos valores representan un intervalo y no una hora puntual. Las variables que una fuente no provee quedan sin valor.

La comparación con las observaciones mostró que la temperatura mínima que TWC informa para un día corresponde a la noche siguiente, es decir, a la madrugada del día posterior: su error absoluto medio respecto de la mínima observada era de 2,7 °C, y se reducía a 1,8 °C al compararla con la mínima del día siguiente. Por este motivo, en la capa 2 la mínima de cada día se toma de la fila del día anterior de la misma consulta. Con esta corrección, TWC pasó a ser la fuente con menor error en la temperatura mínima desde la anticipación 1.

La orquestación se implementó en el pipeline `PPLN_PRONOS`, que se presenta en la figura 3.7. El pipeline recibe un período de fechas de cálculo y, en la ejecución diaria, procesa la fecha en curso. En primer lugar, ejecuta en paralelo los notebooks de Open-Meteo y TWC, junto con un notebook que verifica la carga del SMN realizada por Dagster. Esta validación espera hasta una hora a que estén disponibles todas las estaciones vigentes. Luego, cada tabla de capa 2 se actualiza mediante la eliminación previa del período a insertar. Si el pronóstico del SMN no se completa, la tabla diaria se actualiza igualmente con las fuentes restantes y la ejecución finaliza con error para advertir el faltante.

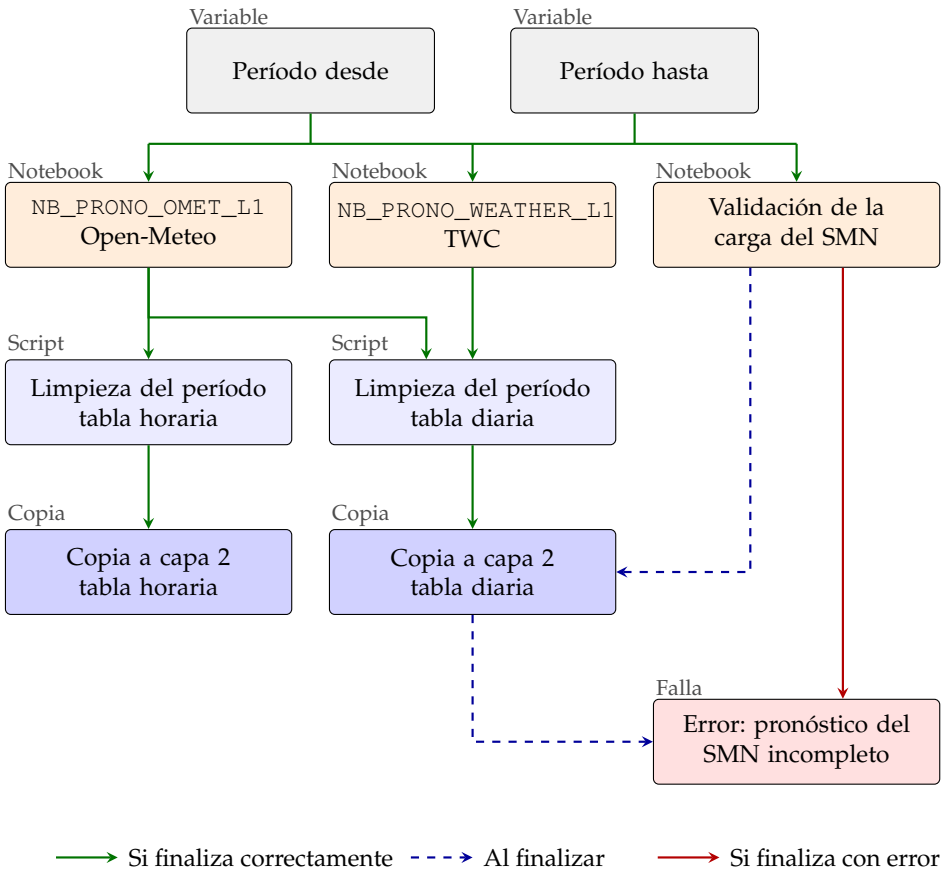


FIGURA 3.7. Pipeline de Fabric para la orquestación de pronósticos meteorológicos.

De esta manera, el flujo deja disponibles los pronósticos de cuatro modelos numéricos y dos servicios meteorológicos con una estructura común y con definiciones de variables compatibles con las observaciones. Sobre esta base se construyen las variables exógenas de los modelos descritos en las secciones siguientes.

3.2. Desarrollo de modelos

El desarrollo de los modelos tuvo como objetivo obtener pronósticos de la energía diaria (EN) y de las potencias pico (PI) y mínima (MI) de cada región eléctrica y del MEM, con un horizonte de 14 días. Se organizó en etapas sucesivas, en las que los resultados de cada una orientaron las decisiones de la siguiente:

1. Selección de un modelo de referencia entre algoritmos clásicos de aprendizaje automático.
2. Evaluación de modelos de aprendizaje profundo, de un modelo fundacional y de ensambles.
3. Definición de las covariables, de las fuentes meteorológicas y del nivel de agregación.
4. Representación de la respuesta de la demanda a la temperatura.
5. Corrección y combinación de los pronósticos.

Todos los modelos se implementaron con la biblioteca Darts, presentada en la sección 2.1, y comparten la formulación del problema. En cada fecha de cálculo D se dispone de la demanda observada hasta el día $D-1$, ya que el día en curso está incompleto, y se pronostican los días D a $D+14$, es decir, con anticipaciones de 0 a 14 días. El día D se incluye porque, en los modelos recursivos, su pronóstico constituye la entrada del día siguiente.

Los modelos se entrenan con la meteorología observada y predicen con los pronósticos meteorológicos emitidos en la fecha de cálculo, según la estructura descrita en la sección 3.1.4. De este modo, cada pronóstico de demanda utiliza la información que habría estado disponible en producción. Cada fuente meteorológica define un escenario de evaluación. El escenario con la meteorología observada se utiliza como referencia, ya que permite distinguir el error del modelo de demanda del error introducido por el pronóstico meteorológico. Cuando una fuente cubre un horizonte menor que 14 días, como el SMN o ICON, solo se evalúan las anticipaciones disponibles.

La evaluación se realizó mediante un esquema de origen móvil con reentrenamiento periódico y ventana de entrenamiento creciente, sobre el período de prueba comprendido entre el 01/09/2025 y el 31/08/2026. En cada fecha de reentrenamiento R, el modelo se entrena con los datos disponibles hasta $R-1$ y genera los pronósticos de todas las fechas de cálculo comprendidas hasta el siguiente reentrenamiento R', utilizando la demanda observada hasta el día anterior. La figura 3.8 ilustra el procedimiento.

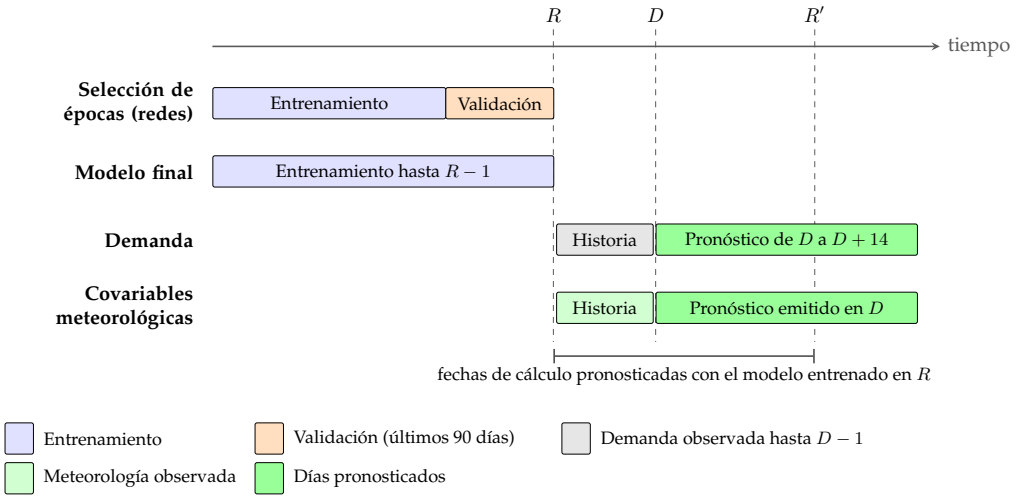


FIGURA 3.8. Esquema de validación con origen móvil: reentrenamiento en la fecha R y pronóstico de una fecha de cálculo D hasta el reentrenamiento siguiente R'.

Dentro de cada escenario, los modelos se comparan sobre el mismo conjunto de regiones, fechas de cálculo y anticipaciones, para evitar que las diferencias de cobertura entre fuentes o entre modelos afecten la comparación. Los modelos de cada reentrenamiento se almacenaron junto con sus parámetros de estandarización, lo que permitió evaluar escenarios adicionales sin reentrenar.

3.2.1. Selección del modelo de referencia

El modelo de referencia establece el nivel de desempeño que deben superar los modelos más complejos y constituye, además, una alternativa productiva de bajo costo computacional. Se evaluaron los algoritmos presentados en la sección 2.3.1: regresión lineal (RLIN), Random Forest (RF), XGBoost (XGB) y LightGBM (LGBM). Como referencia mínima se incorporó un modelo ingenuo estacional semanal (SNAIVE), que repite los valores de la última semana observada.

Se entrenó un modelo local por algoritmo, variable objetivo y región, con estrategia recursiva, los rezagos de 1, 2, 7 y 14 días de la variable objetivo y las covariables del día pronosticado. Se evaluó también una variante que incorpora las covariables de 1, 2 y 7 días antes del día pronosticado. Se utilizaron los hiperparámetros por defecto de cada biblioteca, ya que el propósito de esta etapa fue establecer una referencia y no optimizar cada algoritmo.

Las covariables se organizaron en cinco grupos de complejidad creciente, presentados en la tabla 3.2. Todos incluyen el cuadrado de la temperatura, necesario para que la regresión lineal represente la relación no lineal entre temperatura y demanda. Los dos primeros grupos difieren en la codificación del tipo de día. La codificación simple distingue días hábiles, sábados y domingos o feriados, mientras que la completa incluye una variable indicadora por día de la semana y el indicador de feriado, que toma valores fraccionarios en las jornadas de actividad reducida. El mes se representa mediante su seno y coseno, para preservar la continuidad entre diciembre y enero.

TABLA 3.2. Grupos de covariables evaluados en la selección del modelo de referencia.

Grupo	Calendario	Variables meteorológicas
G1	Codificación simple y mes.	Temperatura media y su cuadrado.
G2	Codificación completa y mes.	Temperatura media y su cuadrado.
G3	Codificación completa y mes.	Temperaturas máxima y mínima y sus cuadrados.
G4	Codificación completa y mes.	Temperaturas aparentes máxima, mínima y media, y sus cuadrados.
G5	Codificación completa y mes.	Variables de G4, humedad relativa y velocidad del viento a las 15 horas, nubosidad media y radiación solar acumulada.

Los grupos G1 a G3 utilizan variables que informan todas las fuentes de pronóstico, mientras que G4 y G5 requieren temperatura aparente, nubosidad y radiación, que solo proveen los modelos numéricos obtenidos de Open-Meteo. Por este motivo, cada fuente se evaluó únicamente con los grupos cuyas variables informa en al menos el 95 % de los registros.

La selección se realizó en dos fases. En la primera se eligió el grupo de covariables de cada algoritmo, variable objetivo y región. Para ello, se realizó una validación con origen móvil entre el 01/09/2024 y el 31/08/2025, con meteorología observada y reentrenamiento mensual, y se adoptó el grupo con menor MAPE promedio sobre las 15 anticipaciones. Las fechas de cálculo se limitaron de modo que todos los días pronosticados quedaran dentro de ese período, por lo que el conjunto de prueba no intervino en la elección. En la segunda fase, los modelos se evaluaron sobre el período de prueba con reentrenamiento semanal, con la meteorología observada y con los pronósticos de cada fuente. Cuando el grupo elegido requería variables que una fuente no provee, se utilizó el siguiente grupo del orden obtenido en la primera fase.

3.2.2. Modelos de aprendizaje profundo, fundacionales y ensambles

La segunda etapa evaluó si arquitecturas más recientes mejoran el pronóstico respecto del modelo de referencia. Se implementaron las redes recurrentes LSTM y GRU, las arquitecturas de múltiples pasos TFT, TiDE y TSMixer, y el modelo fundacional Chronos-2, presentados en las secciones 2.3 y 2.3.3, con la configuración de la tabla 3.3.

TABLA 3.3. Configuración de los modelos de aprendizaje profundo y fundacionales.

Modelo	Estrategia	Hiperparámetros principales
LSTM	Recursiva, día a día.	2 capas de 64 unidades; *dropout* 0,1.
GRU	Recursiva, día a día.	2 capas de 64 unidades; *dropout* 0,1.
TFT	Directa, 15 días.	Dimensión oculta 32; 4 cabezales de atención; *dropout* 0,1.
TiDE	Directa, 15 días.	Dimensión oculta 128; *dropout* 0,1.
TSMixer	Directa, 15 días.	2 bloques; dimensión oculta 64; *dropout* 0,1.
Chronos-2	Directa, 15 días.	Contexto de 512 días; sin ajuste y con ajuste mediante LoRA.

A diferencia del modelo de referencia, los modelos neuronales se entrenaron de forma global para cada variable objetivo: un mismo modelo aprende de las diez regiones, que se identifican mediante una covariable estática con codificación *one-hot*. En LSTM y GRU, que no admiten covariables estáticas en Darts, esa codificación se incorporó como covariables futuras constantes. El entrenamiento global multiplica la cantidad de ejemplos disponibles, lo que resulta relevante para redes con muchos más parámetros que los modelos basados en árboles. La variable objetivo y las covariables se estandarizaron por región con la media y el desvío del período de entrenamiento.

Se utilizó el grupo G5, que obtuvo el mejor desempeño en la primera fase de la selección del modelo de referencia. Los modelos reciben una ventana de 56 días, con sus covariables y las de los días pronosticados. TFT, TiDE y TSMixer generan los 15 días en un único paso, mientras que LSTM y GRU recorren la historia hasta $D - 1$ y avanzan un día por vez con las covariables del día pronosticado y su propia predicción del día anterior.

El entrenamiento utilizó la pérdida L1, el optimizador Adam con una tasa de aprendizaje de 10^{-3}, lotes de 64 ejemplos y semillas fijas. En cada reentrenamiento mensual se aplicó el procedimiento en dos pasos de la figura 3.8. En el primero, el modelo se entrenó con los datos disponibles hasta 90 días antes de la fecha de reentrenamiento, con detención temprana (*early stopping*) sobre esos 90 días, una paciencia de 5 épocas y un máximo de 50, para determinar la cantidad de épocas. En el segundo, se entrenó un modelo nuevo con todos los datos hasta $R-1$ durante esa cantidad de épocas. De este modo, la validación regula la extensión del entrenamiento sin excluir del modelo final los datos más recientes.

Chronos-2 se utilizó sin ajuste (*zero-shot*) a través de Darts y con ajuste mediante LoRA en cada reentrenamiento, a través de la biblioteca oficial del modelo, ya que Darts no admite su ajuste. El ajuste partió en cada caso del modelo preentrenado, con 500 pasos de optimización y una tasa de aprendizaje de 10^{-5}.

Para que la comparación con el modelo de referencia dependiera únicamente del modelo, LightGBM se volvió a evaluar con el grupo G5 y reentrenamiento mensual. Se incorporó, además, una variante con hiperparámetros ajustados (LGBM_OPT). La búsqueda se realizó con Optuna, con 50 pruebas por variable objetivo sobre el espacio de la tabla 3.4. Cada prueba se evaluó con el MAPE promedio de las 15 anticipaciones en una validación con origen móvil, con meteorología observada y reentrenamiento trimestral, entre el 01/09/2024 y el 31/08/2025. De este modo, la búsqueda no utilizó el período de prueba.

TABLA 3.4. Espacio de búsqueda de los hiperparámetros de LGBM_OPT.

Hiperparámetro	**Rango**
Cantidad de árboles	100 a 1000, en pasos de 50.
Tasa de aprendizaje	0,01 a 0,2, escala logarítmica.
Cantidad de hojas	8 a 128, escala logarítmica.
Mínimo de observaciones por hoja	5 a 100, escala logarítmica.
Fracción de observaciones por árbol	0,5 a 1.
Fracción de variables por árbol	0,5 a 1.
Regularización L2	10^{-3} a 10, escala logarítmica.

Sobre las predicciones de los modelos individuales se construyeron los dos ensambles descritos en la sección 2.3.4. ENS_PROM promedia las predicciones, mientras que ENS_STACK aplica un metamodelo de regresión lineal con pesos no negativos y sin término independiente, ajustado por variable objetivo, escenario y anticipación. En cada mes, el metamodelo se ajusta solo con las predicciones de los meses anteriores cuyo valor real ya se conoce, por lo que no utiliza información futura. Las observaciones se ponderan por la inversa del cuadrado del valor real, de modo que el ajuste minimiza el error relativo, coherente con el MAPE. Mientras no se dispone de 200 observaciones, o de 100 en las series del MEM, se utiliza el promedio.

3.2.3. Covariables, fuentes meteorológicas y nivel de agregación

La tercera etapa definió las covariables, las fuentes meteorológicas y el nivel de agregación de los pronósticos. A partir de los resultados de la etapa anterior, que se presentan en el capítulo 4, se mantuvieron SNAIVE, LGBM_OPT, GRU, LSTM, TSMixer y TFT, este último como representante de las arquitecturas basadas en atención. Los ensambles se construyeron con LGBM_OPT, GRU, LSTM y TSMixer. Además de la meteorología observada, se evaluaron los pronósticos de IFS, ICON y GFS. Este último solo está disponible desde abril de 2026, por lo que su evaluación se limita a ese período.

La temperatura aparente de G5 requiere humedad, viento y radiación, y solo la informan los modelos numéricos de Open-Meteo. Para evaluar si justifica esa dependencia y para aprovechar las fuentes que informan únicamente la temperatura del aire, como el SMN y TWC, se definió el grupo G5A, que reemplaza las temperaturas aparentes de G5 por las temperaturas del aire máxima y mínima.

El grupo G5A permite construir grupos de pronósticos, que son escenarios en los que cada variable se toma de la fuente y del rango de anticipaciones que se indiquen. Los grupos se definieron a partir del error de cada fuente respecto de las observaciones. TWC presentó el menor error en la temperatura máxima en todo el horizonte, mientras que IFS e ICON fueron más precisos en la humedad. La tabla 3.5 presenta los dos grupos evaluados. El primero responde a la práctica operativa del área de Programación Semanal y Diaria, que consulta el pronóstico del SMN para los primeros días. El segundo prescinde del SMN, por lo que su comparación con el primero mide el aporte de esa fuente.

TABLA 3.5. Grupos de pronósticos evaluados.

Grupo	Temperaturas máxima y mínima	Humedad, nubosidad y radiación	Viento
SMN + TWC + IFS	SMN en los días 0 a 6 y TWC en los días 7 a 14.	IFS	TWC
TWC + IFS	TWC	IFS	TWC

Se evaluó, además, la incorporación del Estimador Mensual de Actividad Económica (EMAE) del INDEC como indicador de la actividad económica. Para reproducir su disponibilidad en producción, cada fecha de cálculo utiliza el último valor publicado, que el INDEC difunde con un rezago de varios meses. Su aporte fue reducido y dispar entre modelos, por lo que no se incorporó, dado el costo de mantener una fuente externa adicional.

En cuanto al nivel de agregación, la energía del MEM puede obtenerse como suma de los pronósticos regionales o pronosticarse en forma directa como una única serie. Para el pronóstico directo, las covariables reúnen las variables meteorológicas de las diez regiones como columnas separadas. Como referencia del desempeño previo al trabajo, se incluyó una réplica de la regresión lineal utilizada en producción (RLIN_LEGACY), con sus mismas variables: temperaturas máximas y mínimas de siete estaciones de referencia con sus cuadrados y cubos, feriados del día, del día anterior y del siguiente, día de la semana agrupado, mes, humedad y nubosidad de GBA, y la energía del día anterior. La suma de los pronósticos regionales resultó más precisa, por lo que se adoptó para la energía. Las potencias pico y mínima, en cambio, no son aditivas, porque las regiones no alcanzan sus extremos en la misma hora, por lo que se pronostican en forma directa.

3.2.4. Representación de la respuesta a la temperatura

El análisis de los errores de la etapa anterior mostró que los modelos subestiman la demanda en los días de mayor consumo. Para representar mejor la respuesta de la demanda a la temperatura, se definieron los grupos G6 y G6A, que modifican G5 y G5A en tres aspectos: reemplazan los cuadrados de las temperaturas por los grados-día presentados en la sección 2.3.5, incorporan su persistencia y agregan los feriados vecinos.

Los grados-día de cada región se calculan con su temperatura media, aparente en G6 y del aire en G6A, y se acompañan de sus cuadrados, que permiten representar una respuesta que se acelera en los extremos. Los umbrales se estimaron por región con los dos años anteriores al período de prueba. Para cada región se ajustó, por mínimos cuadrados, un modelo de la energía diaria en función de la tendencia, el feriado, el día de la semana y los dos tramos de temperatura, y se eligieron los umbrales de menor error en una grilla de 0,5 °C. La tabla 3.6 presenta los valores obtenidos. Las diferencias entre regiones son marcadas, y GBA presenta la zona de confort más alta.

TABLA 3.6. Umbrales de grados-día por región eléctrica, en °C.

	Temperatura aparente		Temperatura del aire	
Región	**Refrigeración**	**Calefacción**	**Refrigeración**	**Calefacción**
CEN	20,0	12,5	20,0	15,5
COM	17,0	12,5	19,5	15,5
CUY	17,5	13,0	20,5	15,5
GBA	23,0	17,0	22,0	18,0
LIT	21,0	14,0	21,0	16,0
NEA	22,0	12,5	21,0	15,0
NOA	21,0	14,5	21,0	15,5
PAT	14,5	14,5	19,0	17,0
PBN	21,5	15,5	21,0	18,5
PBS	17,0	12,0	19,5	16,0

La persistencia se representa con la suma de los CDD y de los HDD de los tres días anteriores. Los grados-día se calculan después de combinar la meteorología observada hasta $D-1$ con la pronosticada desde D, por lo que la persistencia de los días pronosticados incorpora también valores pronosticados. Los feriados

vecinos son indicadores de feriado del día anterior y del día siguiente, que la regresión de producción ya utilizaba. Sin ellos, LightGBM, que solo recibe las covariables del día pronosticado, y LSTM, que no conoce las del día siguiente, no pueden representar el efecto de los días puente.

Con el mismo objetivo se agregó una variante de LGBM_OPT, identificada como LGBM_OPT_PESOS, en la que los días con demanda superior al percentil 90 del entrenamiento pesan tres veces más que el resto. Ambas variantes comparten los hiperparámetros, que se volvieron a ajustar con Optuna para los grupos G6 y G6A, por lo que su comparación aísla el efecto de la ponderación. Para reducir el costo de entrenamiento, en esta etapa se mantuvieron SNAIVE, LGBM_OPT, LSTM y TSMixer, y los ensambles se construyeron con LGBM_OPT, LSTM y TSMixer.

La tabla 3.7 resume las configuraciones evaluadas en esta etapa y en la anterior, que se identifican por el nivel de agregación y el grupo de covariables. Los resultados del capítulo 4 se presentan con esta denominación.

TABLA 3.7. Configuraciones de modelos evaluadas.

Configuración	Variables objetivo	Modelos
Regional G5	EN de cada región.	SNAIVE, LGBM_OPT, GRU, LSTM, TSMixer, TFT y ensambles.
Regional G5A	EN de cada región.	SNAIVE, LGBM_OPT, GRU, LSTM, TSMixer, TFT y ensambles.
MEM G5	EN, PI y MI del MEM.	Modelos de Regional G5 y RLIN_LEGACY.
Regional G6	EN y PI de cada región.	SNAIVE, LGBM_OPT, LGBM_OPT_PESOS, LSTM, TSMixer y ensambles.
Regional G6A	EN de cada región.	SNAIVE, LGBM_OPT, LGBM_OPT_PESOS, LSTM, TSMixer y ensambles.
MEM G6	EN, PI y MI del MEM.	SNAIVE, LGBM_OPT, LGBM_OPT_PESOS, LSTM, TSMixer y ensambles.
MEM G6A	EN, PI y MI del MEM.	SNAIVE, LGBM_OPT, LGBM_OPT_PESOS, LSTM, TSMixer y ensambles.

Las configuraciones con temperatura del aire, G5A y G6A, se evaluaron también con los grupos de pronósticos de la tabla 3.5. En las configuraciones regionales, la energía del MEM se obtiene como suma de las regiones.

3.2.5. Corrección y combinación de los pronósticos

La última etapa incorporó correcciones que no requieren reentrenar los modelos. Todas utilizan solo información disponible en la fecha de cálculo.

En primer lugar, los pronósticos de temperatura de cada fuente se corrigieron con el método descrito en la sección 2.3.5. Para cada fuente, región, variable de temperatura y anticipación, el sesgo en la fecha de cálculo D se estima como el error medio de los pronósticos de los días $D-30$ a $D-1$, ya observados en D, y se resta del valor pronosticado. Se requieren al menos 15 días con error conocido. Por ejemplo, en verano IFS pronostica temperaturas aparentes máximas entre 0,8 y 1,5 °C inferiores a las observadas. Las fuentes corregidas se agregaron como escenarios de las configuraciones con G6 y G6A. Dado que el sesgo de los últimos 30 días anticipa mejor el error de los días próximos que el de dos semanas después,

se construyeron también escenarios híbridos, que utilizan el pronóstico corregido hasta la anticipación 6 y el pronóstico original desde la anticipación 7.

En segundo lugar, para cada modelo se promediaron las predicciones obtenidas con IFS híbrido, con el grupo TWC + IFS híbrido y con ICON corregido, este último solo en las anticipaciones 0 a 6, que son las que cubre. Dado que el grupo TWC + IFS requiere la temperatura del aire, el promedio combina las configuraciones con G6 y con G6A del mismo nivel de agregación.

Por último, sobre el promedio se aplicó una corrección del sesgo reciente de los pronósticos de demanda. En la fecha de cálculo D, cada predicción $\hat{y}$ se corrige según la ecuación 3.8:

$$\hat{y}' = \frac{\hat{y}}{1 + s_D/100} \tag{3.8}$$

donde s_D es el error porcentual medio de los pronósticos de anticipación 0 de la misma serie en los 28 días anteriores a D, ya conocidos en esa fecha. Se requieren al menos 14 días con error conocido. Se evaluó, además, una corrección condicional, que estima el sesgo según el nivel de la predicción y el tramo de anticipación, pero su aporte fue despreciable y no se incorporó.

La configuración productiva, presentada en la sección siguiente, se eligió a partir de la comparación del capítulo 4.

3.3. Integración y puesta en producción

La puesta en producción integra el pipeline de datos y los modelos seleccionados en un proceso automático que genera diariamente los pronósticos de demanda, los almacena junto con la información necesaria para su trazabilidad y calcula sus métricas a medida que se dispone de los valores reales. La solución se implementó íntegramente sobre Microsoft Fabric y reutiliza los criterios aplicados en el pipeline de datos: procesos parametrizados por fecha, cargas idempotentes y validaciones previas a la escritura.

3.3.1. Configuración productiva

Para generar los pronósticos se utiliza el ensamble ENS_STACK, que combina LGBM_OPT, LSTM y TSMixer con las covariables de la sección 3.2.4, y con las correcciones de la sección 3.2.5. Se mantienen cuatro conjuntos de modelos, que corresponden a las configuraciones con G6 y G6A de la tabla 3.7:

- Energía de cada región, con temperatura aparente y con temperatura del aire. La energía del MEM se obtiene como suma de las regiones.
- Potencias pico y mínima del MEM, con pronóstico directo y las mismas dos variantes de temperatura.

Para cada variable, el pronóstico publicado es el promedio de las predicciones obtenidas con IFS híbrido, con el grupo TWC + IFS híbrido y con ICON corregido, este último en las anticipaciones 0 a 6. Al promedio se le aplica la corrección del sesgo reciente. Si una fuente no está disponible en la fecha de cálculo, el promedio

se calcula con las restantes. IFS es la única fuente obligatoria; si falta, se utiliza GFS en su lugar.

3.3.2. Arquitectura de ejecución

La figura 3.9 presenta los componentes del sistema en producción. El proceso diario se orquesta mediante el pipeline `PPLN_MODELOS`, que se ejecuta una vez finalizada la carga de pronósticos meteorológicos de `PPLN_PRONOS`. El reentrenamiento se orquesta en un pipeline independiente, `PPLN_REENTRENO`, con frecuencia semanal. Ambos procesos leen las vistas de capa 3 de los esquemas `DEMANDA`, `METEO` y `PRONOS`, de modo que los modelos consumen en producción los mismos datos que se utilizaron durante el desarrollo.

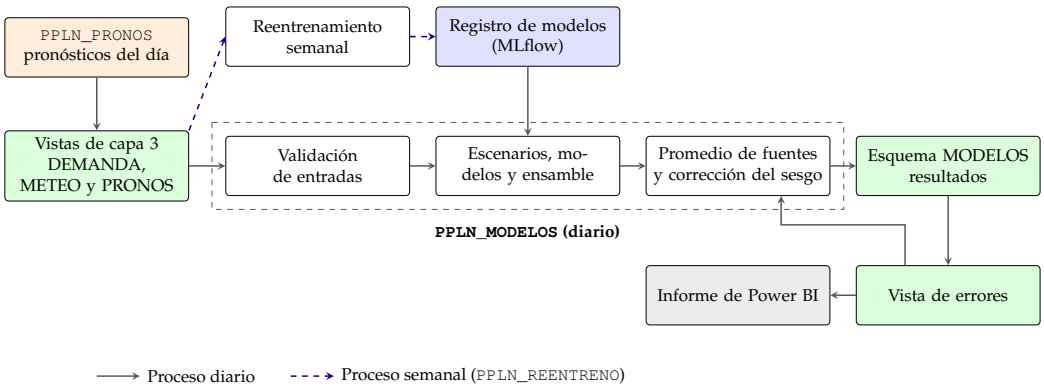


FIGURA 3.9. Arquitectura del sistema de pronóstico en producción.

La construcción de las series de entrada y de las covariables se encapsuló en un módulo de Python compartido por los notebooks de desarrollo, de reentrenamiento y de generación de pronósticos. El módulo incluye la estandarización, los grados-día con los umbrales de cada región, la corrección de los pronósticos meteorológicos, la construcción de los grupos de pronósticos y el postproceso. De esta forma, las transformaciones aplicadas en producción coinciden exactamente con las utilizadas durante la evaluación, y se evita que el modelo reciba variables con definiciones o escalas distintas de las del entrenamiento.

3.3.3. Generación diaria de pronósticos

El pipeline diario comienza con un notebook de validación que verifica las condiciones necesarias para pronosticar. Se controla que la demanda del día anterior esté completa, con las 24 horas de todas las regiones, y que IFS, o GFS en su reemplazo, disponga de la ejecución del día con todas las variables requeridas para los 15 días del horizonte. También se registra la disponibilidad de las demás fuentes. Si no se cumplen las condiciones, la ejecución finaliza con error y no se escriben resultados parciales.

A continuación, el notebook de pronóstico construye los escenarios meteorológicos del día: corrige los pronósticos de temperatura con el sesgo de los últimos 30 días, calculado a partir de las vistas de pronósticos y de observaciones, arma los escenarios híbridos y el grupo TWC + IFS. Luego obtiene del registro de modelos la versión vigente de cada modelo y genera, para cada escenario, los pronósticos

de los días D a $D + 14$ con la demanda observada hasta $D - 1$. Las predicciones de LGBM_OPT, LSTM y TSMixer se combinan con los pesos de ENS_STACK vigentes.

Finalmente, el notebook de postproceso promedia los escenarios disponibles y aplica la corrección del sesgo reciente, con los errores de los últimos 28 días obtenidos de la vista de errores. La corrección se aplica a cada serie publicada: la energía de cada región y la energía, la potencia pico y la potencia mínima del MEM.

Los resultados se escriben en dos tablas del esquema `MODELOS`. La primera conserva las predicciones de cada modelo y escenario, con la versión del modelo que las generó, y permite comparar en forma continua el efecto de cada fuente meteorológica. La segunda contiene el pronóstico publicado, junto con el valor previo a la corrección del sesgo. Ambas se describen en el apéndice A. Como en el resto del pipeline, la escritura elimina previamente los registros de la fecha de cálculo procesada, por lo que una ejecución puede repetirse sin generar duplicados.

3.3.4. Reentrenamiento y registro de modelos

El reentrenamiento reproduce el procedimiento aplicado durante el desarrollo, con una frecuencia semanal. Se ejecuta los domingos y entrena cada modelo productivo con todos los datos disponibles hasta el día anterior. En los modelos neuronales se aplica el mismo procedimiento en dos pasos: la cantidad de épocas se determina con detención temprana sobre los últimos 90 días y el modelo final se entrena con la totalidad de los datos. El entrenamiento se ejecuta en notebooks de Fabric sin GPU, ya que LSTM y TSMixer tienen pocos parámetros y su entrenamiento requiere pocos minutos. En la misma ejecución se actualizan los pesos de ENS_STACK con las predicciones almacenadas cuyo valor real ya se conoce.

Los hiperparámetros de LGBM_OPT y los umbrales de los grados-día se mantienen fijos entre reentrenamientos. Los hiperparámetros se vuelven a ajustar con Optuna solo cuando cambian las covariables, y los umbrales se recalculan una vez por año con los dos años más recientes, porque cambian lentamente con el equipamiento de los usuarios.

Cada modelo entrenado se registra en MLflow junto con sus parámetros de estandarización, sus hiperparámetros, el período de datos utilizado, la cantidad de épocas y el error obtenido sobre el último mes. La nueva versión reemplaza a la vigente solo si su error en ese período no supera al de la versión anterior en más de un 10 %. En caso contrario, se mantiene la versión vigente y se emite una notificación para su revisión. Dado que cada pronóstico almacenado incluye la versión del modelo que lo generó, es posible reconstruir en cualquier momento qué modelo y qué datos produjeron un valor determinado.

3.3.5. Monitoreo del desempeño

La vista `MODELOS.ERRORES_MODELOS` vincula cada pronóstico con el valor real de la variable objetivo y calcula el error, el error absoluto y el error porcentual absoluto. Los valores reales se toman de la vista `DEMANDAS_DIARIA_REGIONES` para las regiones y de `DEMANDAS_MEM` para el MEM, ambas del esquema `DEMANDA`.

Los valores se incorporan automáticamente a medida que se completa la demanda de cada día, de modo que las métricas se actualizan sin intervención manual. La misma vista provee los errores que utiliza la corrección del sesgo reciente.

Sobre esta vista se construyó un informe de Power BI que presenta el MAE, el RMSE y el MAPE en ventanas móviles, desagregados por modelo, variable objetivo, región, anticipación y fuente meteorológica. El informe permite comparar el desempeño reciente con el obtenido en la evaluación del capítulo 4, seguir el comportamiento de los modelos en los días de alta demanda y analizar períodos particulares, como olas de calor o feriados.

Capítulo 4

Ensayos y resultados

En este capítulo se presentan los resultados obtenidos en cada etapa del desarrollo de los modelos descrito en la sección 3.2. En primer lugar, se define el plan de evaluación: los conjuntos de datos, las métricas y las condiciones de comparación. A continuación, se presentan los resultados de cada etapa, que fundamentan las decisiones adoptadas en la siguiente, y se analizan los errores de la configuración seleccionada. Finalmente, se describen los ensayos del sistema integrado en producción.

4.1. Plan de evaluación

La evaluación tuvo como objetivo comparar los modelos en las mismas condiciones en las que operarían en producción. Por este motivo, los resultados de este capítulo se obtuvieron mediante el esquema de origen móvil presentado en la figura 3.8: en cada fecha de cálculo se utiliza solo la demanda observada hasta el día anterior y los pronósticos meteorológicos emitidos ese día, y los modelos se reentrenan periódicamente con todos los datos disponibles hasta ese momento.

Los datos utilizados comienzan el 01/01/2021. La tabla 4.1 presenta los períodos que se utilizaron para cada propósito. El período de prueba no intervino en ninguna decisión de diseño: la selección de covariables, la búsqueda de hiperparámetros y la estimación de los umbrales de los grados-día utilizaron solo datos anteriores al 01/09/2025.

TABLA 4.1. Períodos utilizados en el entrenamiento y la evaluación de los modelos.

Conjunto	**Período**	**Uso**
Entrenamiento	Desde el 01/01/2021 hasta el día anterior a cada reentrenamiento.	Ajuste de los modelos, con ventana creciente.
Validación	Últimos 90 días previos a cada reentrenamiento.	Determinación de la cantidad de épocas de las redes neuronales.
Validación	01/09/2024 a 31/08/2025.	Selección de los grupos de covariables del modelo de referencia y búsqueda de hiperparámetros de LGBM_OPT.
Validación	01/09/2023 a 31/08/2025.	Estimación de los umbrales de los grados-día.
Prueba	01/09/2025 a 31/08/2026.	Fechas de cálculo de todos los resultados de este capítulo.

4.1.1. Métricas

Se utilizaron las métricas definidas en la sección 1.4: el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE). Se agregó, además, el error porcentual medio, que mide el sesgo del pronóstico. Para un conjunto de n pronósticos $\hat{y}_i$ con valores observados y_i, y con el error definido como $e_i = \hat{y}_i - y_i$, las métricas se calculan según las ecuaciones 4.1 a 4.4:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i| \tag{4.1}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}e_i^2} \tag{4.2}$$

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{e_i}{y_i}\right| \tag{4.3}$$

$$\mathrm{Sesgo} = \frac{100}{n}\sum_{i=1}^{n}\frac{e_i}{y_i} \tag{4.4}$$

Un sesgo positivo indica que el modelo sobreestima la demanda, y uno negativo, que la subestima. El MAPE se adoptó como métrica principal, porque permite comparar variables y niveles de agregación de distinta magnitud y es la métrica habitual en el área de Programación Semanal y Diaria. El MAE y el RMSE se expresan en GWh para la energía y en MW para las potencias. El RMSE penaliza en mayor medida los errores grandes, por lo que su comparación con el MAE indica la presencia de días con errores elevados.

Las métricas se calculan por anticipación, de 0 a 14 días, y como promedio de todas las anticipaciones. En los gráficos, el MAPE se presenta en función de la anticipación, y la distribución del error porcentual de cada anticipación se representa mediante diagramas de caja, que muestran el sesgo y la dispersión de los errores.

4.1.2. Alcance y condiciones de comparación

Para acotar la extensión del capítulo, los resultados se presentan para el MEM. Las métricas de cada región eléctrica no se incluyen, aunque se calcularon con el mismo procedimiento y se encuentran disponibles en el sistema de monitoreo. En las configuraciones regionales, la energía del MEM se obtiene como suma de los pronósticos de las diez regiones, y se consideran solo las fechas en las que se dispone del pronóstico de todas ellas. Las potencias pico y mínima del MEM corresponden al pronóstico directo.

Los resultados se presentan por escenario meteorológico. El escenario con meteorología observada mide el error propio del modelo de demanda, mientras que el escenario con el pronóstico de IFS representa las condiciones de producción. IFS se adoptó como escenario principal porque es la única fuente con pronósticos de 15 días durante todo el período de prueba. ICON cubre solo las anticipaciones 0

a 6, y GFS está disponible desde el 02/04/2026. Por lo tanto, sus métricas no son comparables con las de los demás escenarios y solo se mencionan cuando aportan información adicional.

Dentro de cada escenario, los modelos se comparan sobre el mismo conjunto de fechas de cálculo y anticipaciones. Cuando se comparan escenarios entre sí, el conjunto se restringe además a las fechas disponibles en todos ellos. Por último, para analizar el desempeño en las condiciones más exigentes para la operación, se definen como días de alta demanda aquellos en los que la variable observada supera el percentil 90 de su distribución en el período de entrenamiento comprendido entre el 01/01/2021 y el 31/08/2025.

4.2. Evaluación del modelo

Los resultados se presentan en el orden de las etapas descritas en la sección 3.2. Cada etapa se compara con la anterior, de modo que se identifique el aporte de cada decisión al desempeño final.

4.2.1. Modelo de referencia

La tabla 4.2 presenta las métricas de la energía del MEM obtenidas por los modelos evaluados en la selección del modelo de referencia, con las covariables del día pronosticado. LightGBM y XGBoost obtuvieron los menores errores, con resultados prácticamente equivalentes: con la meteorología observada, el MAPE fue de 2,37 % y 2,42 %, respectivamente, y con el pronóstico de IFS, de 4,66 % y 4,60 %. Random Forest presentó errores algo mayores, mientras que la regresión lineal presentó un MAPE superior al 7 % en ambos escenarios, cercano al del modelo ingenuo estacional. Este resultado indica que la relación entre la demanda y sus covariables no se representa adecuadamente con una combinación lineal, aun con los cuadrados de las temperaturas.

TABLA 4.2. Métricas de la energía del MEM de los modelos evaluados en la selección del modelo de referencia, promedio de las anticipaciones 0 a 14. MAPE y sesgo en %, RMSE en GWh.

	Meteorología observada			**Pronóstico IFS**		
Modelo	**MAPE**	**RMSE**	**Sesgo**	**MAPE**	**RMSE**	**Sesgo**
LightGBM	2,37	12,4	−1,44	4,66	27,0	−0,80
XGBoost	2,42	12,9	−1,38	4,60	26,8	−0,75
Random Forest	2,89	15,3	−1,22	4,84	27,8	−0,58
Regresión lineal	7,79	38,6	−0,80	8,20	41,1	−0,52
SNAIVE	9,14	48,2	0,66	9,15	48,2	0,71

La figura 4.1 muestra el MAPE en función de la anticipación. Con la meteorología observada, el error de los modelos basados en árboles aumenta entre la anticipación 0 y la 1 y luego se mantiene casi constante, con un MAPE de LightGBM de 1,76 % en el día 0 y de 2,52 % en el día 14. Con el pronóstico de IFS, en cambio, el error crece en forma sostenida con la anticipación, desde 2,11 % hasta 7,79 %. La diferencia entre ambos escenarios muestra que, a partir de los primeros días, el

error del pronóstico meteorológico supera al error propio del modelo de demanda y determina la evolución del error con el horizonte. Estos valores se ubican en el rango que documentaban las evaluaciones internas de CAMMESA, de aproximadamente 3 % para el día siguiente y 10 % para los horizontes más alejados, mencionadas en la sección 1.3.

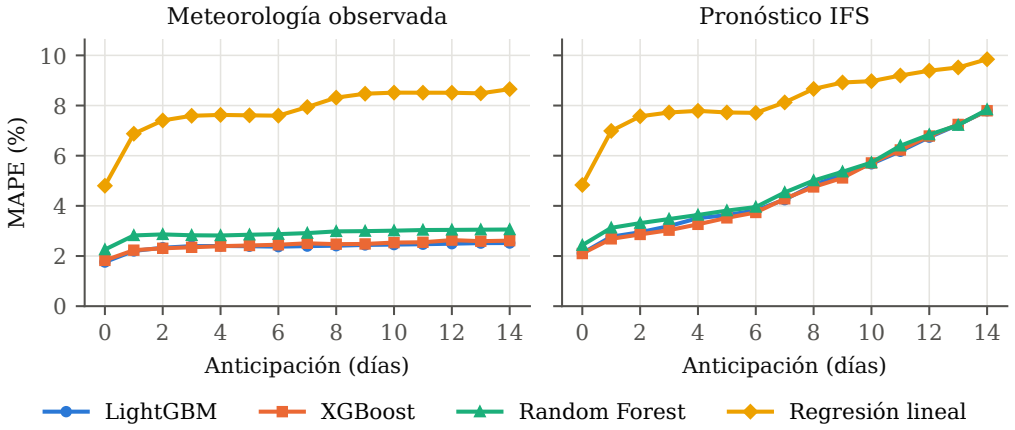


FIGURA 4.1. MAPE de la energía del MEM por anticipación de los modelos evaluados en la selección del modelo de referencia.

La figura 4.2 presenta la distribución del error porcentual de LightGBM con el pronóstico de IFS. La mediana se mantiene cerca de cero en todo el horizonte, con una leve tendencia a la subestimación, mientras que la dispersión aumenta con la anticipación. El intervalo entre los percentiles 5 y 95 pasa de $-4{,}9$ % a 3,9 % en el día 0 a $-17{,}2$ % a 16,1 % en el día 14.

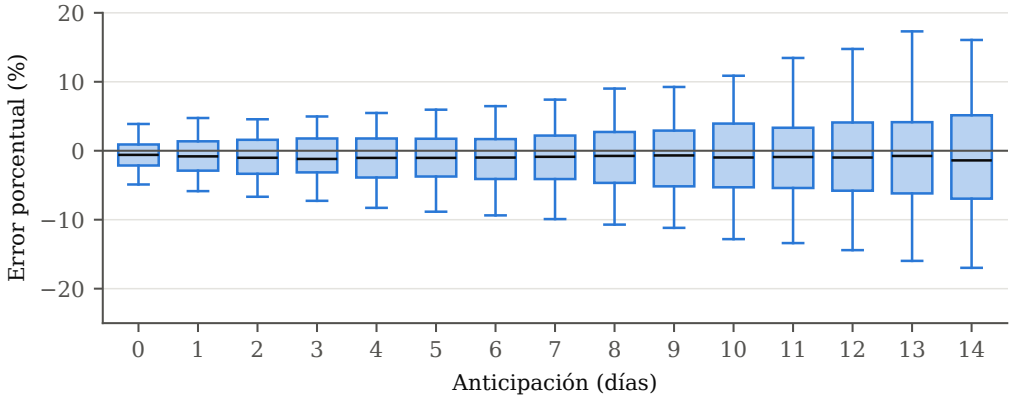


FIGURA 4.2. Distribución del error porcentual de la energía del MEM por anticipación de LightGBM con el pronóstico de IFS. Las cajas representan los percentiles 25 y 75, y los bigotes, los percentiles 5 y 95.

La variante que incorpora las covariables de los días anteriores al pronosticado no modificó el desempeño de los modelos basados en árboles. El MAPE de LightGBM fue de 2,29 % con la meteorología observada y de 4,67 % con IFS, frente a 2,37 % y 4,66 % sin esas covariables. La regresión lineal mejoró, de 7,79 % a 7,17 % con la meteorología observada, aunque sin alcanzar a los demás modelos.

Por lo tanto, se mantuvo la formulación con las covariables del día pronosticado, que es más simple. Entre LightGBM y XGBoost, se eligió LightGBM como modelo de referencia por su menor costo de entrenamiento, ya que su desempeño fue equivalente.

4.2.2. Modelos de aprendizaje profundo y fundacionales

La tabla 4.3 presenta las métricas de la energía del MEM obtenidas en la segunda etapa. En esta etapa, la historia de pronósticos de IFS disponible cubría las anticipaciones 0 a 12, por lo que las métricas de ese escenario corresponden a ese rango. La tabla incluye el tiempo medio de cada reentrenamiento mensual de los modelos entrenados con GPU.

TABLA 4.3. Métricas de la energía del MEM de los modelos de aprendizaje profundo y fundacionales, y tiempo medio de entrenamiento. MAPE y sesgo en %, RMSE en GWh y tiempo en segundos.

	Meteorología observada		**Pronóstico IFS**			
Modelo	**MAPE**	**RMSE**	**MAPE**	**RMSE**	**Sesgo**	**Tiempo**
TSMixer	1,63	8,6	3,93	23,0	0,16	98
TFT	1,79	9,6	4,10	23,6	0,00	634
GRU	1,85	10,1	3,99	23,4	0,16	24
LSTM	1,90	10,1	3,97	23,2	−0,04	24
LGBM_OPT	2,29	11,8	4,14	24,0	−0,85	–
TiDE	2,32	12,0	4,20	24,0	−0,21	80
LightGBM	2,39	12,7	4,22	24,3	−0,88	–
Chronos-2 ajustado	2,99	15,3	4,70	25,8	0,17	338
Chronos-2 sin ajuste	3,55	18,9	4,98	27,3	−0,53	–
SNAIVE	9,14	48,2	8,99	47,5	0,71	–

Con la meteorología observada, todas las redes neuronales superaron al modelo de referencia, aunque TiDE quedó muy cerca. TSMixer obtuvo el menor error, con un MAPE de 1,63 %, un 29 % inferior al de LGBM_OPT. Con el pronóstico de IFS, las diferencias se reducen: los modelos entrenados, salvo Chronos-2, se ubican entre 3,93 % y 4,22 %, porque el error del pronóstico meteorológico, común a todos, pasa a dominar. El ajuste de hiperparámetros de LightGBM produjo una mejora pequeña, de 2,39 % a 2,29 % con la meteorología observada y de 4,22 % a 4,14 % con IFS.

La figura 4.3 muestra el comportamiento por anticipación de los modelos más representativos de cada familia. Con la meteorología observada, el error de TSMixer, que genera el horizonte completo en un único paso, se mantiene casi constante, entre 1,45 % y 1,71 %. Las redes recurrentes, en cambio, obtienen el menor error en el día 0, con 1,19 % en LSTM, pero su error crece con la anticipación hasta 2,27 % en el día 14, como consecuencia de la acumulación de errores de la estrategia recursiva. Con IFS, las curvas de todos los modelos entrenados prácticamente se superponen a partir del día 7.

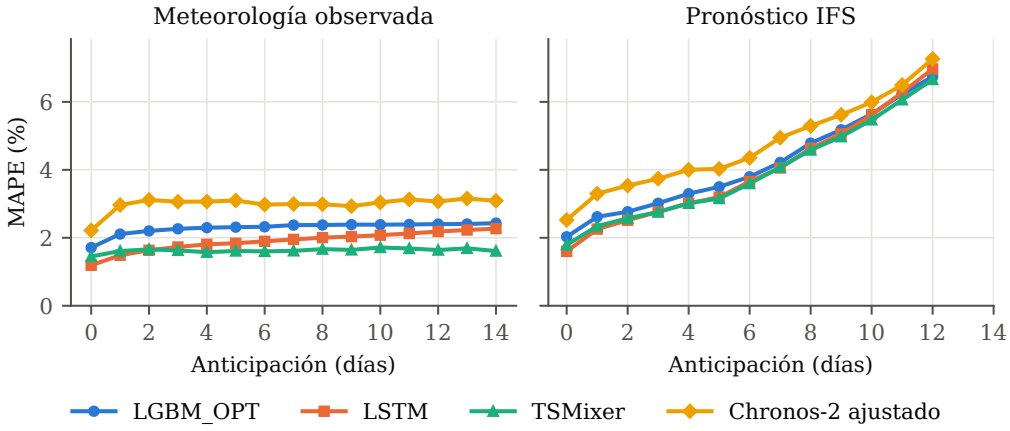


FIGURA 4.3. MAPE de la energía del MEM por anticipación de modelos seleccionados de la segunda etapa.

La figura 4.4 compara la distribución del error porcentual de LGBM_OPT y TSMixer con IFS. LGBM_OPT presenta una mediana negativa en casi todo el horizonte, que confirma la tendencia del modelo de referencia a subestimar la demanda. TSMixer tiene un sesgo cercano a cero y una dispersión menor en las primeras anticipaciones. En el día 12, ambos modelos presentan una dispersión similar, con un percentil 5 cercano a -14 % y un percentil 95 de entre 15 % y 17 %.

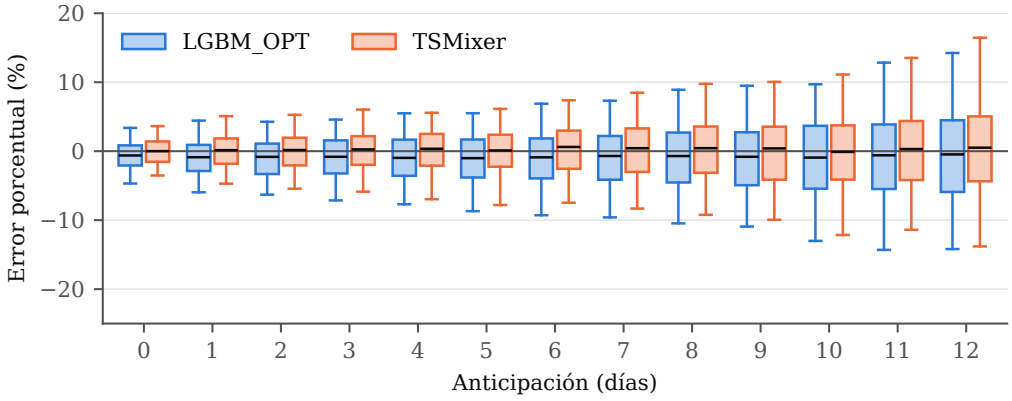


FIGURA 4.4. Distribución del error porcentual de la energía del MEM por anticipación de LGBM_OPT y TSMixer con el pronóstico de IFS. Las cajas representan los percentiles 25 y 75, y los bigotes, los percentiles 5 y 95.

Chronos-2 obtuvo los mayores errores entre los modelos entrenados. El ajuste mediante LoRA redujo su MAPE de 3,55 % a 2,99 % con la meteorología observada, pero no alcanzó al modelo de referencia, con un costo de entrenamiento superior al de las redes recurrentes y TSMixer. TiDE tuvo un desempeño inferior a TSMixer, la otra arquitectura basada en perceptrones multicapa, y TFT obtuvo resultados cercanos a los de TSMixer con un tiempo de entrenamiento seis veces mayor. A partir de estos resultados, se mantuvieron para las etapas siguientes los modelos indicados en la sección 3.2.3.

4.2.3. Covariables, fuentes meteorológicas y nivel de agregación

La tabla 4.4 compara las configuraciones Regional G5, Regional G5A y MEM G5 en la energía del MEM. En esta etapa se incorporaron los ensambles.

TABLA 4.4. MAPE (%) de la energía del MEM según la configuración, promedio de las anticipaciones 0 a 14. G5 y G5A corresponden a las configuraciones regionales.

	Meteorología observada			Pronóstico IFS		
Modelo	**G5**	**G5A**	**MEM G5**	**G5**	**G5A**	**MEM G5**
ENS_STACK	1,42	1,63	1,87	4,39	4,70	4,58
ENS_PROM	1,51	1,70	2,44	4,29	4,58	4,70
TSMixer	1,57	1,86	3,37	4,33	4,64	5,34
GRU	1,67	2,11	2,28	4,37	4,82	4,68
TFT	1,68	1,69	3,25	4,51	4,73	5,18
LSTM	1,82	1,84	2,83	4,43	4,57	4,85
LGBM_OPT	2,29	2,20	2,64	4,59	4,83	4,80
SNAIVE	9,14	9,14	9,14	9,15	9,15	9,15

Los ensambles mejoraron a los modelos individuales con la meteorología observada. ENS_STACK obtuvo un MAPE de 1,42 %, inferior al 1,57 % de TSMixer, el mejor modelo individual. Con IFS, ENS_PROM y ENS_STACK quedaron cerca del mejor modelo individual, con 4,29 % y 4,39 %, ya que el error meteorológico afecta a todos los modelos de la misma forma y reduce el beneficio de combinarlos.

La temperatura del aire produjo errores mayores que la temperatura aparente en casi todos los modelos. El MAPE de ENS_STACK aumentó de 1,42 % a 1,63 % con la meteorología observada y de 4,39 % a 4,70 % con IFS. La temperatura aparente incorpora el efecto de la humedad y del viento sobre la sensación térmica, que influye en el uso de equipos de climatización. Por este motivo, se mantuvo como opción principal.

El pronóstico directo de la energía del MEM resultó menos preciso que la suma de los pronósticos regionales en todos los modelos, con un MAPE de ENS_STACK de 1,87 % frente a 1,42 % con la meteorología observada. Las diferencias fueron mayores en TSMixer y TFT, que en el pronóstico directo disponen de una única serie para entrenar, en lugar de las diez series regionales del entrenamiento global. Por lo tanto, la energía del MEM se obtiene como suma de las regiones.

Grupos de pronósticos

La figura 4.5 compara el MAPE de ENS_STACK en la configuración Regional G5A con el pronóstico de IFS y con los dos grupos de pronósticos de la tabla 3.5. Los grupos redujeron el MAPE promedio de 4,60 % con IFS a 4,06 % con TWC + IFS y a 4,09 % con SMN + TWC + IFS, sobre el mismo conjunto de fechas. La mejora se concentra en las anticipaciones mayores: en el día 14, el MAPE pasa de 7,57 % con IFS a 6,35 % con TWC + IFS. Con ambos grupos, la configuración Regional G5A superó también el resultado de Regional G5 con IFS, de 4,39 %. Es decir, la menor precisión de la temperatura del aire se compensa con la combinación de fuentes que esa variable permite.

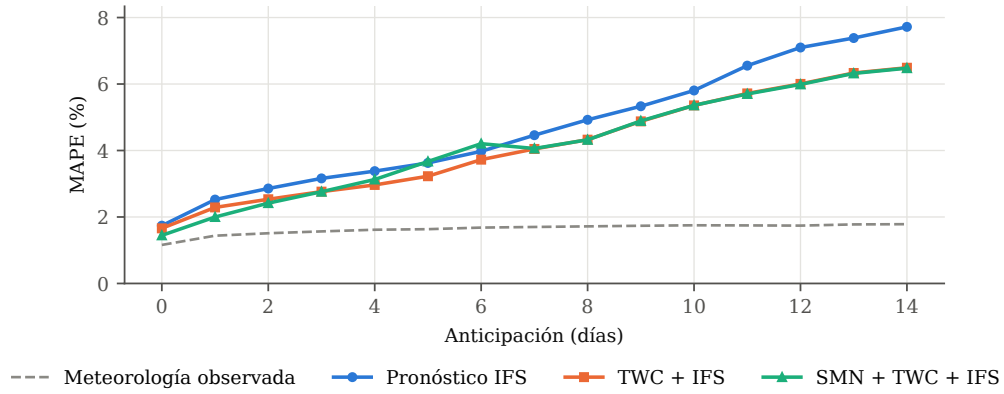


FIGURA 4.5. MAPE de la energía del MEM por anticipación de ENS_STACK en la configuración Regional G5A, según el pronóstico meteorológico utilizado.

El pronóstico del SMN mejoró las tres primeras anticipaciones, con un MAPE de 1,46 % en el día 0 frente a 1,66 % con TWC, pero empeoró las anticipaciones 4 a 6, en las que alcanzó 4,07 % en el día 6 frente a 3,62 %. En promedio, no mejoró al grupo que prescinde de esa fuente. Por este motivo, se adoptó el grupo TWC + IFS.

Indicador de actividad económica

La incorporación del EMAE produjo resultados dispares. Con la meteorología observada, el MAPE de LSTM se redujo de 1,90 % a 1,71 % y el de LGBM_OPT, de 2,29 % a 2,05 %, mientras que el de TSMixer aumentó de 1,63 % a 1,87 %. Con IFS, las variaciones fueron de hasta 0,2 puntos porcentuales, en ambos sentidos. La ausencia de una mejora consistente, sumada al costo de mantener una fuente externa adicional, fundamentó la decisión de no incorporarlo.

Potencias del MEM y comparación con el modelo de producción

La tabla 4.5 presenta las métricas de la configuración MEM G5 para las tres variables objetivo

TABLA 4.5. MAPE (%) de la configuración MEM G5 por variable objetivo, promedio de las anticipaciones 0 a 14.

	Meteorología observada			Pronóstico IFS		
Modelo	**EN**	**PI**	**MI**	**EN**	**PI**	**MI**
ENS_STACK	1,87	2,24	2,07	4,58	5,26	4,27
ENS_PROM	2,44	2,78	2,26	4,70	5,41	4,25
GRU	2,28	2,69	2,47	4,68	5,49	4,41
LGBM_OPT	2,64	3,00	2,85	4,80	5,46	4,56
LSTM	2,83	3,27	2,64	4,85	5,65	4,64
TFT	3,25	3,31	2,64	5,18	5,89	4,58
TSMixer	3,37	3,35	3,11	5,34	5,83	4,72
RLIN_LEGACY	6,08	5,91	5,35	7,41	7,51	6,44
SNAIVE	9,14	9,72	8,68	9,15	9,72	8,67

ENS_STACK obtuvo el menor error en las tres variables. La potencia pico resultó la variable más difícil de pronosticar, con un MAPE de 5,26 % con IFS, ya que corresponde a un valor horario extremo, mientras que la energía integra el comportamiento de todo el día. Respecto de RLIN_LEGACY (la réplica de la regresión lineal utilizada en producción antes del trabajo), el MAPE con IFS se redujo un 30 % en la potencia pico y un 34 % en la potencia mínima. En la energía, la reducción alcanza el 41 % si se considera la suma de los pronósticos regionales de la configuración Regional G5, con un MAPE de 4,39 % frente a 7,41 %.

Apéndice A

Modelo de datos del warehouse

En este apéndice se describen las tablas y vistas del warehouse `WH_PSYD` que intervienen en el pipeline de datos presentado en la sección 3.1. Se detallan los esquemas DEMANDA, METEO y PRONOS, junto con las dimensiones que los vinculan, y el esquema MODELOS, que almacena los resultados de los modelos en producción. Para cada objeto se indican la capa a la que pertenece, su clave y su contenido. Las variables comunes a varias tablas se describen una única vez.

A.1. Relaciones entre esquemas

Los esquemas se vinculan mediante tres identificadores. `RGE_ID` identifica las regiones eléctricas, definidas en la tabla `REGIONES_ELECTRICAS_TOTALES` del esquema `GENERAL`. Luego, `EMET_ID` identifica las estaciones meteorológicas, y `PRON_ID` identifica los modelos y servicios de pronóstico. Las tablas de dimensiones incluyen períodos de vigencia (`FECHA_DESDE` y `FECHA_HASTA`), por lo que las vistas de capa 3 asocian cada estación con su región según la fecha del dato. La figura A.1 resume estas relaciones.

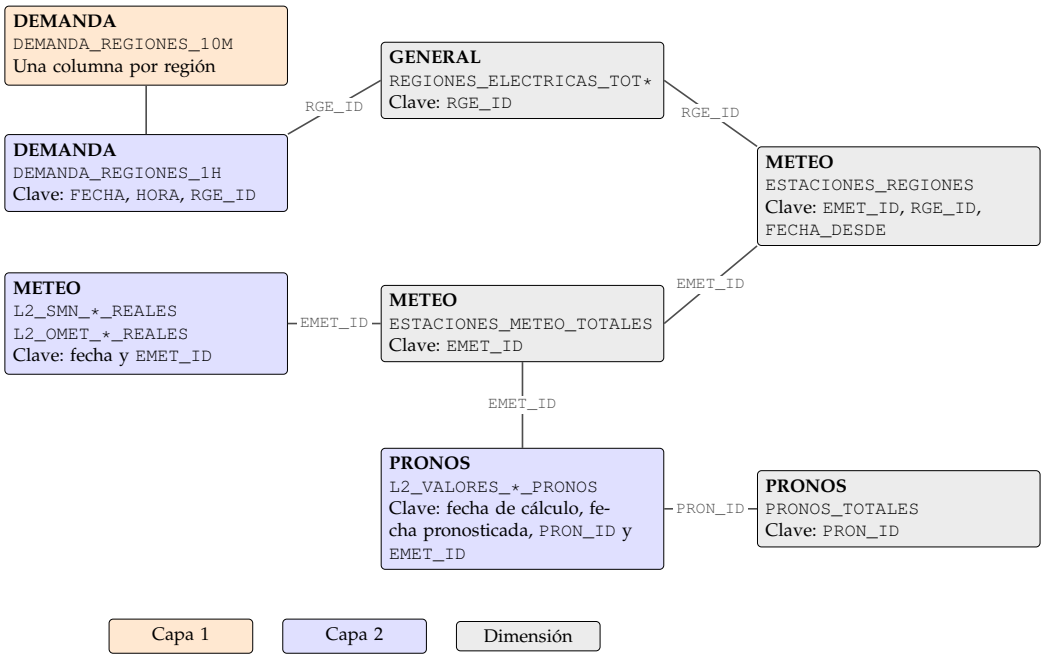


FIGURA A.1. Relaciones entre las tablas principales de los esquemas DEMANDA, METEO y PRONOS.

A.2. Esquema DEMANDA

El esquema DEMANDA contiene la demanda eléctrica calculada a partir del SOTR y las variables objetivo de los modelos. La tabla A.1 describe sus objetos.

TABLA A.1. Tablas y vistas del esquema DEMANDA.

Objeto	Tipo y capa	Clave	Contenido
DEMANDA_ REGIONES_10M	Tabla, capa 1	FECHA, HORA, INTERVALO	Demanda en MW cada diez minutos, en formato ancho, con una columna por región y otra para el MEM, junto con las variables de control del cálculo.
DEMANDA_ REGIONES_1H	Tabla, capa 2	FECHA, HORA, RGE_ID	Demanda horaria depurada por región, con el valor original anterior a la limpieza y la marca de corrección.
DEMANDAS_MEM	Vista, capa 3	FECHA, TARGET_ ID_ASOCIADO	Variables objetivo diarias del MEM: energía (1), potencia máxima entre las 6 y las 24 horas (2) y potencia mínima entre las 0 y las 12 horas (3).

La tabla A.2 detalla las columnas de las dos tablas del esquema.

TABLA A.2. Columnas de las tablas del esquema DEMANDA.

Columna	Descripción
Tabla DEMANDA_ REGIONES_10M	
FECHA, HORA, INTERVALO	Fecha, hora e intervalo de diez minutos de la medición.
MEM	Demanda del MEM, calculada como suma de las regiones, en MW.
GBA, CEN, LIT, CUY, NEA, NOA, COM, PBN, PBS, PAT	Demanda de cada región eléctrica corregida por pérdidas, en MW.
CHK_MEM_TAG, CHK_MEM_DIF, CHK_MEM_DIF_PORC	Medidor nacional de referencia y diferencias absoluta y porcentual respecto del MEM calculado.
CHK_PBA, CHK_PBN_TAG, CHK_PBS_TAG, CHK_PBA_PARTICION, CHK_DIF_PBN, CHK_DIF_PBS, CHK_DIF_PBN_PORC, CHK_DIF_PBS_PORC	Controles de la partición de PBA: demanda original de la región, mediciones directas de PBN y PBS y diferencias absolutas y porcentuales asociadas con la partición.
CHK_INTERCAMBIOS	Suma de los intercambios entre regiones, que debe permanecer próxima a cero.
Tabla DEMANDA_REGIONES_1H	
FECHA, HORA	Fecha y hora, con la convención horaria de CAMMESA (1 a 24).
RGE_ID	Identificador de la región eléctrica.
VALOR	Demanda horaria depurada, en MW.
VALOR_ORIGINAL	Demanda horaria calculada con los datos anteriores a la limpieza, en MW.
FLAG_CORREGIDO	Indica si VALOR difiere de VALOR_ORIGINAL.

A.3. Esquema METEO

El esquema METEO contiene las estaciones meteorológicas, su asociación con las regiones eléctricas y los datos observados del SMN y de Open-Meteo. La tabla A.3 describe sus objetos. Las tablas de capa 2 se separan por fuente y por resolución, mientras que las vistas de capa 3 integran ambas fuentes: para cada variable toman el valor del SMN y, si no está disponible, el de Open-Meteo.

TABLA A.3. Tablas y vistas del esquema METEO.

Objeto	Tipo y capa	Clave	Contenido
ESTACIONES_METEO_TOTALES	Dimensión	EMET_ID	Estaciones meteorológicas: nombre, código OACI, provincia, región y prioridad dentro de ella, coordenadas, altura, localidad del SMN y vigencia.
ESTACIONES_REGIONES	Dimensión	EMET_ID, RGE_ID	Estación representativa de cada región eléctrica y su período de vigencia.
L2_SMN_VALORES_HORARIOS_REALES	Tabla, capa 2	FECHA_HORA, EMET_ID	Observaciones horarias del SMN y temperatura aparente calculada.
L2_SMN_VALORES_DIARIOS_REALES	Tabla, capa 2	FECHA, EMET_ID	Valores diarios del SMN, sin nubosidad, precipitación ni radiación.
L2_OMET_VALORES_HORARIOS_REALES	Tabla, capa 2	FECHA_HORA, EMET_ID	Valores horarios de Open-Meteo para las coordenadas de cada estación.
L2_OMET_VALORES_DIARIOS_REALES	Tabla, capa 2	FECHA, EMET_ID	Valores diarios de Open-Meteo para las coordenadas de cada estación.
L3_METEO_VALORES_HORARIOS_REALES	Vista, capa 3	FECHA_HORA, EMET_ID	Valores horarios por estación que integran ambas fuentes.
L3_METEO_VALORES_DIARIOS_REALES	Vista, capa 3	FECHA, EMET_ID	Valores diarios por estación que integran ambas fuentes.
L3_METEO_VALORES_HORARIOS_REALES_REGIONES	Vista, capa 3	FECHA_HORA, RGE_ID	Valores horarios de la estación vigente para cada región eléctrica.
L3_METEO_VALORES_DIARIOS_REALES_REGIONES	Vista, capa 3	FECHA, RGE_ID	Valores diarios de la estación vigente para cada región eléctrica.

Las tablas A.4 y A.5 describen las variables meteorológicas horarias y diarias. Son las mismas en las tablas de datos observados y en las de pronósticos. Cada tabla contiene solo las variables que su fuente provee. Todas incluyen, además, la columna ULT_FECHA, con la fecha y hora de la última actualización del registro.

TABLA A.4. Variables meteorológicas horarias.

Columna	Unidad	Descripción
FECHA_HORA	–	Fecha y hora local (UTC-3) del valor.
FECHA, HORA	–	Fecha y hora con la convención horaria de CAMMESA (1 a 24).
TEMPERATURA	°C	Temperatura del aire a 2 m de altura.
HUMEDAD_RELATIVA	%	Humedad relativa a 2 m de altura.
PRESION_HPA	hPa	Presión atmosférica.
VIENTO_VEL_KMH	km/h	Velocidad del viento a 10 m de altura.
VIENTO_DIR_GRADOS	°	Dirección del viento.
NUBOSIDAD_PORC	%	Cobertura nubosa total.
TEMPERATURA_APARENTE	°C	Temperatura aparente según la ecuación 3.1. En la tabla del SMN se denomina TEMP_APARENTE_CALC.
PRECIPITACION_MM	mm	Precipitación acumulada en la hora.
RADIACION_SOLAR_GHI_WM2	W/m^2	Radiación solar global media de la hora.

TABLA A.5. Variables meteorológicas diarias.

Columna	Unidad	Descripción
FECHA	–	Fecha del valor.
TEMP_MAX, TEMP_MIN	°C	Temperaturas máxima y mínima del día.
TEMP_MED	°C	Semisuma de las temperaturas máxima y mínima.
TEMP_AVG	°C	Promedio de las temperaturas del día.
TEMP_APARENTE_MAX, TEMP_APARENTE_MIN, TEMP_APARENTE_MED, TEMP_APARENTE_AVG	°C	Valores análogos para la temperatura aparente.
VIENTO_VEL_8HS_KMH, VIENTO_VEL_15HS_KMH, VIENTO_VEL_21HS_KMH	km/h	Velocidad del viento a las 8, 15 y 21 horas.
VIENTO_DIR_8HS_GRADOS, VIENTO_DIR_15HS_GRADOS, VIENTO_DIR_21HS_GRADOS	°	Dirección del viento a las 8, 15 y 21 horas.
HUMEDAD_RELATIVA_15HS	%	Humedad relativa a las 15 horas.
NUBOSIDAD_MEDIA_PORC	%	Cobertura nubosa media del día.
PRECIPITACION_ACUM_MM	mm	Precipitación acumulada en el día.
RADIACION_SOLAR_ACUM_MJ_M2	MJ/m^2	Radiación solar global acumulada en el día.

A.4. Esquema PRONOS

El esquema PRONOS contiene los modelos y servicios de pronóstico meteorológico y los valores pronosticados. La tabla A.6 describe sus objetos. A diferencia del esquema METEO, las tablas de capa 2 integran todas las fuentes y las distinguen mediante PRON_ID. Las vistas de capa 3 presentan los valores por región eléctrica, según la estación vigente en la fecha de cálculo.

TABLA A.6. Tablas y vistas del esquema PRONOS.

Objeto	Tipo y capa	Clave	Contenido
PRONOS_TOTALES	Dimensión	PRON_ID, FECHA_DESDE	Modelos y servicios de pronóstico: servicio, modelo, horizonte en días, descripción, parámetro de consulta a la API y vigencia.
L2_VALORES_HORARIOS_PRONOS	Tabla, capa 2	FECHA_CALCULO, FECHA_HORA_PRONOS, PRON_ID, EMET_ID	Valores horarios pronosticados por los modelos de Open-Meteo.
L2_VALORES_DIARIOS_PRONOS	Tabla, capa 2	FECHA_CALCULO, FECHA_PRONOS, PRON_ID, EMET_ID	Valores diarios pronosticados por Open-Meteo, TWC y el SMN.
L3_VALORES_HORARIOS_PRONOS_REGIONES	Vista, capa 3	FECHA_CALCULO, FECHA_HORA_PRONOS, PRON_ID, RGE_ID	Valores horarios pronosticados para cada región eléctrica.
L3_VALORES_DIARIOS_PRONOS_REGIONES	Vista, capa 3	FECHA_CALCULO, FECHA_PRONOS, PRON_ID, RGE_ID	Valores diarios pronosticados para cada región eléctrica.

Las variables meteorológicas de estas tablas son las descritas en las tablas A.4 y A.5. La tabla A.7 detalla las columnas propias de los pronósticos.

TABLA A.7. Columnas propias de las tablas y vistas del esquema PRONOS.

Columna	Descripción
FECHA_CALCULO	Fecha de la ejecución del modelo o de la consulta al servicio que generó el pronóstico.
FECHA_PRONOS, FECHA_HORA_PRONOS	Fecha, o fecha y hora local, a la que corresponde el valor pronosticado.
ANTICIPACION_DIAS	Diferencia en días entre la fecha pronosticada y la fecha de cálculo.
PRON_ID, MODELO	Identificador y nombre del modelo o servicio de pronóstico.
EMET_ID, NOMBRE_ESTACION	Identificador y nombre de la estación cuyas coordenadas se utilizaron en la consulta.
RGE_ID, RGE_NEMO	Identificador y abreviatura de la región eléctrica (solo en las vistas de capa 3).

A.5. Esquema MODELOS

El esquema MODELOS contiene el catálogo de modelos y de escenarios meteorológicos de producción, los pronósticos generados y los errores calculados a medida que se conocen los valores reales. La tabla A.8 describe sus objetos. Los escenarios se definen mediante reglas que indican, para cada variable meteorológica y rango de anticipaciones, la fuente utilizada y si se aplica la corrección del sesgo, por lo que un nuevo grupo de pronósticos puede incorporarse sin modificar el código.

TABLA A.8. Tablas y vistas del esquema MODELOS.

Objeto	Tipo y capa	Clave	Contenido
MODELOS_TOTALES	Dimensión	MOD_ID, FECHA_DESDE	Modelos productivos: nombre, algoritmo, variable objetivo, nivel (región o MEM), variante de temperatura y vigencia.
ESCENARIOS_ TOTALES	Dimensión	ESC_ID	Escenarios meteorológicos: nombre, descripción y vigencia.
ESCENARIOS_ FUENTES	Dimensión	ESC_ID, VARIABLE, ANT_DESDE	Fuente (PRON_ID) de cada variable meteorológica por rango de anticipaciones e indicador de corrección del sesgo.
RESULTADOS_ MODELOS	Tabla, capa 2	FECHA_CALCULO, FECHA_PRONOS, MOD_ID, ESC_ID, RGE_ID	Predicción de cada modelo y escenario, con la anticipación y la versión del modelo registrada en MLflow.
PRONOSTICOS_ DEMANDA	Tabla, capa 2	FECHA_CALCULO, FECHA_PRONOS, TARGET_ID, RGE_ID	Pronóstico publicado de cada variable objetivo, valor previo a la corrección del sesgo, sesgo aplicado y fuentes utilizadas en el promedio.
ERRORES_MODELOS	Vista, capa 3	FECHA_CALCULO, FECHA_PRONOS, MOD_ID, ESC_ID, RGE_ID	Valor real, error, error absoluto y error porcentual absoluto de cada predicción y del pronóstico publicado.

Bibliografía

[1] Congreso de la Nación Argentina. *Ley 24.065: Régimen de la energía eléctrica*. Boletín Oficial de la República Argentina, 16 de enero de 1992. https://mepriv.mecon.gob.ar/Normas/24065.htm. Consultado el 5 de octubre de 2026. 1992.

[2] Poder Ejecutivo Nacional. *Decreto 1192/1992: Constitución de la Compañía Administradora del Mercado Mayorista Eléctrico Sociedad Anónima*. https://mepriv.mecon.gob.ar/Normas/1192-92.htm. Consultado el 5 de octubre de 2026. 1992.

[3] CAMMESA. *Empresa*. https://cammesaweb.cammesa.com/empresa/. Consultado el 5 de octubre de 2026.

[4] Oscar A. Oviedo. «Short-Term Regional Electricity Demand Forecasting in Argentina Using LSTM Networks». En: *arXiv preprint arXiv:2509.19374* (2025). DOI: 10.48550/arXiv.2509.19374. arXiv: 2509.19374 [eess.SP]. URL: https://arxiv.org/abs/2509.19374.

[5] Mariela N. Uhrig, Leandro D. Vignolo y Omar V. Müller. «Multivariate Forecasting of Energy Demand Using Recurrent Neural Networks». En: *Advanced Engineering Informatics* 71 (2026), pág. 104419. DOI: 10.1016/j.aei.2026.104419. URL: https://sinc.unl.edu.ar/sinc-publications/2026/UVM26/.

[6] João Vitor Leme et al. «Towards Assessing the Electricity Demand in Brazil: Data-Driven Analysis and Ensemble Learning Models». En: *Energies* 13.6 (2020), pág. 1407. DOI: 10.3390/en13061407. URL: https://doi.org/10.3390/en13061407.

[7] Giancarlo Aquila et al. «An Overview of Short-Term Load Forecasting for Electricity Systems Operational Planning: Machine Learning Methods and the Brazilian Experience». En: *Energies* 16.21 (2023), pág. 7444. DOI: 10.3390/en16217444. URL: https://doi.org/10.3390/en16217444.

[8] Bryan Lim et al. «Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting». En: *International Journal of Forecasting* 37.4 (2021), págs. 1748-1764.

[9] Abhimanyu Das et al. «Long-term Forecasting with TiDE: Time-series Dense Encoder». En: *Transactions on Machine Learning Research* (2023).

[10] Si-An Chen et al. «TSMixer: An All-MLP Architecture for Time Series Forecasting». En: *Transactions on Machine Learning Research* (2023).

[11] Marcel Meyer et al. «Benchmarking Time Series Foundation Models for Short-Term Household Electricity Load Forecasting». En: *IEEE Access* 13 (2025), págs. 218141-218153. DOI: 10.1109/ACCESS.2025.3648056.

[12] Dagster Labs. *Dagster Documentation: Overview*. 2026. URL: https://docs.dagster.io/ (visitado 12-09-2026).

[13] Dagster Labs. *Dagster Documentation: Assets*. 2026. URL: https://docs.dagster.io/api/dagster/assets (visitado 12-09-2026).

[14] Microsoft. *Use Fabric notebooks with data from a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/notebooks (visitado 12-09-2026).
[15] PIconnect Contributors. *PIconnect Documentation*. 2026. URL: https://piconnect.readthedocs.io/en/main/ (visitado 12-09-2026).
[16] Julien Herzen et al. «Darts: User-Friendly Modern Machine Learning for Time Series». En: *Journal of Machine Learning Research* 23.124 (2022), págs. 1-6.
[17] Takuya Akiba et al. «Optuna: A Next-generation Hyperparameter Optimization Framework». En: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, págs. 2623-2631. DOI: 10.1145/3292500.3330701.
[18] James Bergstra et al. «Algorithms for Hyper-Parameter Optimization». En: *Advances in Neural Information Processing Systems 24*. 2011, págs. 2546-2554.
[19] Microsoft. *Microsoft Fabric interactive exercises: Data science and MLflow*. 2026. URL: https://microsoftlearning.github.io/mslearn-fabric/ (visitado 12-09-2026).
[20] Microsoft. *What is Power BI?* 2026. URL: https://learn.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview (visitado 16-10-2026).
[21] SMN. *Datos Abiertos SMN*. 2026. URL: https://www.smn.gob.ar/descarga-de-datos (visitado 13-09-2026).
[22] Open-Meteo. *Historical Weather API*. 2026. URL: https://open-meteo.com/en/docs/historical-weather-api (visitado 12-09-2026).
[23] Open-Meteo. *Historical Forecast API*. 2026. URL: https://open-meteo.com/en/docs/historical-forecast-api (visitado 12-09-2026).
[24] The Weather Channel. *The Weather Channel - Buenos Aires*. 2026. URL: https://weather.com/es-AR/ar/city/buenos-aires/today (visitado 13-09-2026).
[25] Pablo Montero-Manso y Rob J. Hyndman. «Principles and Algorithms for Forecasting Groups of Time Series: Locality and Globality». En: *International Journal of Forecasting* 37.4 (2021), págs. 1632-1653. DOI: 10.1016/j.ijforecast.2021.03.004.
[26] Leo Breiman. «Random Forests». En: *Machine Learning* 45.1 (2001), págs. 5-32.
[27] Tianqi Chen y Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 785-794.
[28] Guolin Ke et al. «LightGBM: A Highly Efficient Gradient Boosting Decision Tree». En: *Advances in Neural Information Processing Systems 30*. 2017.
[29] Sepp Hochreiter y Jürgen Schmidhuber. «Long Short-Term Memory». En: *Neural Computation* 9.8 (1997), págs. 1735-1780.
[30] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. 2014, págs. 1724-1734.
[31] Abdul Fatir Ansari, Oleksandr Shchur, Jaris Küken et al. *Chronos-2: From Univariate to Universal Forecasting*. https://arxiv.org/abs/2510.15821. 2025. arXiv: 2510.15821.
[32] Jerome H. Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.
[33] Boris N. Oreshkin et al. «N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting». En: *arXiv preprint arXiv:1905.10437* (2020). DOI: 10.48550/arXiv.1905.10437. arXiv: 1905.10437 [cs.LG]. URL: https://arxiv.org/abs/1905.10437.

[34] Cristian Challu et al. «N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6. 2023, págs. 6989-6997. DOI: 10.1609/aaai.v37i6.25854. URL: https://doi.org/10.1609/aaai.v37i6.25854.

[35] Abdul Fatir Ansari et al. «Chronos: Learning the Language of Time Series». En: *Transactions on Machine Learning Research* (2024). URL: https://openreview.net/forum?id=gerNCVqqtR.

[36] Edward J. Hu et al. «LoRA: Low-Rank Adaptation of Large Language Models». En: *International Conference on Learning Representations*. 2022.

[37] David H. Wolpert. «Stacked Generalization». En: *Neural Networks* 5.2 (1992), págs. 241-259. DOI: 10.1016/S0893-6080(05)80023-1.

[38] J. M. Bates y C. W. J. Granger. «The Combination of Forecasts». En: *Operational Research Quarterly* 20.4 (1969), págs. 451-468. DOI: 10.2307/3008764.

[39] Enric Valor, Vicente Meneu y Vicente Caselles. «Daily Air Temperature and Electricity Load in Spain». En: *Journal of Applied Meteorology* 40.8 (2001), págs. 1413-1421. DOI: 10.1175/1520-0450(2001)040<1413:DATAEL>2.0.CO;2.

[40] Harry R. Glahn y Dale A. Lowry. «The Use of Model Output Statistics (MOS) in Objective Weather Forecasting». En: *Journal of Applied Meteorology* 11.8 (1972), págs. 1203-1211. DOI: 10.1175/1520-0450(1972)011<1203:TUOMOS>2.0.CO;2.

[41] Microsoft. *Analyze data in a KQL database*. 2026. URL: https://learn.microsoft.com/en-us/fabric/real-time-intelligence/eventhouse-analyze-data-with (visitado 12-09-2026).

[42] Microsoft. *Documentación de Data Warehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-warehouse/ (visitado 13-09-2026).

[43] Microsoft. *Documentación de Data Lakehouse*. 2026. URL: https://learn.microsoft.com/es-es/fabric/data-engineering/lakehouse-overview (visitado 13-09-2026).

[44] Microsoft. *Documentación de Pipeline*. 2026. URL: https://learn.microsoft.com/es-mx/fabric/data-factory/pipeline-overview (visitado 13-09-2026).

[45] Google. *Google Colaboratory*. 2026. URL: https://colab.research.google.com/ (visitado 12-10-2026).

[46] Robert G. Steadman. «Norms of apparent temperature in Australia». En: *Australian Meteorological Magazine* 43 (1994), págs. 1-16.

[47] Open-Meteo. *Open-Meteo: código fuente del módulo* `Meteorology.swift`. https://github.com/open-meteo/open-meteo/blob/main/Sources/App/Helper/Meteorology.swift. Consultado el 28 de septiembre de 2026.

[48] European Centre for Medium-Range Weather Forecasts. *IFS documentation*. https://www.ecmwf.int/en/publications/ifs-documentation. Consultado el 28 de septiembre de 2026.

[49] Günther Zängl et al. «The ICON (ICOsahedral Non-hydrostatic) modelling framework of DWD and MPI-M: Description of the non-hydrostatic dynamical core». En: *Quarterly Journal of the Royal Meteorological Society* 141.687 (2015), págs. 563-579. DOI: 10.1002/qj.2378.

[50] National Centers for Environmental Information. *Global Forecast System (GFS)*. https://www.ncei.noaa.gov/products/weather-climate-models/global-forecast. Consultado el 28 de septiembre de 2026.

[51] David Walters et al. «The Met Office Unified Model Global Atmosphere 7.0/7.1 and JULES Global Land 7.0 configurations». En: *Geoscientific Model Development* 12.5 (2019), págs. 1909-1963. DOI: 10.5194/gmd-12-1909-2019.

[52] Open-Meteo. *Single Runs API*. https://open-meteo.com/en/docs/single-runs-api. Consultado el 28 de septiembre de 2026.
[53] Open-Meteo. *Historical Forecast API*. https://open-meteo.com/en/docs/historical-forecast-api. Consultado el 28 de septiembre de 2026.